

SSQR 中文精读导读：把知识图谱“压缩成离散码”，无缝塞进大模型

原文：Lin, Zhao, He, Peng, Xu, Huang, Ma, Feng（新加坡国立大学、西安交通大学，ACL 2025）

本导读为面向初学者的中文学习笔记：含要点翻译、公式精讲与图表解读。

论文卡片

标题	Self-supervised Quantized Representation for Seamlessly Integrating Knowledge Graphs with Large Language Models
中译	用自监督量化表示，把知识图谱无缝接入大语言模型
作者	Qika Lin, Tianzhe Zhao, Kai He, Zhen Peng, Fangzhi Xu, Ling Huang, Jingying Ma, Mengling Feng
机构	新加坡国立大学（NUS）、西安交通大学
会议	ACL 2025（计算语言学协会年会）
arXiv	2501.18119
方向	知识图谱（KG）× 大模型 × 向量量化 / 离散表示
一句话	把每个实体的“结构 + 语义”用自监督方式压成 16 个离散码（token），这些码能像普通词一样直接喂进 LLM，做知识图谱补全等任务。

1 一、这篇论文在解决什么问题

知识图谱（Knowledge Graph, KG）用三元组“（头实体, 关系, 尾实体）”的形式，把海量事实知识结构化地存起来，例如“（哈利波特, 作者, J.K. 罗琳）”。它是大语言模型（Large Language Model, LLM，如 LLaMA、GPT-4）的天然“知识外挂”：能补充事实、减少胡说。

但麻烦在于：**KG 是“图”，LLM 只认“一串离散的词（token）”**，两者的表示形式天生不一样（作者称之为“自然鸿沟 natural gap”）。怎么把图的结构信息无缝注入 LLM，是一个公开难题。已有做法都有硬伤：

1. 直接把子图“摊平”成文字喂给 LLM（图 1(a)）：把相关三元组、邻居一条条写成文本提示。问题是 token 会爆炸——作者实测，FB15k-237 上只采样 20% 的 2-跳邻居，每个实体平均就需要

约 3000 个 token (中位数也要约 300 个), 30% 采样时中位数更逼近 2500。一个任务往往涉及多个实体, 连最强的长上下文 LLM 也吃不消; 而采样又会破坏图的整体结构、丢信息。

2. 用一个可学习的适配器 (adapter) 把 KG 的连续向量嵌入对齐进 LLM: 要额外引入新网络, 还要在“KG 嵌入空间”和“LLM 表示空间”这两个不同的隐空间之间做精细对齐, 很别扭。
3. 已有的“量化”方法是无监督的 (NodePiece、EARL、RandomEQ): 它们靠无监督地选“锚点 (anchor)”来表示实体, 无法对图的整体结构和语义做建模, 码的区分度不够。

本文的目标: 借鉴多模态大模型里的“早融合 (early fusion)”思想, 把每个实体压缩成一串 **离散的码 (discrete codes, 即 token)**, 而不是连续向量。这些码和自然语言是同一种“离散形式”(见图 1(b)), 于是只要给 LLM 的词表扩充这些新 token, 就能**无缝**把 KG 接进 LLM, 不用改任何框架结构。




图 1: 把 KG 接入 LLM 的两种策略 (原文 Figure 1, 图内英文为原文保留)。(a) 直接法: 把 (采样得到的) 图结构和语义文本一条条写成文字喂给 LLM, token 量巨大; (b) 本文 SSQR: 先用编码器把实体学成一小串离散的量化码 (图中绿色小方块里的数字 5,73,47,...), 再像普通词一样喂进 LLM, 实现“无缝整合”。

2 二、摘要中译

由于知识图谱 (KG) 结构与自然语言之间存在天然鸿沟, 如何把 KG 的整体结构信息有效地与大语言模型 (LLM) 结合, 已成为一个重要问题。为此, 我们提出一个**两阶段框架**, 为每个实体学习并应用 **量化码 (quantized codes)**, 以实现 KG 与 LLM 的无缝整合。第一阶段, 我们提出一种 **自监督量化表示 (Self-supervised Quantized Representation, SSQR)** 方法, 把 KG 的结构知识与语义知识一起压缩成离散的码 (即 token), 使其对齐自然语言句子的格式。第二阶段, 我们把这些学到的码当作特征, 设计 KG 指令跟随 (instruction-following) 数据直接输入 LLM, 从而实现无缝整合。实验表明: SSQR 优于已有的无监督量化方法, 能产生区分度更高的码; 进一步地, 微调后的 LLaMA2 与 LLaMA3.1

在 KG 链接预测 (link prediction) 与三元组分类 (triple classification) 任务上也取得了更优表现, 而且**每个实体只用 16 个 token**, 远少于传统提示方法所需的成千上万个 token。

3 三、三大核心贡献

1. **首个自监督的 KG 量化方法 (SSQR)**: 能同时获取 KG 的结构与语义知识。据作者所知, 这是第一项以自监督方式做 KG 量化学习的研究。
2. **首次用学到的码“无缝”整合 KG 与 LLM**: 把码当作输入特征、设计 KG 指令数据, 无需修改 LLM 框架, 只需扩充词表。可广泛用于 KG 链接预测、三元组分类等任务。
3. **扎实的实验证据**: SSQR 优于现有无监督量化方法、码更可区分; 仅用 16 个码, 微调后的 LLaMA2 / LLaMA3.1 在链接预测和三元组分类上都表现优越。

4 四、预备知识 (小白先看这里)

【小白补丁】知识图谱 (KG) 与三元组 (triple)

KG 把知识写成“(头实体 h , 关系 r , 尾实体 t)”的三元组, 例如“(北京, 是首都, 中国)”。一堆三元组连起来就成了一张“图”: 实体是**节点**, 关系是带标签的**有向边**。本文形式化记作 $G = \{\mathcal{E}, \mathcal{R}, \mathcal{F}\}$ ——实体集 $\mathcal{E}$ 、关系集 $\mathcal{R}$ 、三元组集 $\mathcal{F} \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}$ 。

【小白补丁】什么是“量化 / 向量量化 (VQ) / 码本 (codebook)”

量化 (quantization) 就是“把连续的东西, 用有限个离散档位来近似表示”。**向量量化 (Vector Quantization, VQ)** 更具体: 先准备一本**码本 (codebook)** $X = [x_1, x_2, \dots, x_M]$ ——可以把它想成一个有 M 行的“调色板/字典”, 每一行 x_m 是一个可学习的向量, 代表第 m 号“码 (code)”。给定任意一个向量 e , 就在码本里找离它最近的那一行, 用那一行的“编号 i ”来代替它。于是“一个连续向量”就被压成了“一个离散整数编号”, 正好像一个词的 ID。VQ 最早火于 VQ-VAE、VQ-GAN 这类图像生成模型。本文把它搬到了 KG 上。

【小白补丁】为什么要“离散码”而不是“连续向量”

LLM 的词表本质是一堆离散 token (每个词一个整数 ID)。如果实体也被表示成**离散整数码**, 它就和普通词“同一种语言”, 可以直接塞进 LLM 的词表和句子里, 无需额外的对齐网络——这正是“无缝”

的来源。反观连续向量，得再训一个适配器去对齐空间，麻烦且容易没对准。

【小白补丁】自监督 (self-supervised) 与 “语义蒸馏”

自监督指不依赖人工标注，而是从数据本身造出“监督信号”来训练。本文的自监督信号有两路：(1) **结构重建**——要求学到的码能反推回“原图里哪些三元组成立”；(2) **语义蒸馏 (distilling)**——让码去对齐“一个现成大模型给实体文字描述算出的文本向量”。**蒸馏**就是“让小模型/新表示去模仿大模型的输出”，这里是让离散码去逼近 LLM 的语义嵌入。

形式化记号（看不懂可跳过，用到时再回看）：对每个实体 e ，用它的**邻居** $N(e)$ 描述结构，用它的**文字描述** T_e 描述语义。码本大小记作 M （共多少种码），每个实体被表示成长度为 N 的**码序列** $[q_1, q_2, \dots, q_N]$ （每个 q_n 是码本里的一个编号）。直觉上： M 越大“调色板”越丰富， N 越长“每个实体用的码越多、越能精细刻画”。

5 五、数据集与任务

作者在三个常用 KG 数据集上做实验（统计源自原文 Table 6）：

表 1：实验所用数据集统计（数据源自原文 Table 6）。前两个用于链接预测，FB15k-237N 用于三元组分类。

数据集	实体数	关系数	训练集	验证集	测试集
WN18RR	40,943	11	86,835	3,034	3,134
FB15k-237	14,541	237	272,115	17,535	20,466
FB15k-237N	13,104	93	87,282	7,041/7,041	8,226/8,226

- **WN18RR**：源自 WordNet 的词义关系图，关系种类少（11 种）、结构稀疏、实体多。
- **FB15k-237**：源自 Freebase 的常识知识图，关系种类多（237 种）、结构丰富。
- **FB15k-237N**：上者的变体，带正/负样本（“/” 左右分别是正、负），专门用于三元组分类。

两个下游任务：

1. **链接预测 (link prediction) / KG 补全**：给定一个缺尾巴的查询三元组 $(h, r, ?)$ ，从候选实体里预测正确的尾实体，并排序。指标用 **MRR**（平均倒数排名）和 **Hits@k**（正确答案排进前 k 名的比例）。

2. **三元组分类 (triple classification)**: 判断一个给定三元组 (h, r, t) 是真还是假 (True/False)。指标用准确率 Acc、精确率 P、召回率 R、F1。

【小白补丁】MRR 和 Hits@ k 怎么读

模型对每个查询会输出一个候选排名列表。**Hits@1** = 正确答案恰好排第一的比例(越高越好); **Hits@10** = 正确答案排进前 10 的比例。**MRR**: 若正确答案排第 n 名, 则该题得分 $1/n$, 对所有题求平均——排得越靠前, 分越高。三者都是“越大越好”。

6 六、方法逐节精讲：SSQR 怎么把图压成码

整体是一条**两阶段流水线**(见图 2): **阶段一**(图 (a)) 自监督地学码——编码器把图结构编码, 经向量量化得到离散码, 再用两路监督(结构重建 + 语义蒸馏)训练; **阶段二**(图 (b)) 把学好的“编码器 + 量化”冻结, 用它给实体生成码, 把码写进指令里去微调 LLM。图中**火苗图标**表示该模块在训练(参数更新), **雪花图标**表示冻结不动。




图 2: SSQR 总体架构 (原文 Figure 3, 图内英文为原文保留)。(a) SSQR 量化表示学习: 图 $G \rightarrow$ Encoder (GCN 编码多跳邻居结构) $\rightarrow$ quantization (按码本 X 就近匹配, 得到离散码) $\rightarrow$ Decoder (做结构重建, 虚线回到原图); 同时下方一路把实体文字经冻结的 LLM 得到语义向量, 做语义蒸馏对齐。(b) 指令微调: 把冻结的“Encoder & Quantization”产生的码, 作为 Input 写进 Instruction, 交给 LLM 生成答案。火苗 = 训练, 雪花 = 冻结。

6.1 第 1 步：结构建模 (Structural Modeling) ——用 GCN 编码邻居

用图卷积网络 (Graph Convolutional Network, GCN) 按“消息传递”逐层更新实体向量, 把第 l 层的表示更新到第 $l+1$ 层:

$$e_j^{l+1} = W_1^l e_j^l + \sum_{(e_i, r) \in N(e_j)} W_2^l m_{e_i, r, e_j}^l, \quad (1)$$

其中 e 是实体向量, W 是变换矩阵, m 是某条边携带的“消息”。边的消息用关系向量 v_r 与邻居实体向量做逐元素相乘 ($*$) 来算 (即“composition 组合操作”):

$$m_{e_i, r, e_j}^l = e_i^l * v_r^l. \quad (2)$$

关系向量在层间用线性变换更新 $v^{l+1} = W_{\text{rel}}^l v^l$ 。堆叠 L 层后, 得到实体表示 e^L 和关系表示 v^L 。

【小白补丁】“消息传递”一句话直觉

GCN 的核心是“看邻居、攒信息”: 每个实体的新表示 = 它自己的旧表示 + 邻居们传来的消息之和。层数 L 越多, 能“看到”越远的邻居 (多跳结构), 从而把图的整体结构吸收进每个实体的向量里。

6.2 第 2 步：量化表示 (Quantized Representation) ——把向量压成离散码

准备一个可学习的码本 $X = [x_1, \dots, x_M]$ (每个 $x_m \in \mathbb{R}^d$ 代表第 m 号码)。任一向量 e 的量化, 就是在码本里找欧氏距离最近的那一行:

$$Q(e) = x_i, \quad \text{其中 } i = \arg \min_m \|e - x_m\|_2^2. \quad (3)$$

若每个实体只配一个码, 表达力太弱。于是先用前馈网络把实体表示 e^L 升维成 N 倍 ($\text{FFN}(e^L) \in \mathbb{R}^{N \times d}$), 这样每个实体就能对应一段**长度为 N 的码序列** $[q_1, \dots, q_N]$ 。其量化表示向量为:

$$q_e = W_q Q(e^L), \quad Q(e^L) = [x_{q_1}, x_{q_2}, \dots, x_{q_N}]. \quad (4)$$

由于“取最近邻”这一步不可导, 作者用 VQ-VAE 提出的**直通梯度估计 (straight-through estimator)** 让整个模型端到端可训, 量化损失为:

$$L_q = \|\text{sg}[e^L] - q_e\|_2^2 + \beta \|e^L - \text{sg}[q_e]\|_2^2. \quad (5)$$

【小白补丁】公式 (5) 在干嘛? $\text{sg}[\cdot]$ 与两个损失项

$\text{sg}[\cdot]$ 是“停止梯度 (stop gradient)”: 前向计算时它就是原值, 反向传播时它的梯度被截成 0。第一项 $\|\text{sg}[e^L] - q_e\|^2$ 是**码本损失**: 固定编码器输出、去拉近码, 让码靠近编码器的输出; 第二项 $\|e^L - \text{sg}[q_e]\|^2$

是**承诺损失 (commit loss)**：固定码、去拉近编码器，让编码器别乱跑、要“承诺”靠近自己选中的码。 β （取 0.25）是平衡两项的权重。直觉：让“连续向量”和“它选中的离散码”互相靠拢，从而量化误差尽量小。

6.3 第 3 步：结构重建 (Structure Reconstruction) ——让码记住图

为把整体结构信息注入码，作者要求“学到的码能反推 KG 结构”。但 KG 异质又稀疏，直接预测邻接矩阵不合适。于是改成**逐三元组判真伪**（用 ConvE 打分）：

$$s(h, r, t) = \text{Flat}(\text{Conv}(\bar{q}_h \parallel \bar{v}_r^L))^T W_c q_t. \quad (6)$$

其中 Conv、Flat 是 2D 卷积与展平， $\bar{q}, \bar{v}$ 是嵌入的变换矩阵， $\parallel$ 表示拼接。分数过 sigmoid 得 $\tilde{y} = \sigma(s(h, r, t))$ ，再与真实标签 y 算二元交叉熵：

$$L_{st} = -\frac{1}{|\mathcal{F}|} \sum_i [y_i \log \tilde{y}_i + (1 - y_i) \log(1 - \tilde{y}_i)]. \quad (7)$$

6.4 第 4 步：语义蒸馏 (Semantic Distilling) ——让码听懂文字

让码也含有实体文字描述的语义。先用一个强力文本嵌入模型 (OpenAI 的 `text-embedding-3-large`，输出 3072 维) 把实体文字编码成 $t_e = \text{LLM}(T_e)$ ，再要求量化输出去逼近它（均方误差）：

$$L_{se} = -\frac{1}{|\mathcal{E}|} \sum_i \|W_s q_{e_i} - t_{e_i}\|_2^2. \quad (8)$$

这样就把现成 LLM 的语义知识“蒸馏”进了离散码。

阶段一总损失：把量化、结构、语义三项加起来，端到端训练：

$$L = L_q + L_{st} + L_{se}. \quad (9)$$

6.5 第 5 步：用 SSQR 微调 LLM (阶段二)

每个实体现在都是一串长度 N 的码，形式同自然语言。把每个码当作一个**新 token** 加进 LLM 词表，再设计指令数据。以**链接预测**为例（原文 Table 1 的指令格式）：给出查询 $(h, r, ?)$ 的头实体码 $\text{Code}(h)$ ，再附上若干候选实体及其码（候选由传统 KG 嵌入模型如 AdaProp 生成），要 LLM 输出 Top-3 答案的码序列。微调时按“下一个 token 预测”优化：

$$L_{llm} = -\sum_{n=1}^N \log(x_n | x_{<n}, I), \quad (10)$$

其中 I 是指令。三元组分类则把指令换成“给定 (h, r, t) 的码，回答 True/False”。

【小白补丁】“候选选择 + 排序” 这一招很关键

LLM 不是从零生成答案，而是从给定候选里挑并排序。这样既缩小了搜索空间，又把难题转成了“认码、比对、排序”。论文后面指出：哪怕候选生成模型本身一般，SSQR 也常能把正确答案从候选列表中后排（如第 16、17 名）精准提到第 1 名（见案例研究 Table 8、9）。

7 七、实验与结果解读

设置：编码器用 2 层 GCN；阶段一码本 $M=2048$ 、码长 $N=32$ ；微调 LLM 时为效率把 $M=2048$ 、 $N=16$ （即每个实体仅 16 个 token）。LLM 用 LLaMA2 (7B) 与 LLaMA3.1 (8B)，4 张 H100。

7.1 结果一：SSQR 量化本身就已比已有无监督方法强（原文 Table 2）

表 2: SSQR 与无监督量化方法对比（数值源自原文 Table 2；越高越好，加粗为最优）。 $\Delta(\uparrow)$ 为 SSQR 相对最佳基线的提升；下半部为消融。

模型	WN18RR		FB15k-237	
	MRR	Hits@10	MRR	Hits@10
NodePiece	0.403	0.515	0.256	0.420
+RandomEQ	0.425	0.522	0.263	0.425
EARL	0.440	0.527	0.310	0.501
+RandomEQ	0.442	0.536	0.308	0.502
SSQR	0.483	0.578	0.361	0.545
$\Delta(\uparrow)$	9.28%	7.84%	16.45%	8.57%
w/o GCN（去结构）	0.479	0.577	0.309	0.482
w/o sem（去语义）	0.447	0.521	0.347	0.528

怎么读：SSQR 在两个数据集上全面超过 NodePiece、EARL、RandomEQ，MRR 在 WN18RR 上提升 9.28%、在结构更丰富的 FB15k-237 上更是提升 16.45%。消融很有意思：去掉 GCN（结构）对 FB15k-237 伤害最大（MRR 掉 14.40%），因为它结构丰富、靠 GCN 才抓得住；而去掉语义对稀疏的 WN18RR 伤害更大（掉 7.45%），因为它结构信息少、得靠文字语义补。结论：结构与语义两路互补，缺一不可。

【小白补丁】“各向异性 (anisotropic)” ——码为什么要更“分得开”

作者用余弦相似度可视化（原文 Figure 4）发现：只用原始文本嵌入时，实体之间相似度都是“小正数”、挤在空间一个角落；而“SSQR 去掉 GCN”后相似度几乎全是 1（彼此分不开）——这叫**各向异性**，即表示空间没被充分利用。完整的 SSQR 让相似度有了更大范围和差异，**实体之间更可区分**，这正是离散码“好用”的前提。

7.2 结果二：接入 LLM 后，链接预测刷新 SOTA（原文 Table 3）

表 3: KG 链接预测主结果（数值源自原文 Table 3；越高越好，加粗为本文方法）。

模型	WN18RR				FB15k-237			
	MRR	H@1	H@3	H@10	MRR	H@1	H@3	H@10
传统 KG 嵌入方法								
TransE	0.223	0.014	0.401	0.529	0.330	0.231	0.369	0.528
CompGCN	0.479	0.443	0.494	0.546	0.355	0.264	0.390	0.535
MA-GNN	0.565	0.507	0.592	0.679	0.379	0.282	0.415	0.569
基于 LLM 的方法								
KICGPT	0.549	0.474	0.585	0.641	0.412	0.327	0.448	0.554
KG-FIT	0.553	0.488	0.595	0.695	0.362	0.275	0.485	0.572
MKGL	0.552	0.500	0.577	0.656	0.415	0.325	0.454	0.591
SSQR-LLaMA2	0.591	0.548	0.618	0.673	0.449	0.374	0.491	0.597
SSQR-LLaMA3.1	0.598	0.559	0.618	0.675	0.459	0.393	0.491	0.597

怎么读：相比此前最强的 MA-GNN,SSQR-LLaMA2 在两数据集上分别约提升 4.60%/8.09%/4.39%/−0.88% (WN18RR) 与 18.47%/32.62%/18.31%/4.92% (FB15k-237)。**亮点集中在 Hits@1**（如 FB15k-237 上 Hits@1 从 0.282 升到 0.374, +32.62%）——这正是“候选选择 + 排序”策略的功劳：模型擅长把正确答案从候选里挑到第一。换更强的 LLaMA3.1 还能再涨，说明方法能吃到“更大模型”的红利。

7.3 结果三：三元组分类同样领先（原文 Table 4）

表 4: FB15k-237N 三元组分类结果（数值源自原文 Table 4；w/o SSQR 为去掉码、只用实体名的消融）。

模型	Acc	P	R	F1
KG-LLaMA	0.748	0.674	0.962	0.793
KoPA	0.777	0.708	0.941	0.808
SSQR-LLaMA2	0.794	0.757	0.867	0.808
w/o SSQR	0.754	0.699	0.891	0.783
SSQR-LLaMA3.1	0.798	0.759	0.872	0.811

怎么读：SSQR-LLaMA2/3.1 的准确率 0.794/0.798，明显超过最强基线 KoPA 的 0.777。更关键的是**消融对照**：去掉 SSQR 码、只用实体名字微调（w/o SSQR），分数明显下滑，且作者发现此时 LLM 会**过拟合**——训练集分数很高却无法泛化到验证/测试集。这说明**学到的离散码确实是“可区分、有代表性”的好特征**，而不是简单背名字。

7.4 结果四：消融再确认“码”的价值（原文 Table 5）

在链接预测上去掉 SSQR 码（w/o SSQR）：WN18RR 的 MRR 从 0.591 掉到 0.541（-8.46%）、Hits@1 掉 9.67%；FB15k-237 的 MRR 从 0.449 掉到 0.401（-10.69%）、Hits@1 掉 13.90%。**码一旦拿掉，LLM 就明显变差**，印证了量化表示是性能的关键来源。

【小白补丁】案例研究直观感受（原文 Table 8/9）

WN18RR 上查询“(radiotherapy, hypernym, ?)”（放疗的上位词是什么），正确答案 therapy 在候选里原本排第 17，SSQR-LLaMA2 把它的码序列准确生成在**第 1 位**；FB15k-237 上正确答案 Indiana 从第 16 被提到第 1。可见模型是真的在用码做匹配与排序，而非碰运气。

8 八、附录里值得一看的补充

- **token 省了多少**（附录 A、原文 Figure 2/9）：在 WN18RR 上 100% 采样邻居时，每个实体中位需 623 个 token、均值约 1493 个；FB15k-237 更夸张。而 SSQR **每个实体只要 16 个 token**。
- **M 与 N 的影响**（原文 Figure 5/7）：总体上 M、N 越大越好；其中 **N（码长）比 M（码本大小）更关键**，尤其在 FB15k-237 上把 N 调小掉分明显——长码序列更能区分实体。

- **区分度量化** (附录 D): 用“熵”和“Jaccard 距离”度量码的多样性与区分度, SSQR 与 RandomEQ 都远高于 NodePiece、EARL; SSQR 在 WN18RR 上更优。
- **码与真实词在 LLM 里“各占一方”** (原文 Figure 8/13): 用 t-SNE 把 2048 个码 token 和等量真实词 token 降到 2 维, 二者明显分成两簇——说明 LLM 能感知“这是不同类型的 token”, 为后续探索留了空间。
- **局限** (Limitations): 目前是“一个 KG + 一个任务”地微调 LLM, 泛化性受限、计算开销大; 作者计划构建面向多任务的统一 KG-LLM 框架。

9 九、小白知识点卡片（速查）

- **知识图谱 / 三元组**: 用“(头, 关系, 尾)”存事实的结构化图。
- **向量量化 VQ / 码本 codebook**: 用有限个离散“码”近似连续向量; 码本是可学习的“向量字典”。
- **离散码 / token**: 每个实体被压成一串整数编号, 和词一样能塞进 LLM。
- **自监督**: 不用人工标注, 从数据自身造监督信号 (这里 = 结构重建 + 语义蒸馏)。
- **蒸馏 distilling**: 让新表示去模仿一个强模型的输出 (这里让码逼近 LLM 的文本嵌入)。
- **GCN / 消息传递**: 图神经网络, 靠“聚合邻居信息”更新每个节点的向量。
- **直通梯度估计 (straight-through)**: 让“取最近邻”这种不可导操作也能反向传播训练。
- **各向异性 anisotropic**: 表示都挤在空间一角、彼此分不开, 是“坏”的表示空间。
- **链接预测 / 三元组分类**: KG 的两类经典任务——补全缺失实体 / 判真伪。
- **MRR、Hits@k**: 排名类指标, 正确答案越靠前分越高。

10 十、一句话总结与定位

一句话: SSQR 用自监督 (结构重建 + 语义蒸馏) 把每个 KG 实体压成一小串离散码, 这些码与自然语言同形、可直接当 token 喂进 LLM; 于是只需扩词表 + 指令微调, 就能**无缝**地把图的结构与语义注入大模型, 在链接预测、三元组分类上又准、又省 token (每个实体仅 16 个)。

在“KG × LLM”谱系里的位置: 它走的是“**离散量化对齐**”路线——把图量化成 *token* 去匹配 LLM 的离散词表, 这是它“无缝”的核心, 区别于 (1) **直接提示 / 检索**把子图摊成文字 (token 爆炸)、(2) **连续适配器** (如 KoPA) 把 KG 连续嵌入对齐进 LLM (需额外网络与空间对齐)。思想上它

借鉴了多模态的早融合与 VQ-VAE/VQ-GAN 的向量量化，是把“离散表示学习”引入 KG-LLM 融合的代表性尝试。

适合谁读：想理解“如何把非文本结构（图）变成 LLM 能直接消化的 token”的同学；本文是入门“量化表示 + 知识图谱 + 大模型指令微调”的一篇很清晰的范例。