

UniGraph 中文精读导读：用“文本”当通用语，造一个跨领域的图基础模型

原文：Yufei He, Yuan Sui, Xiaoxin He, Bryan Hooi（新加坡国立大学，KDD 2025）

本导读为面向初学者的中文学习笔记：含要点翻译、公式精讲与图表解读。

论文卡片

标题	UniGraph: Learning a Unified Cross-Domain Foundation Model for Text-Attributed Graphs
作者	Yufei He, Yuan Sui, Xiaoxin He, Bryan Hooi
机构	新加坡国立大学 (National University of Singapore)
会议	KDD 2025 (ACM SIGKDD 知识发现与数据挖掘大会)
arXiv	2402.13630
代码	https://github.com/yf-he/UniGraph
方向	图 (Graph) × 基础模型 × 自监督预训练 × 跨领域迁移
一句话	把各种图统一看成“带文字的图”，用文本当通用语、用掩码自监督预训练一个能零样本/少样本迁移到没见过的图与任务的基础模型。

1 一、这篇论文在解决什么问题

最近几年，**基础模型 (foundation model)** 彻底改变了 AI：像 ChatGPT、GPT-4 这样的大模型，预训练一次，就能在大量它原本没专门学过的任务上通用。但作者指出，**图学习 (graph learning)** 这个领域却一直停留在“老办法”上——**一次只为一张图训练一个模型**（作者称之为 单图模型，*single-graph model*）。这种模型通常只能做一两个任务，换一张图、换一个任务就得从头再来，而且每个任务都要大量人工标注，数据稀缺时很吃亏。

于是一个自然的问题是：**能不能像 NLP、CV 那样，造一个“图的基础模型”**——预训练一次，就能零样本/少样本地用到从没见过的图 and 任务上？作者认为这件事很难，难点集中在“图领域千差万别、如何学到跨领域不变的东西”，具体有两点：

1. **特征空间与标签空间不统一**。NLP 里不同领域的文本再不一样，也能用同一套词典编码，因此表示天然可迁移；但不同领域的图，节点和边的类型与含义完全不同（论文的引用网络 vs. 知识图

谱的实体关系)，特征互不兼容，输入都没法统一。更麻烦的是，GNN 用一个固定的 softmax 分类器输出，换个标签空间就没法零样本预测。

2. **图结构差异巨大**。引用网络是有向、近似无环的；知识图谱却充满环、团 (clique) 这类复杂模式；分子图又是另一回事。让模型把“在一种图上学到的结构知识”迁移到另一种图上，非常困难。

本文的目标：提出 **UniGraph** 框架，设计并训练一个真正跨领域的图基础模型，能泛化到不同领域、没见过的图上的各种任务。

【小白补丁】什么叫“跨领域图基础模型”？为什么它这么难

“基础模型”= 预训练一个大模型当通用底座，下游各种任务直接拿来用。语言模型能这样，是因为有“**不变量**”：所有英文都共用一套词典。图却没有这种天然的通用语——社交网络的“节点”和分子的“原子”根本不是一回事。UniGraph 的核心赌注就是：用“**文本**”给所有图当通用语，从而把这个“没有共同词典”的难题转化成“大家都说同一种语言（自然语言）”的问题。

2 二、摘要中译

像 ChatGPT、GPT-4 这样的基础模型已经革新了人工智能，展现出超越其初始训练目标、在大量任务与应用上泛化的惊人能力。然而图学习长期以单图模型为主，针对特定任务或数据集量身定制，缺乏把已学知识迁移到不同领域的能力。这一局限源于图结构固有的复杂性与多样性，以及图数据各自不同的特征空间与标签空间。本文中，我们认识到**文本是一种有效的统一媒介**，并借助**文本属性图 (Text-Attributed Graphs, TAGs)** 来发挥这一潜力。我们提出 UniGraph 框架，旨在为 TAG 学习一个基础模型，使其能够泛化到不同领域中未见过的图与任务。不同于以维度各异的预计算节点特征为输入的单图模型，我们的方法用**文本特征来统一节点表示**，即便是分子图这类本身没有天然文本特征的图也能处理。我们提出一种**语言模型 (LM) 与图神经网络 (GNN) 级联的新颖架构**作为主干网络；此外，我们提出首个专为 TAG 上大规模自监督学习设计的预训练算法，它基于**掩码图建模 (Masked Graph Modeling)**。我们还引入借助**大语言模型 (LLM) 的图指令微调 (graph instruction tuning)**，以赋予模型零样本预测能力。覆盖多种图学习任务与领域的全面实验表明，本模型在未见图上的自监督表示学习、少样本上下文迁移、以及零样本迁移上都很有效，甚至**超过或追平了在目标数据集上做过监督训练的 GNN**。

3 三、三大核心贡献

1. **指出难点 + 给出统一思路**：识别出跨领域图基础模型的核心挑战，提出用 **TAG (文本属性图)** 统一不同领域的图，并给出 UniGraph 模型——含一个新颖的“**LM + GNN 级联**”主干，以及

首个面向 TAG 大规模自监督学习的预训练算法。

2. 用图指令微调解锁零样本：借助 LLM 强大的泛化能力，把不同图的标签空间 **统一成自然语言**，从而在图学习任务上做零样本预测。
3. 大规模、跨领域的充分验证：在 **5 个领域、11 个数据集**上做了节点/边/图三种层级的任务，最大的图有 **1.11 亿个节点**。在跨领域设定下，UniGraph 不仅胜过其他跨领域方法，**还胜过在目标数据集上专门做监督训练的模型**。

4 四、预备知识（小白先看这里）

【小白补丁】什么是文本属性图（TAG, Text-Attributed Graph）

就是**节点（有时还有边）上带着一段文字**的图。比如引用网络：每个节点是一篇论文，文字就是它的标题 + 摘要；知识图谱：节点是实体，文字是实体名 + 描述。论文的巧思在于：**连本来没有文字的图也强行“配上文字”**——例如分子图，把每个原子描述成“某元素、手性如何、几个氢、是否在环上……”这样一句话，于是分子图也变成了 TAG。这样一来，所有图都能用同一个语言模型来编码，特征空间就统一了。

【小白补丁】什么是自监督学习与掩码预测（masked modeling）

自监督（self-supervised）指不用人工标签，而是从数据自己造监督信号来训练。最经典的玩法就是**掩码预测**：像 BERT 那样把句子里一些词盖住（换成 [MASK]），让模型根据上下文把被盖的词猜回来。猜对猜错本身就是监督信号，不需要人去标注。UniGraph 把这招搬到图上：盖住某个节点的部分文字，让模型借助“邻居节点的文字”把它补全——这就逼着模型既理解文本、又利用图结构。

【小白补丁】什么是锚节点（Anchor Node）及其上下文子图

这是 UniGraph 统一“节点/边/图三种任务”的关键概念。**锚节点** = 你这次要做预测的对象所在的那个（些）节点。**上下文子图** = 围绕锚节点取出的一小块局部子图（它的“邻里环境”）。做节点任务时锚节点就是那一个点；做边任务时锚节点是这条边的两个端点；做图任务时整张图的所有点都是锚节点。这样一个**统一函数**就能适配三种任务，不必为每种任务单独设计模型（详见第六节）。

形式化记号（看不懂可跳过，用到时再回看）：文本属性图记作 $G = (V, E, T_V, T_E)$ ，其中 V, E 是节点集与边集， T_V, T_E 分别是节点文字、边文字的集合（很多图只有 T_V ）。预训练好的模型记作 f_θ ，

它吃一张图、为每个节点吐一个向量：

$$f_{\theta}: G \rightarrow \mathbb{R}^{|V| \times d}, \quad (\text{记号})$$

d 是向量维度。论文用三种问题设定来检验它的跨领域泛化：

- **自监督表示学习**：冻结 f_{θ} ，只在它产出的向量上训练一个线性分类器（叫 线性探测, *linear probing*），看表示好不好用。
- **少样本迁移 (Few-shot)**： N 类、每类只给 K 个带标签样本 (N -way K -shot)，不更新模型参数，靠比对查询样本与支持样本的向量相似度来分类，考的是“上下文学习”能力。
- **零样本迁移 (Zero-shot)**：把 K 设为 0，完全没见过目标类别的任何样本，靠图指令微调过的 LLM 直接用自然语言预测。

5 五、数据集与任务

作者在 5 个领域、11 个数据集上做实验，覆盖节点/边/图三种任务层级（见表 1）。最关键的一点：所有自监督方法都只在一张超大引用网络 ogbn-Papers100M (1.11 亿节点) 上预训练一次，然后直接拿去测从没见过另外那些图——这才叫“跨领域”。

表 1: 11 个文本属性图数据集统计（数据源自原文 Table 1）。

数据集	领域	任务	图数	平均节点数	平均边数
Cora	引用网络	节点	1	2,708	5,429
PubMed	引用网络	节点	1	19,717	44,338
ogbn-Arxiv	引用网络	节点	1	169,343	1,166,243
ogbn-Papers100M	引用网络	节点	1	111,059,956	1,615,685,872
ogbn-Products	商品网络	节点	1	2,449,029	61,859,140
Wiki-CS	网页链接	节点	1	11,701	216,123
FB15K237	知识图谱	边	1	14,541	310,116
WN18RR	知识图谱	边	1	40,943	93,003
PCBA	分子	图	437,929	26.0	28.1
HIV	分子	图	41,127	25.5	27.5
ChEMBL	分子	图	365,065	25.9	55.9

【小白补丁】为什么这套数据集能体现“跨领域”含金量

预训练只用引用网络这一种图；测试却要去做商品分类、知识图谱关系预测、分子性质预测——这些图的节点含义（论文 vs. 商品 vs. 实体 vs. 原子）、任务层级（节点 vs. 边 vs. 图）全都不同。模型从没在这些领域训练过，却要直接给出好结果，难度远大于“同领域迁移”。

6 六、UniGraph 方法逐节精讲

UniGraph 由三块拼成 (见图 1): **自监督预训练** (图左, 用掩码图建模学一个 LM+GNN 编码器); **少样本上下文学习** (图右上, 靠向量相似度比对, 不训练); **图指令微调** (图右下, 把图向量喂给 LLM, 用自然语言做零样本预测)。下面分别讲。




Figure 1: Overview of UniGraph framework. 1) In pre-training, we employ a self-supervised approach, leveraging TAGs to unify diverse graph data. This phase involves a cascaded architecture combining LMs and GNNs. We propose Graph Siamese

图 1: UniGraph 总体框架 (原文 Figure 1, 图内英文为原文保留)。左 (**Self-supervised Pre-training**): 随机掩盖节点文字, 经“LM 编码器 + GNN 编码器”级联后, 用解码器去重建被掩盖的文字 (Masked Language Modeling Loss), 同时用一个不参与梯度的 目标网络 (*Target Encoder*) 做隐空间正则 (Latent Loss)。右上 (**Few-shot In-context Learning**): 用预训练好的 LM+GNN 编码器把“支持图”和“查询图”都编码成向量, 靠相似度 $h_i \cdot s_j$ 给查询样本分类。右下 (**Graph Instruction Tuning**): 经投影器 (Projector) 把图向量送入冻结的 LLM (Llama), 配上自然语言指令、用 LoRA 微调, 让模型用自然语言说出类别标签, 实现零样本。图例: *Updated by gradient*= 梯度更新, *Frozen*= 冻结, *Updated by EMA*= 指数滑动平均更新。

6.1 6.1 用“锚节点 + 上下文子图”统一所有任务

作者要找一个**通用函数**, 能适配节点/边/图三种任务。做法是把“要预测的对象”统一表述成**锚节点 (Anchor Node) 集合 A** 和它们的上下文子图集合 X , 再套一个统一公式:

$$h = g(X, A) = R(f_{\theta}(X), A). \quad (1)$$

意思是：先用预训练模型 f_θ 把上下文子图 X 编码，再用一个**任务专属的读出函数** R (readout) 把锚节点对应的部分抽出来、聚合成最终向量 h 。三种任务只是 A 和 R 不同：

- **节点级**：锚节点就是要预测的那个点 v ， $A = \{v\}$ ， $X = \{G_v\}$ ； R_{node} 直接取出它的向量。
- **边级**：锚节点是这条边的两个端点 v, u ， $A = \{v, u\}$ ； R_{edge} 取出两点向量**拼接**起来。
- **图级**：图通常较小，整张图所有点都是锚节点， $A = V$ ； R_{graph} 用**池化**（如平均池化）汇总。

【小白补丁】怎么取“上下文子图”？——个性化 PageRank (PPR)

对锚节点 v ，作者用 **top- k 个性化 PageRank (Personalized PageRank, PPR)** 采样它的上下文子图：PPR 会给图上每个点算一个“相对于 v 的相关度分数”，然后取分数最高的 k 个点（连同它们之间的边）组成子图 G_v 。相比简单的“ k 跳邻居”，PPR 能挑出在**更大范围里真正重要的节点和结构**，更通用、更可迁移；而且“只取一小块子图”让模型能**扩展到网页级的超大图**。

6.2 预训练核心：图孪生掩码自编码器 (Graph Siamese Masked Autoencoders)

这是论文首创的、专为 TAG 设计的自监督预训练算法。主干是“**LM + GNN 级联**”：论文用 DeBERTa-base 当 LM、GAT 当 GNN。训练分四步：

(a) **掩码 (Masking)**：给每个节点的文字前后加上 [CLS] 和 [SEP] 标记，把 token 序列里**随机一部分换成 [MASK]**（掩码率 p ，论文取 0.75）。形式化为：

$$m_v = \text{Mask}(t_v) = [[\text{CLS}], M_1, M_2, \dots, M_{n_v}, [\text{SEP}]], \quad M_i = \begin{cases} [\text{MASK}], & \text{以概率 } p \\ T_i, & \text{否则.} \end{cases} \quad (2)$$

(b) **编码器 (Encoder)**：先用 LM f_{LM} 处理被掩码的序列 m_v ，取出每个节点的 [CLS] 向量；再把**所有节点的 [CLS] 向量 $\tilde{E}_{\text{cls}}$ 喂给 GNN f_{GNN}** ，在图上传播，得到融合了邻居信息的 $\tilde{E}'_{\text{cls}} = f_{\text{GNN}}(G, \tilde{E}_{\text{cls}})$ 。这一步就是“**LM 管文本、GNN 管结构**”的级联精髓。

(c) **解码 + 掩码语言建模 (MLM) 损失**：把“GNN 传播后的节点向量”和“该节点被掩码的文字表示”拼接、线性变换后，过一个 MLMHead 映射到词表，预测**被掩盖位置的原始 token**。损失是对所有被掩位置的交叉熵：

$$\mathcal{L}_{\text{mask}} = -\frac{1}{\sum_v \sum_i \mathbb{I}(v, i)} \sum_{v \in V} \sum_{i=1}^{n_v} \mathbb{I}(v, i) \cdot \log P_v[i, T_i]. \quad (4)$$

其中 $\mathbb{I}(v, i) = 1$ 表示节点 v 的第 i 个 token 被掩码了， $P_v[i, T_i]$ 是模型给正确 token T_i 打的概率。**直觉**：模型被迫用邻居节点的文字去补全当前节点被盖住的文字——这就同时学会了“看懂文本”和“利用图结构”。

(d) **隐空间正则 (Latent Loss)**: 为了让训练更稳、表示质量更高, 作者再加一个**目标网络 (target network)**。它和编码器结构相同, 但**参数不靠梯度更新**, 而是用指数滑动平均 (EMA) 缓慢跟随编码器: $\delta' \leftarrow \delta, \xi' \leftarrow \tau \xi' + (1 - \tau) \xi$ 。目标网络处理未掩码的原文, 编码器的输出要去**对齐**目标网络的输出 (用余弦相似度):

$$\mathcal{L}_{\text{latent}} = \frac{1}{|V|} \sum_i \left(1 - \frac{\bar{z}_i^\top e'_{\text{cls},i}}{\|\bar{z}_i\| \cdot \|e'_{\text{cls},i}\|} \right). \quad (5)$$

【小白补丁】为什么要搞一个“不学习”的目标网络？

这是自监督里防“崩塌” (collapse) 的常用技巧 (来自 BYOL、DINO 等)。如果编码器只优化掩码重建, 表示可能学得不稳。引入一个用 EMA 缓慢更新的“影子网络”当作**稳定的对齐目标**, 让编码器去追它, 能让隐空间表示更平滑、更稳健。 $\xi' \leftarrow \tau \xi' + (1 - \tau) \xi$ 就是“影子”每步只挪一点点 (τ 接近 1, 论文取 0.996)。

总损失: 两项用系数 λ 混合 (论文 $\lambda = 0.1$):

$$\mathcal{L} = \mathcal{L}_{\text{mask}} + \lambda \cdot \mathcal{L}_{\text{latent}}. \quad (6)$$

推理时: 扔掉解码器和目标网络, **只留编码器 (LM+GNN)** 来给节点产出向量。

6.3 6.3 少样本: 靠相似度做“上下文学习”

预训练完, 每个节点/边/图都能得到一个 (向量 h , 标签 y) 对。在 N -way K -shot 任务里, 对每个类别 c 算它 K 个支持样本的**平均向量** e_c , 再把查询样本 h_q 按**余弦相似度**归到最近的类。准确率写作:

$$\mathcal{M} = \frac{1}{|Q|} \sum_{h_q \in Q} \mathbb{I} \left[\arg \max_{c \in \{1, \dots, N\}} \frac{h_q \cdot e_c}{\|h_q\| \|e_c\|} = y_q \right]. \quad (7)$$

关键: 这一步完全不更新模型参数, 纯靠预训练向量的质量——所以它直接检验“表示好不好用”。

6.4 6.4 零样本: 图指令微调 (Graph Instruction Tuning)

不同领域标签空间不同 (论文类别 vs. 商品类别 vs. 关系类型), 想零样本就得有个**能用自然语言说出任意标签的出口**。作者的做法: 把预训练得到的图向量经一个**投影器 (Projector)** 映射进 LLM 的词嵌入空间, 再和**自然语言指令**拼在一起喂给 LLM (论文用 Llama-7B), 用 **LoRA 微调 LLM**、词嵌入保持冻结, 训练它直接生成**自然语言形式的类别标签** (损失只算在预测目标上)。

【小白补丁】为什么图指令微调能“零样本”？

LLM 本身就懂海量自然语言。把“图的结构信息 (向量)”对齐进 LLM 后, 分类任务就变成了“读懂指令、用自然语言回答属于哪一类”。由于答案是开放式自然语言而非固定 softmax 输出, **遇到训练时**

没见过的新类别/新图，也能直接用语言描述出来——这就是零样本能力的来源。论文特意让指令微调用的类别（Arxiv、FB15K237）与下游测试的类别完全不重叠，以确保是真零样本。

7 七、实验怎么做、结果怎么读

核心实验设置：LM 用 DeBERTa-base，GNN 用 GAT，LLM 用 Llama-7B；所有自监督方法**统一**在 **ogbn-Papers100M**（1.11 亿节点）上预训练一次，再去测其它从没见过的图。下面挑三组关键结果。

7.1 7.1 自监督表示学习（跨领域，线性探测）

怎么读：白底行 = 自监督方法（在 Papers100M 预训练后迁移），灰底的 GCN/GAT= 在目标数据集上专门监督训练的“天花板”对照。表 2 节选关键行。

表 2：自监督表示学习结果（数值源自原文 Table 2；节点/边任务报准确率%，图任务报 ROC-AUC%；越高越好，加粗为最优）。

	方法	Cora	PubMed	Arxiv	Products	WN18RR	HIV	PCBA
自监督 (DeBERTa 特征)	GraphMAE2	42.87	53.98	59.39	67.91	51.78	61.42	52.35
	GAT(监督)	47.99	61.01	63.11	67.02	73.98	67.12	56.45
以原文 为输入	GIANT-XRT+GraphMAE2	80.11	69.43	72.01	75.23	57.32	67.23	52.01
	UniGraph	81.43	74.33	72.91	80.11	85.45	71.23	57.67

三点结论（原文）：(1) UniGraph **大幅领先**所有自监督基线，说明它在跨领域场景下泛化更强；(2) **直接从 TAG 文本学**（UniGraph、GIANT-XRT）比“先用 LM 把文本预编码成向量再喂 GNN”更有利于跨领域；(3) 最惊人的是——作为一个迁移过来的模型，UniGraph 在多数数据集上**追平甚至超过了在该数据集上专门监督训练的 GCN/GAT**（如 WN18RR 上 85.45 vs. GAT 的 73.98）。这直接证明了“训练一个图基础模型”是可行的。

7.2 7.2 少样本迁移（不更新参数）

在 Arxiv、FB15K237 上做 N -way K -shot（表 3 节选）。对照里 OFA、Prodigy 是在同任务上专门预训练的强基线，UniGraph **却不在下游训练、纯靠相似度**就赢了它们。

表 3: 少样本迁移结果（数值源自原文 Table 3，报准确率%；越高越好，加粗为最优）。

方法	Arxiv		FB15K237		
	40-way	5-way	40-way	10-way	5-way
Prodigy	25.13	61.52	59.58	81.10	88.02
OFA	22.13	60.12	65.23	83.01	90.11
GIANT-XRT+GraphMAE2	27.35	66.91	47.73	74.33	80.17
UniGraph	31.35	74.12	68.76	85.32	91.12

怎么读: 在 Arxiv 5-way 上, UniGraph 74.12 比 OFA 60.12 高出约 14 个点; FB15K237 10-way 上 85.32 也超过 OFA 的 83.01。**关键意义:** 这些基线都在下游数据上微调过, UniGraph 一个参数不动还能赢, 说明它从预训练里学到的是**可在上下文里直接复用的通用知识**。

7.3 7.3 零样本迁移（图指令微调）

把 UniGraph 的图向量接上指令微调的 LLM（记作 **UniGraph-IT**），与通用 LLM、图-LLM 方法比（表 4 节选）。

表 4: 零样本迁移结果（数值源自原文 Table 4，报准确率%；越高越好，加粗为最优）。

	Cora(7)	PubMed(2)	Products(47)	Wiki-CS(10)	WN18RR(11)
vicuna-7B-v1.5	45.23	72.21	20.24	29.46	23.24
G2P2	54.29	82.41	30.82	30.11	26.24
ZeroG	64.21	87.83	31.24	31.26	31.42
UniGraph-IT	69.53	89.74	38.45	43.45	36.73

怎么读: UniGraph-IT 在所有数据集上都明显胜过通用 LLM 和图-LLM 基线。比如 Products 47 类零样本上 38.45 vs. ZeroG 的 31.24。这说明：把高质量图向量对齐进 LLM 后，**LLM 确实能从图指令微调里学到“可迁移的图结构与图任务知识”**，从而对完全没见过类别的图做预测。

7.4 7.4 其它值得一看的分析

- **vs. 同数据集专用自监督**（原文 Table 5）：即便只比表示学习，跨领域的 UniGraph 也超过了在各数据集上单独训练的 DGI/BGRL/GraphMAE2；而同数据集版 UniGraph-single 更高一截，说明算法本身强、且跨领域仍有提升空间。
- **消融实验**（原文 Table 7）：去掉 GNN 掉分最狠（如 HIV 71.23→56.11），其次是去掉 MLM 损失；去掉隐空间损失、去掉 PPR 采样也都有掉分。**结论：LM+GNN 级联、掩码重建、隐空间正则、PPR 采样四件套缺一不可。**

- **预训练数据消融** (原文 Table 8): 在预训练里加入同领域的图能提升对应下游性能 (如加分子图后 HIV 从 71.23 升到 77.84), 印证 “同领域迁移更容易”。
- **效率** (原文 Table 6 与 Table 10): UniGraph 预训练虽久 (Papers100M 上约 23.4 小时), 但开销与 “只训练一个 LM 做 MLM” 相当 (参数、显存、速度都接近 DeBERTa-base); 而它作为基础模型, 下游只需推理、无需重训, 数据集越多越省。

8 八、小白知识点卡片 (速查)

- **文本属性图 / TAG**: 节点 (有时含边) 带文字的图。UniGraph 把分子图等也 “配文字” 变成 TAG。
- **基础模型 (foundation model)**: 预训练一次、能通用到大量下游任务的大模型。
- **跨领域 (cross-domain)**: 在一种图上预训练, 迁移到另一种领域的图与任务。
- **自监督学习**: 不用人工标签, 从数据自身造监督信号训练。
- **掩码图建模 (MGM)**: 盖住节点文字、用邻居文字补全, 是 UniGraph 的预训练任务。
- **锚节点 + 上下文子图**: 统一节点/边/图三种任务的通用表述。
- **PPR (个性化 PageRank)**: 按 “相对某点的相关度” 采样局部子图, 比 k 跳邻居更通用、可扩展。
- **LM+GNN 级联**: LM 管文本语义、GNN 管图结构传播的主干架构。
- **目标网络 / EMA**: 用指数滑动平均缓慢更新的 “影子网络”, 防自监督表示崩塌。
- **图指令微调**: 把图向量喂给 LLM、用自然语言输出标签, 从而零样本预测。
- **线性探测 (linear probing)**: 冻结模型、只训一个线性分类器, 用来评测表示质量。
- **N -way K -shot**: N 个类、每类 K 个样本; $K = 0$ 即零样本。
- **LoRA**: 参数高效微调, 只训练低秩增量矩阵, 省显存。

9 九、一句话总结与谱系定位

一句话: UniGraph 把 “所有图都看成带文字的图 (TAG)”, 用文本当跨领域通用语; 靠 “LM+GNN 级联 + 掩码图建模 + 目标网络正则” 做大规模自监督预训练得到一个图基础模型, 再用 “锚节点 + 上下文子图” 统一节点/边/图三种任务、用 “图指令微调 LLM” 解锁零样本——从而一次预训练、零样本/少样本迁移到没见过的图与任务, 甚至打赢专门训练的监督模型。

在“图 × 大模型”谱系里的位置：它属于“用文本统一 + 自监督预训练”这条造图基础模型的路线。与之相对：**OFA** 是监督框架、需要下游标签且要多图共训；**GCC/ULTRA** 忽略节点特征、只迁移结构；**LLaGA/GraphGPT** 是纯 *LLM* 路线（把图映射进 *LLM* 嵌入空间做指令微调）。UniGraph 的差异化在于端到端、自监督、且预训练后能直接泛化到任意未见 **TAG**，并且它输出的高质量图向量还能反过来增强 *LLaGA/GraphGPT* 这类方法。

动手复现：官方代码 <https://github.com/yf-he/UniGraph>（含 DeBERTa+GAT 级联、掩码图建模预训练、PPR 采样、以及 Llama 图指令微调流程），是入门“图基础模型”很好的练手项目。