

API 指引

速率限制

 Copy page

为保障平台服务稳定性、模型资源的公平使用，以及整体服务质量，智谱 BigModel 开放平台对 API 调用实施 **速率限制（Rate Limits）机制**。下面对速率限制的触发场景、常见错误码及应对方式进行详细说明。

 **通用 API 用户：** 可通过 [速率限制](#) 查看您的账户目前各模型可调用的速率；

GLM Coding Plan 用户： 速率（并发数）限制与您的套餐等级相关，平台会根据资源进行动态调整，低峰期享有更高速率，基本原则 Max > Pro > Lite。

一、什么是速率限制？

速率限制 是指平台在一定时间窗口内，对单个账户或调用方的 API 并发请求数等进行限制。

在智谱 AI 开放平台中，速率限制主要体现在：

- 并发请求数限制
- 不同模型设有独立的并发限制
- 不同用户权益等级、不同套餐对应不同的 并发限制
- 高峰期的动态限流与平台级保护策略

二、为什么需要速率限制？

速率限制是业界大模型 API 的通用做法，其核心目的包括：

 **1. 保障平台整体稳定性：** 防止瞬时高并发请求对模型服务造成冲击；通过设置速率限制，可以最大程度帮助用户保持稳定的体验。

2. 确保用户间的公平使用： 避免个别账户在高并发场景下占用过多资源，影响其他用户的正常调用。

3. 防范异常流量或误用行为： 包括程序异常、无限重试、非预期高频调用等情况。

三、智谱开放平台速率限制机制说明

1. 按用户权益等级 & 模型维度划分的并发限制

如果您是 API 用户，智谱 AI 开放平台对**不同模型**设置了不同的并发数上限。（可通过 [速率限制](#) 查看您的账户目前各模型可调用的速率）：

- 通用模型
- 图像 / 视频生成模型
- 向量模型
- 实时音视频模型
-

同时，速率限制量级和您的用户权益等级相关，（可通过 [用户权益](#) 查看自己的积分与用户权益等级。）

 并发数指的是：同一时刻正在处理中的请求数量。

2. 按 GLM Coding Plan 套餐等级划分的并发限制

如果您是 GLM Coding Plan 套餐用户，速率限制与您订阅的 **套餐 等级** 相关。不同套餐用户，默认可用的模型并发上限不同，每个项目开发可使用 Subagent 等方式并发模型调用，我们的推荐使用项目数量如下（[查看我的套餐等级](#)）：

- Max：建议同时进行 2+ 个项目的开发

① 套餐用户在低峰期将享有更高的并发权益（动态提升），能够支撑更高数量的项目开发。

3. 高峰期的限流策略

在业务高峰期（如工作日白天、活动期间、每天下午15:00-18:00）：

- 若某一账户在短时间内发起**大量并发请求**
- 超出该账户在对应模型上的并发上限

平台将基于 **账户维度** 对请求进行限流处理，而非模型永久不可用。

4. 平台级服务过载说明

除账户自身速率限制外，平台在以下情况下可能触发 **平台级保护机制**：

- 某一模型在短时间内整体访问量激增
- 底层算力资源处于高负载状态
- 平台进行系统维护、扩容或异常恢复

此类情况属于 **平台服务过载**，与单一账户的调用行为无直接关系。

四、相关错误码

1. 错误码 1302：触发用户速率限制

⚠️ 您的账户已达到速率限制，请您控制请求频率

典型原因

- 当前模型的并发请求数已达到账户上限
- 短时间内请求过于密集

建议处理方式

- 降低并发请求数量
- 增加请求队列或排队机制
- 在必要时提升账户权益等级，提升并发额度（[如何提升用户权益等级](#)）（此条不适用 GLM Coding Plan）

2. 错误码 1305：平台服务过载

错误含义

⚠️ 该模型当前访问量过大，请您稍后再试

典型原因

- 模型在当前时段整体访问压力较高
- 平台触发了全局保护或临时限流

建议处理方式

- 稍后重试请求
- 增加重试间隔，避免立即高频重试
- 在业务允许的情况下进行降级或延迟处理

我们建议开发者在系统设计中提前考虑以下策略：

>

1. 控制并发与请求频率

- 使用请求队列或并发池
- 避免瞬时“洪峰式”请求
- 避免固定间隔的高频重试

2. 异步请求或批处理 API

- 非实时场景可通过批处理方式或异步请求降低并发压力（[Batch API](#)、[异步请求](#)）

六、如何申请提升速率限制？

💡 GLM Coding Plan 用户按订阅套餐等级统一并发，暂不支持申请调整。

若您使用的是**通用 API**，且业务确实需要更高并发能力，可通过控制台提交申请：

1. 进入【[速率限制调整申请](#)】

2. 填写以下信息：

- 需要调整的模型
- 期望增加的并发数量
- 实际使用场景与业务说明

平台将在 **10 个工作日内完成审核**，审核结果将通过注册手机号或站内通知告知。

