

创意实践

AI早报生成

 Copy page

场景介绍

Credit to: 数字生命卡兹克 点击访问原文: [20个群都来问我的AI早报，是这么做的。](#)

技术概述

使用开源框架 Crawl4ai 快速爬取新闻网站 24 小时之内的文章内容，使用 GLM 进行总结归纳生成【AI 早报】，高效获取处理新闻信息。

GitHub 开源项目 Crawl4ai: <https://github.com/unclecode/crawl4ai> Crawl4AI 简化了异步网络爬取和数据提取，使其对大型语言模型（LLMs）和人工智能应用变得可访问

方案

获取新闻信息

以抓取 AI Base 新闻页面为例 <https://www.aibase.com/zh/news/>

首先需要获取 AI Base 新闻页面中的文章 URL，可以通过库 `BeautifulSoup` 快速实现。

1. 获取文章链接

AI Base 的文章较为特殊，文章的编号是连续的，获取第一条文章的编号即可递推获得其它文章的编号。



```
import requests
from bs4 import BeautifulSoup
import re
>

# 获取首条文章的链接
def extract_snumber_from_url(base_url):
    try:
        response = requests.get(base_url)
        response.encoding = 'utf-8'

        soup = BeautifulSoup(response.text, 'html.parser')
        links = soup.find_all('a')

        for link in links:
            href = link.get('href')
            if href:
                pattern = r'/zh/news/(\d+)'
                match = re.search(pattern, href)
                if match:
                    snumber = int(match.group(1))
                    return snumber
    except Exception as e:
        print(f"error: {e}")
    return None
```

2. 获取文章内容

根据 crawl4ai 项目的案例进行适当的改造即可读取，主要爬取文章标题、发布时间和正文三个内容。

```
from crawl4ai import AsyncWebCrawler
from crawl4ai.extraction_strategy import JsonCssExtractionStrategy

# news_url = base_url + snumber
async def extract_news_article(news_url):
    schema = {
        "name": "AIbase News Article",
        "baseSelector": "div.pb-32",
        "fields": [
            {
                "name": "title",
                "selector": "h1",
                "type": "text",
            },
            {
                "name": "publication_date",
                "selector": "div.flex.flex-col > div.flex.flex-wrap > span:nth-child(1)",
                "type": "text",
            },
            {
                "name": "content",
                "selector": "div.post-content",
                "type": "text",
            },
        ],
    }

    extraction_strategy = JsonCssExtractionStrategy(schema, verbose=True)

    async with AsyncWebCrawler(verbose=True) as crawler:
        result = await crawler.arun(
            url=news_url,
            extraction_strategy=extraction_strategy,
            bypass_cache=True,
        )

    if not result.success:
        print("error")
```

```
        extracted_data = json.loads(result.extracted_content)

    >
    return extracted_data
```

文章内容信息获取如下：

```
[
  {
    "title": "新加坡推出 AI 系统安全指南，选举中禁用深度伪造技术",
    "publication_date": "2024年10月18号 11:54",
    "content": "新加坡最近在网络安全方面发布了一系列重要公告，特别是针对人工智能（AI）系统的安  
调了“设计即安全”的理念，旨在帮助企业识别和应对各种网络安全威胁。指南分为五个阶段，涵盖了 AI 生  
  }
]
```

使用该方法，根据文章链接依次获取 24 小时内发布的所有文章内容即可。

使用 智谱 API 生成 AI 早报

获得文章完整内容后使用 GLM 总结即可生成一条新闻的早报。

1. GLM 总结文章内容

GLM-4.7 总结的会更好一点，这里就用免费的 flash 作为案例。



```
def get_news_summary(data):
    API_KEY = "your api key"
    BASE_URL = "https://open.bigmodel.cn/api/paas/v4"

    client = ZhipuAI(api_key=API_KEY, base_url=BASE_URL)

    system_prompt = """
    ## Goals
    读取并解析 JSON 格式的文章，提炼出文章的主旨，形成一句简洁的概述。

    ## Constrains:
    概述长度不超过 80 字，保持文章的原意和重点。

    ## Skills
    JSON 解析能力，文章内容理解和总结能力。

    ## Output Format
    一句话概述，简洁明了，不超过 80 字。

    ## Workflow:
    1. 读取并解析 JSON 格式的文章
    2. 理解文章内容，提取关键信息
    3. 生成一句简洁的概述，不超过 80 字
    """

    try:
        response = client.chat.completions.create(
            model="glm-4-flash",
            messages=[
                {"role": "system", "content": system_prompt},
                {"role": "user", "content": f"文章内容: {data}"}
            ],
            top_p=0.7,
            temperature=0.1,
            stream=False
        )
        return response.choices[0].message.content
    except Exception as e:
```

2. 生成 AI 早报

现在批量获取文章内容并提交给 GLM 进行处理，就可以获得专属的 AI 早报啦！

【AI 早报】 2024 年 10 月 18 日

1. Meta研究人员利用Transformer模型和“逆向生成”方法，成功发现动力系统的全局李雅普诺夫函数，突破
2. 自动驾驶公司小马智行递交IPO申请，计划纳斯达克上市，估值85亿美元，Robotaxi业务增长强劲。
3. Perplexity推出“内部知识搜索”，整合内外部数据，提升企业搜索效率，并新增团队共享与AI助手定制功
4. 哈佛医学院推出CHIEF AI，精准诊断多种癌症，预测患者结果，推荐治疗方案，有望革命性改变癌症诊断。
5. X更新隐私政策，默认允许第三方使用用户数据训练AI，引发隐私保护担忧。
6. 中国科研团队提出的新图像处理技术SGOOL，模拟人类视觉注意力，显著提升图像生成质量，开创认知特征
7. 三星工会呼吁解除AI工具限制，改革人事绩效，以提升竞争力并避免危机。
8. 新加坡发布AI安全指南，禁用深度伪造技术，推医疗设备安全标签，保障网络安全与选举公正。

...

如果文章数目太多可以考虑对文章内容做排序和筛选，进一步提升早报的生成质量。

方案亮点

- 极致时效性：抢占信息传递“第一时间窗口”
- 内容精准度：千人千面的“信息减法”与“价值加法”
- 形式与交互创新：突破“文字 + 图片”的传统框架
- 技术驱动的“反人工依赖”与“低成本扩展”

>
