

[API 调用问题](#)

API 调用

 Copy page

Q：如何调用我们的 API？

A：您可以参考我们平台提供的 [接口文档](#) 进行调用。

Q：同步、异步、SSE 调用方式有什么区别？

A：同步、异步、SSE 调用是三种不同的 API 响应方式。

- **SSE 调用：**客户发起请求后，可以流式的实时获取到模型生成的内容直到推理结束，类似于智谱清言 APP 上的打字机效果。该调用方式适用于对首响及响应时长要求较高的场景，如和用户直接进行交互的智能客服、对话闲聊等。我们推荐您使用 SSE 调用，用户体验更好。
- **同步调用：**客户发起请求，模型完成推理后一次性返回全量生成结果。
- **异步调用：**客户发起请求后，需要用户调用异步接口结果查询模型处理状态和推理结果，如处理完成，可通过结果查询接口获取到模型生成结果。该调用方式适用于对响应时间不敏感的业务场景，如批量处理数据、批量生成文章等。

Q：调用模型时的并发限制是多少？

A：您可以参考 [速率限制](#) 了解当前的并发以及如何提升您的并发数。

A: 在大语言模型中，temperature 和 top_p 参数用于调节生成文本的多样性和质量。

- **temperature** 参数用于控制模型输出结果的随机性，取值范围是: [0.0,1.0]。值越大，生成的文本越随机，值越小，生成的文本越稳定；
- **top_p** 参数用于控制模型输出结果中单词或词组的概率分布，取值范围是: [0.0,1.0]。值越大，模型会在更多单词或词组中进行选择，增加输出结果的随机性，值越小，模型会在更少的单词或词组中进行选择，增加输出结果的稳定性。

要获得更有创意、更多样性的回答，可将 temperature 设为较高值或 top_p 设为较高值；要获得更稳定、更有确定性的回答，可将 temperature 设为较低值或 top_p 设为较低值。您可根据实际的应用场景调整 temperature 或 top_p 参数，但不要同时调整这两个参数。

Q: 如何使用函数调用能力?

A: 您可参考 [函数调用使用文档](#) 了解调用逻辑。

Q: tools 列表支持传多个函数吗?

A: tools 支持传多个函数，但每次调用只能命中一个。

Q: 函数调用，知识库检索，网络搜索可以全部添加到 tools 参数里吗?

A: 函数调用、知识库检索、网络搜索，3个功能互斥。如果同时使用，按照优先级只会生效一个。优先级顺序为：函数调用>知识库检索>网络搜索。

A: 目前可通过提交 [模型微调接口文档](#) [开发者 Pro 版平台服务权益](#) 申请 获得 GLM-4-Flash 模型微调权限，其他模型的微调能力会陆续迭代。开通权限后可通过模型微调接口文档了解调用详情。

您也可以购买我们的云端私有化服务，获得私有化部署及模型微调服务，请随时 [联系我们](#)，我们的咨询顾问将为您详细介绍。

Q: 对话模型如何实现联系上下文？或如何实现多轮对话？

A: 对话模型联系上下文（或实现多轮对话），需要您将之前的对话记录作为参数传过来，传参 messages 示例如下：

```
messages=[

{"role": "user", "content": "作为一名营销专家，请为我的产品创作一个吸引人的slogan"},

{"role": "assistant", "content": "当然，为了创作一个吸引人的slogan，请告诉我一些关于您产品"},

{"role": "user", "content": "智谱开放平台"},

{"role": "assistant", "content": "智启未来，谱绘无限—智谱AI，让创新触手可及\!"},

{"role": "user", "content": "创建一个更精准、吸引人的slogan"}

]
```

Q: 模型上下文、最大输入、最大输出分别有限制吗？

A:

- 模型上下文、最大输出限制请参考文档：[模型概览](#)

>

Q: glm4v 系列模型支持本地图片吗?

A: glm4v 系列模型支持传参 base64 格式的本地图片或图片 url 地址

Q: glm-4v 系列支持传参多张图片吗?

A:

GLM-4V-Plus-0111: 具备卓越的多模态理解能力，可同时处理最多 5 张图像，并支持视频内容理解（视频大小 < 200M），适用于复杂的多媒体分析场景；

GLM-4V-Flash（免费）：专注于高效的单一图像理解，适用于单张图像解析的场景。

Q: 异步任务有过期时间吗?

A: 异步任务没有过期时间

Q: 调用对话 API 接口时，使用了 web_search，但模型返回结果为什么还是跟没联网一样?

A: 原因可能是：

- 使用 Web_Search 工具传参时，未传 enable 参数，该参数默认为 false，需要传 true 才能开启联网

- 如还未解决，可联系人工客服

Q：如何创建自己的智能体？

A： 您可以参考下[智能体开发文档](#)

Q：如何用 API 接口调用自己创建的智能体？

A： 您可以参考下清流智能体 API 接口文档：[清流智能体 API](#)

Q：模型微调后支持下载吗？

A： 目前微调的模型不支持下载