

[API 调用问题](#)

Batch API

 Copy page

Q：支持的 Batch API 模型有哪些？

A：支持的 Batch API 模型如下所示

- GLM-4-Flash
- GLM-4-Air
- GLM-3-Turbo
- Embedding-2
- Embedding-3
- GLM-4-0520
- GLM-4
- GLM-4-Plus
- Cogview-3
- CogVideoX
- GLM-4V
- GLM-4-Plus
- GLM-4-Air-250414
- GLM-4-Long
- GLM-4-FlashX-250414
- GLM-4V-Plus-0111
- CogView-4

>

Q：Batch API 的价格如何？

A： 价格是标准 API 的 50%。参考 [产品定价](#)

Q：Batch API 的并发限制是怎样的？

A： Batch API 的并发限制与现有的每个模型并发限制是分开的。Batch API 引入了两种新的限制：

- 单个 Batch 文件中包含最多 50,000 个请求且不超过 100M。
- 每个模型的 Batch 有最大排队限制。当达到请求队列上限时，请等待当前任务完成后再提交新任务。
- 向量模型（Embedding-2、Embedding-3）Batch 文件请求数量限制为不超过 10,000 次。

模型	Batch 队列限制
GLM-4-Flash	1000 万次
GLM-4-Air	1000 万次
GLM-3-Turbo	200 万次
Embedding-2	200 万次
Embedding-3	200 万次
GLM-4-Plus	200 万次
GLM-4-0520	50 万次
GLM-4	50 万次
Cogview-3	3 万次
CogVideoX	1 万次

模型 BigModel GLM-4V	Batch 队列限制 1 万次
---	---------------------------------------

>

Q：如何在调用 Batch API 前进行实名认证？

A：调用 Batch API 必须实名认证，请前往 [实名认证](#) 页面完成个人认证或企业认证，成功认证后，将免费获得 500 万 tokens。

Q：Batch 的过期如何处理？

A：如果 Batch 未能及时完成，该批次将被标记为过期状态；批次中未完成的请求将被取消。对于批次中已完成的请求，用户可以通过文件获取，并且需要支付这些请求消耗的费用。

Q：Batch 文件有哪些存储限制？

A：Batch 文件最多上传 1000 个文件。系统只保留您的文件 30 天，过期后文件将自动删除，无法恢复。

Q：如何删除Batch 文件？

A：请前往 [Batch 数据](#) 页面进行删除、或通过调用接口删除。

