

模型能力

流式消息

 Copy page

💡 流式消息（Streaming）允许在模型生成响应时实时获取内容，而不需要等待完整响应生成完毕。这种方式可以显著改善用户体验，特别是在生成长文本内容时，用户可以立即看到输出开始出现。

功能特性

流式消息采用增量生成机制，在生成过程中将内容分块实时传输，而非等待完整响应生成后一次性返回。这种机制使得开发者可以：

- **实时响应**：无需等待完整响应，内容逐步显示
- **改善体验**：减少用户等待时间，提供即时反馈
- **降低延迟**：内容生成即传输，减少感知延迟
- **灵活处理**：可以在接收过程中进行实时处理和展示

核心参数说明

- `stream=True`：启用流式输出，必须设置为 `True`
- `model`：支持流式输出的模型，如 `glm-4.7`、`glm-4.7`、`glm-4.6` 等

响应格式说明

流式响应采用服务器发送事件（Server-Sent Events, SSE）格式，每个事件包含：

- `choices[0].delta.content`：增量文本内容



choices[0].delta.reasoning_content : 增量思考内容

BigModel

choices[0].finish_reason : 完成原因 (仅在最后一个chunk中出现)



usage : 令牌使用统计 (仅在最后一个chunk中出现)

代码示例

[cURL](#) [Python](#)

```
curl --location 'https://open.bigmodel.cn/api/paas/v4/chat/completions' \
--header 'Authorization: Bearer YOUR_API_KEY' \
--header 'Content-Type: application/json' \
--data '{
  "model": "glm-4.7",
  "messages": [
    {
      "role": "user",
      "content": "写一首关于春天的诗"
    }
  ],
  "stream": true
}'
```

响应示例

流式响应的格式如下:

 data: {"id": "1", "created": 1677652288, "model": "glm-4.7", "choices": [{"index": 0, "del

data: {"id": "1", "created": 1677652288, "model": "glm-4.7", "choices": [{"index": 0, "del

data: {"id": "1", "created": 1677652288, "model": "glm-4.7", "choices": [{"index": 0, "del

...

data: {"id": "1", "created": 1677652288, "model": "glm-4.7", "choices": [{"index": 0, "fin

data: [DONE]

应用场景



聊天应用

- 实时对话体验
- 逐字显示回复
- 减少等待时间



内容生成

- 文章写作助手
- 代码生成工具
- 创意内容创作



教育应用

- 在线答疑系统
- 学习辅导工具
- 知识问答平台



客服系统

- 智能客服机器人
- 实时问题解答
- 用户支持系统

