

模型能力

深度思考

[📄 Copy page](#)

💡 深度思考（Thinking）高级推理功能，通过启用思维链（Chain of Thought）机制，让模型在回答问题前进行深层次的分析和推理。这种方式能显著提升模型在复杂任务中的准确性和可解释性，特别适用于需要多步推理、逻辑分析和问题解决的场景。

功能特性

深度思考功能目前支持 GLM-5.1、GLM-5、GLM-5-Turbo、GLM-5V-Turbo、GLM-4.7、GLM-4.6、GLM-4.5 等系列最新模型。通过启用深度思考，模型可以：

- **多步推理**：将复杂问题分解为多个步骤，逐步分析解决
- **逻辑分析**：提供清晰的推理过程和逻辑链条
- **提升准确性**：通过深度思考减少错误，提高回答质量
- **增强可解释性**：展示思考过程，让用户理解模型的推理逻辑
- **智能判断**：模型自动判断是否需要深度思考，优化响应效率

核心参数说明

- `thinking.type`：控制深度思考模式
 - `enabled`（默认）：启用动态思考，`glm-5.1` `glm-5` `glm-4.7` `glm-4.5v` 系列为强制思考，其它模型自动判断是否需要深度思考
 - `disabled`：禁用深度思考，直接给出回答

代码示例

[cURL](#) [Python SDK](#)

基础调用（启用深度思考）

```
curl --location 'https://open.bigmodel.cn/api/paas/v4/chat/completions' \
--header 'Authorization: Bearer YOUR_API_KEY' \
--header 'Content-Type: application/json' \
--data '{
  "model": "glm-5.1",
  "messages": [
    {
      "role": "user",
      "content": "详细解释量子计算的基本原理, 并分析其在密码学领域的潜在影响"
    }
  ],
  "thinking": {
    "type": "enabled"
  },
  "max_tokens": 4096,
  "temperature": 1.0
}'
```

流式调用（深度思考 + 流式输出）



```
curl --location 'https://open.bigmodel.cn/api/paas/v4/chat/completions' \
--header 'Authorization: Bearer YOUR_API_KEY' \
--header 'Content-Type: application/json' \
--data '{
  "model": "glm-5.1",
  "messages": [
    {
      "role": "user",
      "content": "设计一个电商网站的推荐系统架构，考虑用户行为、商品特征和实时性要求"
    }
  ],
  "thinking": {
    "type": "enabled"
  },
  "stream": true,
  "max_tokens": 4096,
  "temperature": 1.0
}'
```

禁用深度思考

```
curl --location 'https://open.bigmodel.cn/api/paas/v4/chat/completions' \
--header 'Authorization: Bearer YOUR_API_KEY' \
--header 'Content-Type: application/json' \
--data '{
  "model": "glm-5.1",
  "messages": [
    {
      "role": "user",
      "content": "今天天气怎么样？"
    }
  ],
  "thinking": {
    "type": "disabled"
  }
}'
```

```
{
  "created": 1677652288,
  "model": "glm-5",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "人工智能在医疗诊断中具有巨大的应用前景...",
        "reasoning_content": "让我从多个角度来分析这个问题。首先，我需要考虑AI在医疗诊断中的",
      },
      "finish_reason": "stop"
    }
  ],
  "usage": {
    "completion_tokens": 239,
    "prompt_tokens": 8,
    "prompt_tokens_details": {
      "cached_tokens": 0
    },
    "total_tokens": 247
  }
}
```

最佳实践

推荐启用的场景：

- 复杂问题分析和解决
- 多步骤推理任务
- 技术方案设计
- 策略规划和决策

可以禁用的场景：

- 简单事实查询
- 基础翻译任务
- 简单分类判断
- 快速问答需求

注意事项

1. **响应时间**：启用深度思考会增加响应时间，特别是复杂任务
2. **Token 消耗**：思考过程会消耗额外的 Token，请合理规划使用
3. **模型支持**：确保使用支持深度思考功能的模型版本
4. **任务匹配**：根据任务复杂度选择是否启用深度思考
5. **流式输出**：结合流式输出可以实时查看思考过程，改善用户体验