

向量模型

Embedding-2

 Copy page 概览

Embedding-2 是智谱AI 推出的第二代文本向量化模型，能够将文本转换为高维向量表示，用于语义相似性计算和搜索。该模型在语义理解、文本检索和相似度计算方面表现优异，适用于构建智能搜索、推荐系统和知识库等应用。



价格

0.5 元 / 百万 Tokens



输入模态

文本



输出模态

向量



上下文窗口

8K



向量维度

1024

 推荐场景

▼ 语义搜索

将用户查询和文档库转换为向量，通过计算向量相似度实现精准的语义搜索，能够理解查询意图而非仅仅匹配关键词。

将相似主题文本聚集在一起，用于内容分类、主题发现和文档整理，帮助用户快速理解大量文本的主要内容。

▼ 推荐系统

基于用户历史行为和内容向量化，计算用户偏好与内容的相似度，实现个性化内容推荐。

▼ 异常检测

通过计算文本向量与正常样本的距离，识别异常或可疑内容，用于内容审核和风险控制。

▼ 知识库问答

将知识库文档向量化，通过语义匹配找到与用户问题最相关的文档片段，提供准确的答案。

使用资源

[体验中心](#)：快速测试模型在业务场景上的效果

[接口文档](#)：API 调用方式

↑ 详细介绍

1 模型特性

Embedding-2 采用先进的神经网络架构，能够深度理解文本的语义信息。模型支持中英文等多种语言，在保持高质量向量表示的同时，具有良好的计算效率。

核心特性：

- **多语言支持**：支持中文、英文等多种语言的文本向量化
- **语义理解**：能够捕捉文本的深层语义信息，而非仅仅是词汇匹配



- 高效计算：优化的模型架构确保快速的向量生成速度
- 稳定输出：相同输入始终产生一致的向量表示



2

技术规格

Embedding-2 提供 1024 维的向量输出，支持最大 8K tokens 的文本输入。模型经过大规模多语言语料训练，在各种文本类型上都有良好的表现。

技术参数：

- 向量维度：1024 维
- 输入字符串数组中，单条请求最多支持 512 个 Tokens，数组总长度不得超过 8K

</> 调用示例

以下是一个完整的调用示例，帮助您快速上手 Embedding-2 模型。

[cURL](#) [python](#) [Java](#) [Python\(旧\)](#) [响应示例](#)

```
curl -X POST \
https://open.bigmodel.cn/api/paas/v4/embeddings \
-H "Authorization: Bearer your-api-key" \
-H "Content-Type: application/json" \
-d '{
  "model": "embedding-2",
  "input": "这是一段需要向量化的文本"
}'
```

最佳实践

▸ 文本预处理

用户并发权益

API调用会受到速率限制，当前我们限制的维度是请求并发数量（在途请求任务数量）。不同等级的用户并发保障如下。

V0	V1	V2	V3
50	100	300	500