

向量模型

Embedding-3

 Copy page 概览

Embedding-3 是智谱AI 推出的第三代文本向量化模型，在前代基础上全面升级，提供更强的语义理解能力和更灵活的向量维度选择。该模型支持自定义向量维度，在保持高质量语义表示的同时，为不同应用场景提供了更优的性能和成本平衡。



价格

0.5 元 / 百万 Tokens



输入模态

文本



输出模态

向量



上下文窗口

8K



向量维度

256-2048（可自定义）

 推荐场景

▼ 高精度语义搜索

利用更强的语义理解能力，实现更精准的文档检索和问答系统，特别适合专业领域的知识库构建。

基于用户行为和内容特征的深度理解，提供更个性化和精准的推荐服务，提升用户体验。

▼ 内容理解与分析

深度分析文本内容的主题、情感和意图，用于舆情监控、内容审核和市场分析。

▼ 知识图谱构建

通过语义向量化技术，自动发现实体关系，构建和完善知识图谱，支持复杂的知识推理。

🧠 使用资源

[体验中心](#)：快速测试模型在业务场景上的效果

[接口文档](#)：API 调用方式

↑ 详细介绍

1 模型升级

Embedding-3 在架构和训练数据上都进行了重大升级，显著提升了语义理解的准确性和泛化能力。新模型在多个评测基准上都取得了显著的性能提升。

核心升级：

- **增强语义理解**：更深层的语义捕捉能力，理解复杂的语言表达
- **多语言优化**：针对中文、英文等多语言场景进行专门优化
- **领域适应性**：在科技、金融、医疗等专业领域表现更佳
- **鲁棒性提升**：对噪声文本和非标准表达有更强的容错能力

2 灵活维度选择



维度选项：

- **2048维（默认）**：最高精度，适合对准确性要求极高的场景
- **1024维**：高精度与效率的平衡，适合大多数应用场景
- **512维**：中等精度，适合大规模部署的场景
- **256维**：较高效率，适合实时性要求高的场景

技术参数：

- 输入字符串数组中，单条请求最多支持 3072 个 Tokens，且数组最大不得超过 64 条

</> 调用示例

以下是一个完整的调用示例，帮助您快速上手 Embedding-3 模型。

[cURL](#) [python](#) [Java](#) [Python\(旧\)](#) [响应示例](#)

```
https://open.bigmodel.cn/api/paas/v4/embeddings \  
-H "Authorization: Bearer your-api-key" \  
-H "Content-Type: application/json" \  
-d '{  
  "model": "embedding-3",  
  "input": "这是一段需要向量化的文本"  
}'
```

```
# 自定义维度  
curl -X POST \  
https://open.bigmodel.cn/api/paas/v4/embeddings \  
-H "Authorization: Bearer your-api-key" \  
-H "Content-Type: application/json" \  
-d '{  
  "model": "embedding-3",  
  "input": "这是一段需要向量化的文本",  
  "dimensions": 512  
}'
```

最佳实践

- 维度选择策略
- 性能优化
- 质量提升
- 存储优化

用户并发权益

API 调用会受到速率限制，当前我们限制的维度是请求并发数量（在途请求任务数量）。不同等级的用户并发保障如下。



→			
V0	V1	V2	V3
50	100	300	500

< GLM-4-Voice

Embedding-2 >