

[免费模型](#)

GLM-4.7-Flash

 Copy page

概览

GLM-4.7-Flash 作为 30B 级 SOTA 模型，提供了一个兼顾性能与效率的新选择。面向 **Agentic Coding** 场景强化了编码能力、长程任务规划与工具协同，并在多个公开基准的当期榜单中取得同尺寸开源模型中的出色表现。在执行复杂智能体任务，在工具调用时指令遵循更强，Artifacts 与 Agentic Coding 的前端美感和长程任务完成效率进一步提升。



输入模态

文本



输出模态

文本



上下文窗口

200K



最大输出 Tokens

128K

能力支持



思考模式



流式输出



Function Call



提供多种思考模式，覆盖不同任务需求

BigModel

支持实时流式响应，提升用户交互体验

强大的工具调用能力，支持多种外部工具集成



上下文缓存

智能缓存机制，优化长对话性能



结构化输出

支持 JSON 等结构化格式输出，便于系统集成



MCP

可灵活调用外部 MCP 工具与数据源，扩展应用场景

★ 推荐场景

- Agentic Coding
- 多模态交互与实时应用开发
- 前端视觉审美优化
- 高质量对话与复杂问题协作
- 沉浸式写作与角色驱动创作
- 专业级 PPT / 海报生成
- 智能搜索与 Deep Research

★ 详细介绍



小而强的 Coding Agent

GLM-4.7 系列在编程、推理与智能体三个维度实现了显著突破：




- **更强的编程能力**：显著提升了模型在多语言编码和在终端智能体中的效果；现在可以在 Claude Code、Kilo Code、TRAE、Cline 和 Roo Code 等编程框架中实现“先思考、再行动”的机制，在复杂任务上有更稳定的表现
- **前端审美提升**：GLM-4.7 系列模型在前端生成质量方面明显进步，能够生成观感更佳的网页、PPT、海报
- **工具调用与协同执行更强**：增强对复杂链路的任务拆解与流程编排能力，可在多步执行中持续校验与纠偏，更适合端到端交付类的智能体任务。
- **通用能力增强**：GLM-4.7 系列模型的对话更简洁智能且富有人情味，写作与角色扮演更具文采与沉浸感

在SWE-bench Verified、 τ^2 -Bench等主流基准测试中，GLM-4.7-Flash 的综合表现在相同尺寸模型系列中取得开源SOTA分数。另外，相比于同尺寸模型，GLM-4.7-Flash同样具有出色的前端和后端开发能力。

在内部的编程实测中，GLM-4.7-Flash在前后端任务上表现出色。在编程场景之外，我们也推荐大家在中文写作、翻译、长文本、情感/角色扮演等通用场景中体验GLM-4.7-Flash。

6 benchmarks: SWE-bench Verified, τ^2 -Bench, BrowseComp, AIME 25, GPQA, HLE

GLM-4.7-Flash (30B-A3B) Qwen3-30B-A3B-Thinking-2507
GPT-OSS-20B



使用资源

[体验中心](#): 快速测试模型在业务场景上的效果

[接口文档](#): API 调用方式

以下是完整的调用示例，帮助您快速上手 GLM-4.7-Flash 模型。

>

[cURL](#) [Python](#) [Java](#) [Python\(旧\)](#)

基础调用

```
curl -X POST "https://open.bigmodel.cn/api/paas/v4/chat/completions" \
-H "Content-Type: application/json" \
-H "Authorization: Bearer your-api-key" \
-d '{
  "model": "glm-4.7-flash",
  "messages": [
    {
      "role": "user",
      "content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"
    },
    {
      "role": "assistant",
      "content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"
    },
    {
      "role": "user",
      "content": "智谱AI 开放平台"
    }
  ],
  "thinking": {
    "type": "enabled"
  },
  "max_tokens": 65536,
  "temperature": 1.0
}'
```

流式调用



curl -X POST "https://open.bigmodel.cn/api/paas/v4/chat/completions" \

-H "Content-Type: application/json" \

-H "Authorization: Bearer your-api-key" \

-d '{

"model": "glm-4.7-flash",

"messages": [

{

"role": "user",

"content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"

},

{

"role": "assistant",

"content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"

},

{

"role": "user",

"content": "智谱开放平台"

}

],

"thinking": {

"type": "enabled"

},

"stream": true,

"max_tokens": 65536,

"temperature": 1.0

}'