

音视频模型

GLM-4-Voice

 Copy page 概览

GLM-4-Voice 是智谱推出的首个端到端语音模型。它能够直接理解和生成中英文语音，实现实时语音对话，并可根据用户指令灵活调整语音的情感、语调、语速和方言等特性，使语音交互更加自然生动。



价格

80 元 / 百万 Tokens



输入模态

音频、文本



输出模态

音频



上下文窗口

8K



最大输出 Tokens

4K

 推荐场景

▼ 角色陪伴

AI 通过虚拟角色（如游戏角色、虚拟偶像）与用户进行情感化对话，虚拟角色可以设定为特定性格、背景和声音，实现全天候陪伴。

AI 导游与用户进行实时语音交互，为用户提供详细的历史背景、文化意义和建筑特点，通过语音描述帮助用户规划游览路线，解答用户关于景点的疑问。

▼ 英语学习

AI 英语老师通过模拟真实场景（如点餐、问路）与用户进行对话练习，解答用户关于语法规则的疑问，实时纠正用户发音、学习日常表达和语法知识，并提供改进建议。

▼ 在线教育

AI 辅导老师与学生通过详细讲解课程内容，为学生提供课程讲解、作业辅导和学习建议，涵盖多个学科（如数学、历史、科学），解答学生在作业中遇到的问题，通过多轮对话帮助学生理解难点。

使用资源

[接口文档](#)：API 调用方式

↑ 详细介绍



凭借其实时语音对话功能，GLM-4-Voice 为用户提供高效流畅的沟通体验。GLM-4-Voice 具备情感表达、方言生成和语速调节的能力，同时支持中英文双语。它的应用场景广泛，覆盖虚拟角色互动、智慧教育、智能旅游、儿童陪伴等多个领域。通过灵活的语音输入和输出能力，GLM-4-Voice 能够为用户提供高效且个性化的服务体验。

在企业应用方面，GLM-4-Voice 可针对不同垂直行业定制专业的场景解决方案，帮助开发者以较低成本快速适应和融入大模型时代。



调用示例

安装 SDK ›

```
# 安装最新版本
pip install zai-sdk
# 或指定版本
pip install zai-sdk==0.2.2
```

验证安装

```
import zai
print(zai.__version__)
```

调用示例

```
import base64

from zai import ZhipuAiClient
>

def save_audio_as_wav(audio_data, filepath):
    """保存音频数据为 WAV 文件（模型返回的语音用）"""
    with wave.open(filepath, 'wb') as wav_file:
        wav_file.setnchannels(1)
        wav_file.setsampwidth(2)
        wav_file.setframerate(44100)
        wav_file.writeframes(audio_data)
    print(f"Audio saved to {filepath}")

def get_base64_from_wav(wav_path):
    """将 WAV 文件转为 Base64 编码字符串"""
    with open(wav_path, "rb") as f:
        audio_bytes = f.read()
    return base64.b64encode(audio_bytes).decode("utf-8")

client = ZhipuAiClient(api_key="your_api_key") # 请填写您自己的 APIKey

input_wav_path = "your_voice.wav" # 你的 WAV 文件路径
base64_voice = get_base64_from_wav(input_wav_path)

response = client.chat.completions.create(
    model="glm-4-voice",
    messages=[
        {
            "role": "user",
            "content": [
                {
                    "type": "text",
                    "text": "你好，这是我的语音输入测试，请慢速复述一遍"
                },
                {
                    "type": "input_audio",
                    "input_audio": {
                        "data": base64_voice,
                        "format": "wav"
                    }
                }
            ]
        }
    ]
)
```

BigModel



```
}  
    },  
    stream=False  
)  
  
print(response.choices[0].message.content)  
  
# 解析并保存模型返回的语音  
try:  
    audio_data = response.choices[0].message.audio['data']  
    decoded_data = base64.b64decode(audio_data)  
    save_audio_as_wav(decoded_data, "output.wav")  
except Exception as e:  
    print("处理音频失败: ", e)
```

用户并发权益

API 调用会受到速率限制，当前我们限制的维度是请求并发数量（在途请求任务数量）。不同等级的用户并发保障如下。

V0	V1	V2	V3
5	10	15	20