

文本模型

GLM-4.5

 Copy page

概览

GLM-4.5 和 GLM-4.5-Air 是我们的模型系列，专为智能体应用打造的基础模型。GLM-4.5 和 GLM-4.5-Air 均使用了混合专家（Mixture-of-Experts）架构。GLM-4.5 总参数达 3550 亿，激活参数为 320 亿；GLM-4.5-Air 采用更精简的设计，总参数为 1060 亿，激活参数为 120 亿。

GLM-4.5 和 GLM-4.5-Air 使用了相似的训练流程：首先在15万亿令牌的通用数据上进行了预训练。然后在代码、推理、智能体等领域的数据上进行了针对性训练，并将上下文长度扩展到 128k，最后通过强化学习进一步增强了模型的推理、代码与智能体能力。

GLM-4.5 和 GLM-4.5-Air 在工具调用、网页浏览、软件工程、前端编程领域进行了优化，可以接入 Claude Code、Roo Code 等代码智能体中使用，也可以通过工具调用接口支持任意的智能体应用。

GLM-4.5 和 GLM-4.5-Air 均采用混合推理模式，提供两种模式：用于复杂推理和工具使用的思考模式，以及用于即时响应的非思考模式。可通过 thinking.type 参数启用或关闭（支持 enabled 和 disabled 两种设置），默认开启动态思考功能。



输入模态

文本



输出模态

文本



上下文窗口



最大输出 Tokens

★ GLM-4.5 系列模型

⚠ GLM-4.5、GLM-4.5-X 模型即将下线，建议选择最新旗舰文本模型 [GLM-4.7](#)。



GLM-4.5

我们强大的推理模型，3550亿参数



GLM-4.5-Air

高性价比 轻量级 强性能



GLM-4.5-X

高性能 强推理 极速响应



GLM-4.5-AirX

轻量级 强性能 极速响应



GLM-4.5-Flash

免费 高效 多功能

⚡ 能力支持



深度思考

启用深度思考模式，提供更深层的推理分析



流式输出

支持实时流式响应，提升用户交互体验



Function Call

强大的工具调用能力，支持多种外部工具集成



上下文缓存



结构化输出



MCP

可灵活调用外部 MCP 工具与数据源，扩展应

Benchmark


总览

衡量 AGI 的第一性原理，是在不损失原有能力的前提下融合更多通用智能能力，GLM-4.5 是我们对此理念的首次完整呈现。GLM-4.5 融合更多复杂推理、代码和智能体等多种通用能力并有幸取得技术突破，首次在单个模型中实现将推理、编码和 Agent 能力原生融合，以满足 Agent 应用的复杂需求。

为综合衡量模型的通用能力，我们选择了最具有代表性的12个评测基准，包括MMLU Pro、AIME24、MATH 500、SciCode、GPQA 、HLE、LiveCodeBench、SWE-Bench、Terminal-bench、TAU-Bench、BFCL v3和BrowseComp。综合平均分，GLM-4.5 取得了全球模型第三。


LLM Performance Evaluation: Agentic, Reasoning, And Coding Benchmarks

12 benchmarks: MMLU-Pro, AIME 24, MATH-500, SciCode, GPQA, HLE, LCB (2407-2501), SWE-Bench Verified, Terminal-Bench, TAU-Bench, BFCL V3, BrowseComp




Agentic

Agentic Benchmarks: TAU-Bench, BFCL V3 (Full), BrowserComp




Reasoning

Reasoning Benchmarks: MMLU-Pro, AIME 24, MATH 500, SciCode, GPQA, HLE, LCB (2407-2501)




Coding

Coding Benchmarks: SWE-Bench Verified, Terminal-Bench



GLM-4.5 参数量为 DeepSeek-R1 的 1/2、Kimi-K2 的 1/3，但同样在多项标准基准测试中表现得更为出色，这得益于GLM模型的更高参数效率。值得注意的是，GLM-4.5-Air 以 **106B 总参数 / 12B 激活参数** 实现了重要突破，在 Artificial Analysis 等推理基准上超越 Gemini 2.5 Flash、Qwen3-235B、Claude 4 Opus 等模型，性能位列国产前三。


在 SWE-Bench Verified 等图谱中，GLM-4.5 系列位于性能/参数比帕累托前沿。



低成本、高速度

在性能优化之外，GLM-4.5 系列也在成本和效率上实现突破，由此带来远低于主流模型定价：API 调用价格低至输入 0.8 元/百万 tokens，输出 2 元/百万 tokens

同时，高速版本实测生成速度超过 100 tokens/秒，支持低延迟、高并发的实际部署需求，兼顾成本效益与交互体验。




模型	上下文分段 (千 tokens)	输入价格 (元/M)	输出价格 (元/M)
GLM-4.5	输入 0-32 且 输出 0-0.2	2	8
	输入 0-32 且 输出 0.2+	3	14
	输入 32-128	4	16
GLM-4.5-Air	输入 0-32 且 输出 0-0.2	0.8	2
	输入 0-32 且 输出 0.2+	0.8	6
	输入 32-128	1.2	8
KIMI-K2	-	4	16
DeepSeek-R1	-	4	16
Claude-4-sonnet	-	21.5 (3美元)	107.4 (15美元)
Qwen-3-Coder	输入 0-32	4	16
	输入 32-128	6	24
	输入 128-256	10	40
	输入 256-1M	20	200

真实体验

真实场景表现比榜单更重要。为了评测GLM-4.5在真实场景Agent Coding中的效果，我们接入Claude Code与Claude-4-Sonnet、Kimi-K2、Qwen3-Coder进行对比测试。测试采用52个编程开发任务，涵盖六大开发领域，在独立容器环境中进行多轮交互测试。

实测结果显示（如下图），GLM-4.5 相对其他开源模型展现出强劲竞争优势，特别在工具调用可靠性和任务完成度方面表现突出。GLM-4.5 相比 Claude-4-Sonnet 仍有提升空间，在大部分场景中可以实现平替的效果。为确保评测透明度，我们公布了[52道题目及Agent轨迹](#)，供业界验证复现。

GLM-4.5's Experience with Agentic Coding in Real-world Development Scenarios



推荐场景


1. 点击“体验一下”会跳转至体验中心，建议先看完使用指南再体验哦～
2. 体验过程会消耗模型 tokens，如遇体验失败，可通过 [链接](#) 抢购特价资源包。

[网页搭建](#) [AI 助手](#) [智慧办公](#) [智能问答](#) [复杂文本翻译](#) [内容创作](#) [虚拟角色](#)

核心能力：[代码能力](#) → 智能代码生成 | 实时代码补全 | 自动化Bug 修复

1. 覆盖 Python、JavaScript、Java 等主流语言
2. 基于自然语言指令生成结构清晰、可扩展的高质量代码
3. 聚焦真实开发需求，避免模板化输出

使用案例：1 小时完成重构级任务，5 分钟生成完整产品原型



<> 调用示例

思考模式

GLM 4.5 提供了“深度思考模式”，用户可以通过设置 `thinking.type` 参数来启用或关闭该模式。该参数支持两种取值：`enabled`（动态）和 `disabled`（禁用）。默认情况下开启动态思考功能。

- 简单任务（无需思考）：对于不需要复杂推理的简单请求（例如事实检索或分类），无需思考。
 - 智谱AI 的成立时间。
 - 翻译 I love you 这句英语成中文。
- 中等任务（默认/需要一定程度的思考）：许多常见请求都需要一定程度的分步处理或更深入的理解。GLM-4.5系列模型可以灵活运用思考能力来处理以下任务。
 - 为什么木星拥有较多的卫星，而土星却比木星的卫星少得多？
 - 从北京去上海，对比乘坐飞机和动车的优劣势。
- 困难任务（最大思维能力）：对于真正复杂的挑战，例如解决复杂的数学问题，联网问题，编码问题，这类任务要求模型充分发挥推理和规划能力，通常需要经过许多内部步骤才能提供答案。
 - 详细解释 MoE 模型中不同专家是如何配合的。
 - 根据上证指数的近一周的波动情况和时政信息，预测我是否应该购入股票指数 ETF，为什么？

示例代码

以下是完整的调用示例，帮助您快速上手 GLM-4.5 模型。

[cURL](#) [Python](#) [Java](#) [Python\(旧\)](#)



`curl -X POST "https://open.bigmodel.cn/api/paas/v4/chat/completions" \`

`-H "Content-Type: application/json" \`

`-H "Authorization: Bearer your-api-key" \`

`-d '{`

`"model": "glm-4.5",`

`"messages": [`

`{`

`"role": "user",`

`"content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"`

`},`

`{`

`"role": "assistant",`

`"content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"`

`},`

`{`

`"role": "user",`

`"content": "智谱AI 开放平台"`

`}`

`],`

`"thinking": {`

`"type": "enabled"`

`},`

`"max_tokens": 4096,`

`"temperature": 0.6`

`}'`

流式调用


```
curl -X POST "https://open.bigmodel.cn/api/paas/v4/chat/completions" \
-H "Content-Type: application/json" \
-H "Authorization: Bearer your-api-key" \
-d '{
  "model": "glm-4.5",
  "messages": [
    {
      "role": "user",
      "content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"
    },
    {
      "role": "assistant",
      "content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"
    },
    {
      "role": "user",
      "content": "智谱开放平台"
    }
  ],
  "thinking": {
    "type": "enabled"
  },
  "stream": true,
  "max_tokens": 4096,
  "temperature": 0.6
}'
```