

文本模型

GLM-4.6

 Copy page 概览

GLM-4.6 是智谱的语言模型，其总参数量 355B，激活参数 32B。GLM-4.6 所有核心能力上均完成了对 GLM-4.5 的超越，具体如下：

- **高级编码能力**：在公开基准与真实编程任务中，GLM-4.6 的代码能力对齐 Claude Sonnet 4。
- **上下文长度**：上下文窗口由 128K→200K，适应更长的代码和智能体任务。
- **推理能力**：推理能力提升，并支持在推理过程中调用工具。
- **搜索能力**：增强了模型在工具调用和搜索智能体上的表现，在智能体框架中表现更好。
- **写作能力**：在文风、可读性与角色扮演场景中更符合人类偏好。
- **多语言翻译**：进一步增强跨语种任务的处理效果。



输入模态

文本



输出模态

文本



上下文窗口

200K



最大输出 Tokens

128K



深度思考

启用深度思考模式，提供更深层的推理分析



流式输出

支持实时流式响应，提升用户交互体验



Function Call

强大的工具调用能力，支持多种外部工具集成



上下文缓存

智能缓存机制，优化长对话性能



结构化输出

支持 JSON 等结构化格式输出，便于系统集成



MCP

可灵活调用外部 MCP 工具与数据源，扩展应用场景

🌟 Benchmark


1. 综合评测

在 8 大权威基准：AIME 25、GPQA、LCB v6、HLE、SWE-Bench Verified、BrowseComp、Terminal-Bench、 τ^2 -Bench、GPQA 模型通用能力的评估中，**GLM-4.6** 在大部分权威榜单表现对齐 **Claude Sonnet 4**。

LLM Performance Evaluation: Agentic, Reasoning and Coding

8 benchmarks: AIME 25, GPQA, LiveCodeBench v6, HLE, BrowseComp, SWE-bench Verified, Terminal-Bench, τ^2 -Bench
(Evaluation results under 128K context length)

GLM-4.6 GLM-4.5 DeepSeek-V3.2-Exp Claude Sonnet 4 Claude Sonnet 4.5




2. 真实编程评测

为了测试模型在实际编程任务中的能力，我们在 **Claude Code** 环境下进行了 74 个真实场景编程任务测试。结果显示，**GLM-4.6 实测超过 Claude Sonnet 4**。




BigModel: GLM 4.6's Experience with Agentic Coding in Real-world Development Scenarios



在平均token消耗上，GLM-4.6 比 GLM-4.5 节省 **30%** 以上。

Average Token Usage per Interaction

(input + output tokens for multiple tool calls, without cache)



为确保透明性与可信度，智谱已公开全部测试题目与Agent轨迹，供业界验证与复现（链接：<https://huggingface.co/datasets/zai-org/CC-Bench-trajectories>）。

★ 推荐场景

- 智慧办公
- 翻译与跨语言应用
- 内容创作
- 虚拟角色
- 智能搜索与深度研究

使用资源

[体验中心](#)：快速测试模型在业务场景上的效果

[接口文档](#)：API 调用方式

调用示例

以下是完整的调用示例，帮助您快速上手 GLM-4.6 模型。

[cURL](#) [Python](#) [Java](#) [Python\(旧\)](#)

基础调用

```
-H "Content-Type: application/json" \
```

```
-H "Authorization: Bearer your-api-key" \
```

```
-d '{
```

```
  "model": "glm-4.6",
```

```
  "messages": [
```

```
  {
```

```
    "role": "user",
```

```
    "content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"
```

```
  },
```

```
  {
```

```
    "role": "assistant",
```

```
    "content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"
```

```
  },
```

```
  {
```

```
    "role": "user",
```

```
    "content": "智谱AI 开放平台"
```

```
  }
```

```
  ],
```

```
  "thinking": {
```

```
    "type": "enabled"
```

```
  },
```

```
  "max_tokens": 65536,
```

```
  "temperature": 1.0
```

```
}'
```

流式调用

```
-H "Content-Type: application/json" \
```

```
-H "Authorization: Bearer your-api-key" \
```

```
-d '{>
```

```
  "model": "glm-4.6",
```

```
  "messages": [
```

```
  {
```

```
    "role": "user",
```

```
    "content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"
```

```
  },
```

```
  {
```

```
    "role": "assistant",
```

```
    "content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"
```

```
  },
```

```
  {
```

```
    "role": "user",
```

```
    "content": "智谱开放平台"
```

```
  }
```

```
  ],
```

```
  "thinking": {
```

```
    "type": "enabled"
```

```
  },
```

```
  "stream": true,
```

```
  "max_tokens": 65536,
```

```
  "temperature": 1.0
```

```
}'
```