

[文本模型](#)

# GLM-5

 Copy page

## 概览

GLM-5 是智谱的基座模型，面向 **Agentic Engineering** 打造，能够在复杂系统工程与长程 Agent 任务中提供可靠生产力。在 Coding 与 Agent 能力上，**GLM-5 取得开源 SOTA 表现**，在真实编程场景的使用体感逼近 Claude Opus 4.5，擅长复杂系统工程与长程 Agent 任务，是通用 Agent 助手的理想基座。



定位  
基座模型



输入模态  
文本



输出模态  
文本



上下文窗口  
200K



最大输出 Tokens  
128K

## 能力支持



思考模式



流式输出



Function Call



提供多种思考模式，覆盖不同任务需求

支持实时流式响应，提升用户交互体验

强大的工具调用能力，支持多种外部工具集成



### 上下文缓存

智能缓存机制，优化长对话性能



### 结构化输出

支持 JSON 等结构化格式输出，便于系统集成



### MCP

可灵活调用外部 MCP 工具与数据源，扩展应用场景



### GLM in Excel

适配 Excel 官方的 AI 插件，能深度赋能表格 workflow



## 推荐场景

- Agentic Coding
- 智能体任务
- 办公场景
- 角色扮演 (RolePlay)
- 剧本 / 分镜脚本生成
- 翻译
- 文本数据提取

## 详细介绍

### 1 更大基座，更强智能

GLM-5 全新基座为从“写代码”到“写工程”的能力演进提供了坚实基础：

- **参数规模扩展：**从 355B（激活 32B）扩展至 744B（激活 40B），预训练数据从 23T 提升至 28.5T，更大规模的预训练算力显著提升了模型的通用智能水平
- **异步强化学习：**构建全新的 “Slime” 框架，支持更大模型规模及更复杂的强化学习任务，提升强化学习后训练流程效率；提出异步智能体强化学习算法，使模型能够持续从长程交互中学习，充分激发预训练模型的潜力
- **稀疏注意力机制：**首次集成 DeepSeek Sparse Attention，在维持长文本效果无损的同时，大幅降低模型部署成本，提升 Token Efficiency

### 2 Coding 能力：对齐 Claude Opus 4.5

GLM-5 在编程能力上实现了对 Claude Opus 4.5 的对齐，**在业内公认的主流基准测试中取得开源模型最高分数**。在 SWE-bench-Verified 和 Terminal Bench 2.0 中分别获得 77.8 和 56.2 的开源模型最高分数，性能表现超过 Gemini 3.0 Pro。




# LLM Performance Evaluation: Agentic, Reasoning and Coding

8 benchmarks: Humanity's Last Exam, SWE-bench Verified, SWE-bench Multilingual, Terminal-Bench 2.0, BrowseComp, MCP-Atlas,  $\tau^2$ -Bench, Vending Bench 2



GLM-4.7 GLM-5 Claude Opus 4.5 Gemini 3 Pro GPT-5.2 (xhigh)




在内部 Claude Code 评估集合中，GLM-5 在前端、后端、长程任务等编程开发任务上显著超越 GLM-4.7，能够以极少的人工干预自主完成 Agentic 长程规划与执行、后端重构和深度调试等系统工程任务，使用体验逼近 Opus 4.5。



GLM-4.7 GLM-5 Claude Opus 4.5


>



### 3 Agent 能力：SOTA级长程任务执行

GLM-5 在 Agent 能力上实现开源 SOTA，在多个评测基准中取得开源第一。在 BrowseComp（联网检索与信息理解）、MCP-Atlas（工具调用和多步骤任务执行）和  $\tau^2$ -Bench（复杂多工具场景下的规划和执行）均取得最高表现。

GLM-4.7 GLM-5 Claude Opus 4.5 Gemini 3 Pro GPT-5.2 (xhigh)





BigModel

这些能力是 Agentic Engineering 的核心：模型不仅要能写代码、完成工程，还要能在长程任务中保持目标一致性、进行资源管理、处理多步骤依赖关系，成为真正的 Agentic Ready 基座模型。

>

## 使用资源

[体验中心](#)：快速测试模型在业务场景上的效果

[接口文档](#)：API 调用方式

## 调用示例

以下是完整的调用示例，帮助您快速上手 GLM-5 模型。

[cURL](#)   [Python](#)   [Java](#)   [Python\(旧\)](#)

### 基础调用



curl -X POST "https://open.bigmodel.cn/api/paas/v4/chat/completions" \

-H "Content-Type: application/json" \

-H "Authorization: Bearer your-api-key" \

-d '{

"model": "glm-5",

"messages": [

{

"role": "user",

"content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"

},

{

"role": "assistant",

"content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"

},

{

"role": "user",

"content": "智谱AI 开放平台"

}

],

"thinking": {

"type": "enabled"

},

"max\_tokens": 65536,

"temperature": 1.0

}'

## 流式调用



```
-H "Content-Type: application/json" \
```

```
-H "Authorization: Bearer your-api-key" \
```

```
-d '{
```

```
  "model": "glm-5",
```

```
  "messages": [
```

```
    {
```

```
      "role": "user",
```

```
      "content": "作为一名营销专家，请为我的产品创作一个吸引人的口号"
```

```
    },
```

```
    {
```

```
      "role": "assistant",
```

```
      "content": "当然，要创作一个吸引人的口号，请告诉我一些关于您产品的信息"
```

```
    },
```

```
    {
```

```
      "role": "user",
```

```
      "content": "智谱开放平台"
```

```
    }
```

```
  ],
```

```
  "thinking": {
```

```
    "type": "enabled"
```

```
  },
```

```
  "stream": true,
```

```
  "max_tokens": 65536,
```

```
  "temperature": 1.0
```

```
}'
```