

视觉理解模型

GLM-4.1V-Thinking

📄 Copy page

☰ 概览

GLM-4.1V-Thinking 系列是 10B 尺寸性能卓越的视觉推理模型。它在图表/视频理解、前端 Coding、GUI 任务等核心能力达到全面新 SOTA，并引入思维链推理机制，显著提升模型在复杂场景中的回答精准度与可解释性。

GLM-4.1V-Thinking-FlashX GLM-4.1V-Thinking-Flash



定位
高并发版



价格
2 元 / 百万 Tokens



输入模态
视频、图像、文本



输出模态
文本



上下文窗口
64K

>

 0:00 / 2:13

能力支持



内置深度思考

默认内置深度思考，提供更深层的推理分析



视觉理解

强大的视觉理解能力，支持图片，视频，文件



流式输出

支持实时流式响应，提升用户交互体验

推荐场景

▾ 图文理解

精准识别并综合分析图像与文本信息。

▸ 数学与科学推理

▸ 视频理解

🔗 使用资源

[体验中心](#)：快速测试模型在业务场景上的效果

[接口文档](#)：API 调用方式

↑ 详细介绍

1 多项视觉语言任务性能 SOTA

GLM-4.1V-Thinking 模型在高效部署的同时实现了性能突破。在 MMStar、MMMUPro、ChartQAPro、OSWorld 等 28 项权威评测中，以 23 项 10B 级模型优异成绩展现硬核实力，其中 18 项指标更是持平或超越 8 倍参数量的主流 VLM 模型，充分印证小体积模型的极限性能潜能。



	Benchmark	GLM-4.1V -Thinking-9B	Qwen2.5-VL 7B	InternVL3 9B	Kimi-VL A3B-Thinking	MiMo-VL 7B-RL	Qwen2.5-VL 72B	GPT-4o 2024-11-20
General VQA	MMBench-V1.1-EN	85.8	82.7	81.7	71.6*	79.4*	88.0	84.4*
	MMBench-V1.1-CN	84.7	80.1*	80.9*	70.2*	80.3*	86.7*	83.2*
	MMStar	72.9	63.9	66.3	62.3*	69.3*	70.8	66.2*
	BLINK	65.1	45.7*	58.6	53.5*	62.4	58.0*	66.4*
	MUIRBENCH	74.7	53.2*	51.4	56.8*	64.8*	62.9*	69.7*
STEM	MMMU	68.0	58.6	57.7	61.7	66.7	70.2	69.1*
	MMMU-Pro	57.1	38.3	42.1*	45.5*	53.1*	51.1	54.6*
	VideoMMMU	61.0	47.4	-	-	43.3	60.2	61.2*
	AI2D	87.9	83.8*	84.6	78.1*	83.5	87.6*	84.8*
	MathVista	80.7	68.2	71.5	71.3	81.5	74.8	64.0*
	WeMath	63.8	31.0*	33.8	36.0*	66.3	46.0*	44.4*
OCR & Chart	ChartQAPro	59.5	38.0*	36.1*	44.1*	53.6*	46.7*	49.4*
	ChartMuseum	48.8	27.2*	21.5*	29.3*	44.4*	39.6*	42.7*
	OCRBench	84.2	84.5*	87.7	78.7*	86.6	85.1*	81.1*
Long Document	MMLongBench-Doc	42.4	25.1*	20.4*	35.1	24.9*	35.2*	41.0*
Visual Grounding	RefCOCO-avg (val)	87.4	87.1†	88.7	-	89.6	90.2†	-
GUI Agents	OSWorld	14.9	1.9*	1.4*	8.2	1.9*	8.8	5.0†
	AndroidWorld	41.7	27.6†	1.9*	-	10.8*	35.0	34.5†
	WebVoyageSom	69.0	14.1*	19.5*	1.8*	34.0*	40.4*	-
	Webquest-SingleQA	72.1	53.5*	39.3*	56.8*	64.0*	60.5*	57.0*
	Webquest-MultiQA	54.7	39.4*	26.4*	42.0*	47.5*	52.1*	52.8
Coding	Design2Code	64.7	29.1*	15.3*	38.8*	28.7*	41.9*	35.3*
	Flame-VLM-Code	72.5	25.0*	11.3*	36.3*	8.8*	46.3*	75.0*
Video Understanding	VideoMME (w/o)	68.2	65.1	66.7	67.8	67.4	73.3	71.9
	VideoMME (w/)	73.6	71.6	68.9	72.6	72.8*	79.1	77.2
	MMVU	59.4	50.1	-	-	52.4*	62.9	61.4*
	LVBench	45.1	45.3	-	-	37.1*	47.3	48.9
	MotionBench	59.0	-	-	-	48.4*	-	58.0*

值得注意的是，模型在推荐场景任务处理中展现出卓越的适配能力，其高度的通用性与稳健性在复杂业务场景中尤为凸显。


GLM-4.1V-Thinking 在 GLM-4V 架构基础上引入“**思维链推理机制**”，采用“课程采样强化学习策略”，系统性提升模型跨模态因果推理能力与稳定性补足推理能力后的 GLM-4.1V-Thinking，在面向科学研究、教育、自主 Agent 及多模态助手等更复杂现实世界应用时，解决问题的能力更加强大。

应用示例

图片问答 学科解题 GUI Agent 前端网页Coding



输入



请找出这张图中年度利润最高的公司，以及该公司的最大部门？



输出

Sony has the highest annual profit at \$6.3B. For Sony, the note states, "Media is Sony's second - largest segment after game consoles." Thus, the largest segment is game consoles.

[Python](#) [Java](#) [Python\(旧\)](#)

>

安装 SDK

```
# 安装最新版本
pip install zai-sdk
# 或指定版本
pip install zai-sdk==0.2.2
```

验证安装

```
import zai
print(zai.__version__)
```

调用示例

```
from zai import ZhipuAiClient
client = ZhipuAiClient(api_key="") # 请填写您自己的 APIKey
response = client.chat.completions.create(
    model="glm-4.1v-thinking-flashx", # 请填写您要调用的模型名称
    messages=[
        {
            "role": "user",
            "content": [
                {"type": "text", "text": "请帮我解决这个题目，给出详细过程和答案"},
                {"type": "image_url", "image_url": {"url": "https://img.iplaysoft.com/2024/07/20240720151111.png"}
            ]
        }
    ]
)
print(response.choices[0].message.content)
```



请注意，GLM-4.1V-Thinking 模型支持图片和文本的多模态输入，您可以在 messages 中同时包含文本和图片。

>

用户并发权益

API 调用会受到速率限制，当前我们限制的维度是请求并发数量（在途请求任务数量）。不同等级的用户并发保障如下。

模型版本	V0	V1	V2	V3
GLM-4.1V-Thinking-Flash	5	10	15	20
GLM-4.1V-Thinking-FlashX	30	50	80	100

< [AutoGLM-Phone](#)

[GLM-Image](#) >