

[平台服务](#)

内容安全

 Copy page

了解智谱AI的内容安全审核机制，确保AI应用的安全可控和合规使用

① 智谱AI 致力于做到人工智能的安全可控、可审计、可监督、可追溯和可信赖。为此，我们内置了安全审核机制，旨在减少模型应用中违法及不良信息的出现。

安全审核机制

当我们的内置安全审核机制识别到违法及不良信息时，将提供相应的提示信息或进行拦截处置，例如通过输入拦截、输出限制和终止内容生成。

⚠️ 违法及不良信息包括但不限于：违反法律法规、危害国家安全、恶意营销、涉黄、谩骂、暴恐违禁以及其它不良内容。

模型同步响应

当 API 检测到模型输入或输出内容中含有违法及不良信息时，系统会向开发者返回错误码（1301）、输入（role = user）或输出（role = assistant）、严重程度（level 0-3，level 0 表示最严重，3 表示轻微），不再同步生成结果。

① 建议开发者采取措施，对用户进行正面引导，以确保内容的合规性和适当性。

返回示例

```
{
  "contentFilter": [
    {
      "level": 1,
      "role": "user"
    }
  ],
  "error": {
    "code": "1301",
    "message": "系统检测到输入或生成内容可能包含不安全或敏感内容，请您避免输入易产生敏感内容的"
  }
}
```

模型流式响应

在模型流式输出生成内容的过程中，我们会分批对模型生成内容进行检测，当检测到违法及不良信息时：

- API 返回错误码（1301）
- API（V4）返回停止词 `"finish_reason": "sensitive"`

⚠️ 开发者识别到相关信息，应及时采取终止生成、撤回、修改、清屏、重启等措施删除生成内容，并确保不将含有违法及不良信息的内容传递给模型继续生成，避免其造成负面影响。

返回示例

```
id='202408121950062bfd5bf951d24169',
choices=[,
  Choice(
    delta=ChoiceDelta(
      content='',
      role='user',
      tool_calls=None
    ),
    finish_reason='sensitive',
    index=0
  )
],
created=1723463407,
model='glm-4-0520',
usage=None,
extra_json=None,
content_filter=[
  {
    'role': 'user',
    'level': 1
  }
]
```

终端用户管理



在请求中发送终端用户ID可以协助平台对终端用户的违规行为、生成违法及不良信息或其他滥用行为进行干预。

当我们检测到您的终端用户存在违规、生成违法及不良信息或其他滥用行为时，平台将会对终端用户请求进行封禁处理，避免您的企业账号因终端用户的违规或滥用行为受到影响。

用户ID规范

- ID 是唯一标识终端用户的字符串



用户 ID 长度至少为 6 个字符，但不超过 128 个字符

您可以通过在 API 请求中上传终端用户 ID



>

请求示例

API请求示例



```
{
  "model": "glm-3-turbo",
  "messages": [
    {
      "role": "user",
      "content": "作为一名营销专家，请为智谱开放平台创作一个吸引人的slogan"
    },
    {
      "role": "assistant",
      "content": "当然，为了创作一个吸引人的slogan，请告诉我一些关于您产品的信息"
    },
    {
      "role": "user",
      "content": "智谱AI 开放平台"
    }
  ],
  "stream": "true",
  "user_id": "user_123456"
}
```

安全测试申请

⚠ 如果您需要进行安全相关的测试，请联系商务经理、致电（400-6883-991）进行申请，避免您的企业账号出现违规或滥用等问题。

违法及不良内容反馈



百度智能云高度重视生成式人工智能服务的安全性。如果您在开发过程中发现 API 存在任何安全问题，请联系企业微信客服或者致电（400-6883-991）告知我们。我们非常感谢您的贡献和支持。

联系方式



企业微信客服

通过企业微信联系我们的客服团队



客服热线

400-6883-991

模型计费

模态	计费单位	单价
图片	次	0.0004 元/次
文本	次	0.00012 元/次
视频	秒	0.0002 元/秒
音频	秒	0.00005 元/秒

< 提示词工程

模型迁移 >