

开始使用

核心参数

 Copy page

💡 在与模型进行交互时，你可以通过调整不同的参数来控制模型的输出，以满足不同场景下的需求。理解这些核心参数将帮助你更好地利用模型的能力。

快速参考

参数	类型	默认值	描述
do_sample	布尔值	<code>true</code>	是否对输出进行采样，以增加多样性。
temperature	浮点数	(依赖模型)	控制输出的随机性，值越高越随机。
top_p	浮点数	(依赖模型)	通过核采样控制多样性，建议与 <code>tempe</code>
max_tokens	整数	(依赖模型)	限制单次调用生成的最大 token 数。
stream	布尔值	<code>false</code>	是否以流式方式返回响应。
thinking	对象	<code>{"type": "enabled"}</code>	是否开启思维链深度思考，仅 <code>GLM-4.5</code>

参数详解

do_sample

`do_sample` 是一个布尔值（`true` 或 `false`），用于决定是否对模型的输出进行采样。

- **false**: 采用贪心策略, 总是选择概率最高的下一个 token。输出确定性高, 适用于需要精确、事实性回答的场景。

最佳实践:

- 需要可复现、确定性的输出时, 设为 **false**。
- 希望模型生成更多样、更有趣的内容时, 设为 **true**, 并配合 **temperature** 或 **top_p** 使用。

temperature

temperature (温度) 参数控制着模型输出的随机性。

- 较低的值 (如 0.2): 概率分布更“尖锐”, 输出更具确定性、更保守。
- 较高的值 (如 0.8): 概率分布更“平缓”, 输出更具随机性和多样性。

最佳实践:

- 在需要严谨、事实准确的场景 (如知识问答), 建议使用较低的 **temperature**。
- 在需要创意的场景 (如内容创作), 可以尝试较高的 **temperature**。
- 建议 **temperature** 和 **top_p** 只使用其中一个。

top_p

top_p (核采样) 通过从累积概率超过阈值的最小 token 集合中进行采样来控制多样性。

- 较低的值 (如 0.2): 限制采样范围, 输出更具确定性。
- 较高的值 (如 0.9): 扩大采样范围, 输出更具多样性。

最佳实践:

- 如果希望在保证内容质量的同时获得一定的多样性, **top_p** 是一个很好的选择 (推荐值 0.8-0.95)。

max_tokens

`max_tokens` 用于限制模型单次调用生成的最大 token 数量。GLM-4.6 最大支持 128K 输出长度，GLM-4.5 最大支持 96K 输出长度，建议设置不小于 1024。令牌是文本的基本单位，通常 1 个令牌约等于 0.75 个英文单词或 1.5 个中文字符。设置合适的 `max_tokens` 可以控制响应长度和成本，避免过长的输出。如果模型在达到 `max_tokens` 限制前完成回答，会自然结束；如果达到限制，输出可能被截断。

- 作用: 防止生成过长文本，控制 API 调用成本。
- 注意: `max_tokens` 限制的是生成内容的长度，不包括输入。

最佳实践:

- 根据应用场景合理设置 `max_tokens` 。如果需要简短回答，可设为较小的值（如 50）。

各模型的默认 `max_tokens` 和支持的最大 `max_tokens` :

模型编码	默认 max_tokens	最大 max_tokens
glm-5.1	65536	131072
glm-5v-turbo	65536	131072
glm-5	65536	131072
glm-5-turbo	65536	131072
glm-4.7	65536	131072
glm-4.6	65536	131072
glm-4.6v	16384	32768
glm-4.6v-flash	16384	32768
glm-4.6v-flashx	16384	32768
glm-4.5	65536	98304
glm-4.5-air	65536	98304

模型编码

BigModel

	默认 max_tokens	最大 max_tokens
glm-4.5-x	65536	98304
glm-4.5-flashx	65536	98304
glm-4.5v	16384	16384
glm-4.1v-thinking-flashx	32768	32768
glm-4.1v-thinking-flash	32768	32768
glm-4-air-250414	16384	16384
glm-4-flash-250414	32768	32768
glm-4-plus	动态计算	4095
glm-4-air	动态计算	4095
glm-4-airx	动态计算	4095
glm-4-flash	动态计算	4095
glm-4-flashx	动态计算	4095
glm-4v-plus-0111	1024	8192
glm-4v-flash	1024	1024

stream

- `stream` 是一个布尔值，用于控制 API 的响应方式。
- `false` (默认值): 一次性返回完整的响应，实现简单但等待时间长。
 - `true` : 以流式（SSE）方式返回内容，显著提升实时交互应用的体验。

最佳实践:

- 对于聊天机器人、实时代码生成等应用，强烈建议设为 `true` 。

thinking

- 类型: 对象
- 支持模型: GLM-4.5 及以上

属性:

- `type` (string):
 - `enabled` (默认): 开启思维链。GLM-4.6 GLM-4.5 会自动判断是否需要，而 GLM-4.5V 会强制思考。
 - `disabled` : 关闭思维链。

最佳实践:

- 在需要模型进行复杂推理、规划时，建议开启。
- 对于简单任务，可关闭以获得更快响应。

相关概念

- Token 用量计算
- 最大输出 Tokens
- 上下文窗口
- 并发数权益

希望这份文档能帮助你更好地理解和使用 API 的核心参数！

[>](#)