

[模型工具](#)

模型评测

[Copy page](#)

介绍

什么是模型评测？

模型评测（Model Evaluation）是指对人工智能或机器学习模型的性能进行系统性测量和分析的过程。评测的目标是衡量模型的准确性、效率、鲁棒性、公平性等量化指标，以确保其在实际应用中达到预期效果。

常见的评测指标包括准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1-score、AUC-ROC，以及针对大模型的困惑度（Perplexity）、多样性（Diversity）、推理速度（Inference Speed）等。此外，大模型评测还可能涉及对抗性测试、偏见检测以及人类偏好对齐（RLHF）等方面。

何时使用模型评测？

模型评测通常在以下情况下使用：

1. 模型接入应用场景：已有应用场景，需要进行模型选型，对比多个模型效果，评测可以帮助决策，确保选用了当前应用场景最好的模型。
2. 模型训练后验证：在模型训练完成后，需要评估其在测试集上的表现，以判断是否达到了可接受的标准。
3. 模型优化与调优：通过对不同版本的模型进行对比评测，找到最优的参数配置、架构或训练方法。
4. 模型上线前的质量控制：在模型部署到生产环境之前，进行严格评测，确保其稳定性、安全性和公平性。

>

支持哪些评测方法？

智谱 Bigmodel 目前支持以下两种自动评测方式：AI 裁判员自动评测和基线评测。

- AI 裁判员自动评测：全程无需人工参与，将基于自定义的评测指标，通过 AI 裁判员模型对模型输出效果进行自动打分。该方式具有高效、和公正性的优势，但评测结果高度依赖人为设定的评分维度和标准。该方法适用于在特定业务场景下进行模型比选。
- 基线评测：通过预制的基线评测集对模型的各项基础能力进行自动评测，包括 GSM8k, C-Eval, MMLU 等主流评测集。该方法适用于对微调模型的基本效果进行评价，以避免模型的通用泛化能力发生明显下降。

哪些模型可以评测？

当前评测3类模型：

1. Bigmodel 上所有的语言模型：GLM-4-Plus、GLM-4-0520、GLM-4-Long、GLM-4-Air、GLM-4-Flash、GLM-4-Zero-Preview 等；
 2. 微调后的语言模型：语言模型通过数据进行微调后的模型；
 3. 私有实例：云私私有化部署的语言模型；
包含哪些评测数据集和模板？
- AI 裁判员打分
 1. 打分指令（prompt）

你是一名公正的文本评分裁判，需要在`{{evaluation_scene}}`场景下（场景定义：`{{scene_desc}}`），按

<评分原则>

- 根据以下维度对回复进行评价，按权重从高到低排序：

`{{evaluation_metric}}`

- 每个维度的评分范围为 0 至 `{{max_score}}` 分，评分标准如下：

`{{score_details}}`

<评分步骤>

- 我将提供用户指令、参考答案和需要评估的“AI助手回复”，请按照以下流程对“AI助手回复”进行评价：

`{{steps}}`

<必须遵循>

- 严格依据评分原则进行评价，每个维度必须赋予整数分值。
- 禁止忽略任何维度或添加未提及的维度。

<输出要求>

- 仅输出 JSON 格式内容，禁止任何无关说明。

- JSON 输出模板：

```
{
  "综合评分": "[加权平均得分，取整]",
  "综合评分原因": "（总结综合评分原因）。具体表现如下：",
  "[维度1名称]": {
    "score": "[0至{{max_score}}间的整数分]",
    "analysis": "（简要描述该维度的亮点或不足）"
  },
  "[维度2名称]": {
    "score": "[0至{{max_score}}间的整数分]",
    "analysis": "（简要描述该维度的亮点或不足）"
  },
  // ... 其他维度表现
}
```

#需要分析的用户指令、参考答案和助手回复：

评分步骤(steps)	1. 参照评分原则，仔细阅读并理解用户输入的待评估内容。2. 识别出表现好的维度以
-------------	---

内容创作场景

评测场景(evaluation_scene)	内容创作
场景描述(scene_desc)	根据用户指定的主题、风格、体裁和目标受众，创作出符合要求的原创内容。如撰写
评测维度(evaluation_metric)	1. 需求符合度：严格遵循用户指定的主题、风格、体裁等要求；避免偏离主题、内容
最大分值(max_score)	10
分值标准(score_details)	将分值从高到低划分为三档进行赋分，你的打分需要尽可能严格。作为示例，参考答
评分步骤(steps)	1. 参照评分原则，仔细阅读并理解用户输入的待评估内容。2. 识别出表现好的维度以

- 基线评测

数据集名称	数据集描述
MMLU	评估模型世界知识掌握情况和解决问题的能力
C-Eval	评估模型对中文文本的理解和应用能力
GSM8K	评估基础数学范畴内的多步推理和解决问题的能力

评测步骤

模型评测计费说明

费用均使用【通用推理】模型价格，适用于评测集推理和AI裁判员评测指令两部分，创建评测任务时会预计算【任务消耗】和【任务价格】，**前3次评测免费**；
模型推理价格见[产品计费](#)通用模型计费板块，Batch的批量处理功能可以和评测工具叠加使用。

预估费用 ⓘ



预计消耗 200,574 tokens

预计花费 0.000000 元

开启批量处理，价格减半 ⓘ



创建评测任务

你可以通过页面操作来创建评测任务，入口如下：

点击“创建评测任务”按钮



选择评测方式

Bigmodel目前支持两种评测方式：AI裁判员自动评测和基线评测。

- 评测方式一：基线评测



AI裁判员自动打分

通过AI评测模型自动评测和打分, 生成评测报告



模型基线评测

通用评测集, 评测模型基本能力

评测模型 *

选择评测的模型对象, 支持标准模型和微调模型

选择模型



GLM-4-Plus



GLM-4-Flash



评测数据 *

选择用于评测的数据集, 官方提供多种可选

选择数据集



MMLU

15,000 tokens | 5000 条



C-Eval

15,000 tokens | 5000 条



AI裁判员模型

选择用于评测打分的模型



GLM-4-Flash 免费

智谱AI最受欢迎的免费大模型, 兼具“高速度”和“经济性”



GLM-4-Plus 本次免费

智谱全自研GLM大模型的最新旗舰版本, 各项性能与第一梯度模型持平

评测维度

MMLU

C-Eval

模型配置

✕

温度 (max_score) ①

0.20

多样性 (max_score) ①

0.20

网页检索 ①



调用指令 ①

system_prompt ①

请输入

0/500

user_prompt ①

{query}

请输入

0/500

取消

确认

1. 从评测模型列表中选择参评的模型 基线评测可选基础模型、私有化模型、微调模型。支持同时选择多个模型。 **模型配置**: 提供温度、多样性、网页检索、调用指令选择被评测的模型对象, 支持标准模型和微调模型。
- **温度**: 采样温度可以控制输出的随机性。取值范围为 [0.0,1.0], 其中值越大, 输出内容将更加随机和富有创造性; 值越小, 输出会更加稳定或确定。
 - **多样性**: 通过核取样 (Top-p Sampling) 调节模型输出的多样性。取值范围为 [0.0, 1.0], 表示模型在生成时仅考虑概率质量累积达到 top_p 的候选集。例如, 当值为 0.1 时, 解码器只从前 10% 累积概率的候选tokens中进行选择。若 top_p 设置为 0, 则此参数不生效。
 - **网页检索**: 打开后推理自动调用web_search进行评测。
 - **system_prompt**: 系统调用指令。
 - **user_prompt**: 用户指令, 可配置动态参数。
 - **query**: 为评测集中的用户问题, 可作为动态参数配置在user_prompt中。

数据集名称	数据集描述
MMLU	评估模型世界知识掌握情况和解决问题的能力
C-Eval	评估模型对中文文本的理解和应用能力
GSM8K	评估基础数学范畴内的多步推理和解决问题的能力

3. 选择AI裁判员模型

可选择glm-4-flash（免费）或glm-4-plus（旗舰）作为裁判员模型进行模型打分。

• 评测方式二：AI裁判员自动打分

1. 从评测模型列表中选择参评的模型

基线评测可选基础模型、私有化模型、微调模型。

支持同时选择多个模型。

模型配置：提供温度、多样性、网页检索、调用指令选择被评测的模型对象，支持标准模型和微调模型。

- 温度：采样温度可以控制输出的随机性。取值范围为 [0.0,1.0]，其中值越大，输出内容将更加随机和富有创造性；值越小，输出会更加稳定或确定。
- 多样性：通过核取样（Top-p Sampling）调节模型输出的多样性。取值范围为 [0.0, 1.0]，表示模型在生成时仅考虑概率质量累积达到 top_p 的候选集。例如，当值为 0.1 时，解码器只从前 10% 累积概率的候选tokens中进行选择。若 top_p 设置为 0，则此参数不生效。
- 网页检索：打开后推理自动调用web_search进行评测。
- system_prompt：系统调用指令。
- user_prompt：用户指令，可配置动态参数。
 - query：为评测集中的用户问题，可作为动态参数配置在user_prompt中。

2. 设置评测数据集

您可以选择平台内置数据集或上传新数据集。



- 翻译场景：将给定文本翻译成另一种语言。
- 数据抽取场景：阅读材料并完成信息提取、摘要生成、问题回答等任务。
- 内容创作场景：根据用户指定的主题、风格、体裁和目标受众，创作内容。
- 上传数据集格式：上传新数据集则需要如下规范
评测数据集需按照xlsx格式进行上传，数据包含用户问题“question”和参考答案ref_answer两个字段。

3. 选择AI裁判员模型

可选择glm-4-flash（免费）或glm-4-plus（旗舰）作为裁判员模型进行模型打分。前者适合简单任务，速度更快；后者适合复杂任务，推理能力较强，但是成本较高。

4. 配置评测指令

AI裁判员模型将基于评测指令对参评模型的回答进行打分。为确保不同场景下的评测结果符合您的业务要求，建议根据您的评测场景目标设置对应的评测场景、场景描述、评测维度名称、分值标准等动态变量。您可以前往模型体验中心对您的评测指令进行验证。



GLM-4-Flash 本次免费

智谱AI最受欢迎的免费大模型，兼具“高速
度”和“经济性”



GLM-4-Plus 本次免费

智谱全自研GLM大模型的最新旗舰版本，各项
性能与第一梯度模型持平

剩余免费使用次数（含本次）：3。免费次数用完后，会消耗推理资源包和账户余额，请确保账户内有可用资源；

评测指令 *

评测指令为裁判员模型的打分标准，可在[体验中心](#)测试

评测场景 (task) ⓘ

请输入

场景描述 (task_desc) ⓘ

请输入

0/500

评测维度 (key_metric) ⓘ

维度名称

维度定义



+ 添加维度

最大分值 (max_score) ⓘ

0.20

分值标准 (score_details) ⓘ

请输入

0/500

评分步骤 (steps) ⓘ

请输入

0/500

指令内容 ⓘ



<角色和任务>

你是一名公正的文本评分裁判，需要在 `${task}` 场景下（场景定义：`${task_desc}`），按照以下原则评估“AI助手回复”的质量。

<评分原则>

– 根据以下维度对回复进行评价，按权重从高到低排序：

`${key_metric}`

– 每个维度的评分范围为 0 至 `${max_score}` 分，评分标准如下：

`${score_details}`

<评分步骤>

– 我将提供用户指令、参考答案和需要评估的“AI助手回复”，请按照以下流程对“AI助手回复”进行评价：

`${steps}`

<必须遵循>

– 严格依据评分原则，必须赋整数分值。
– 禁止忽略任何维度或添加未提及的维度。

<输出要求>

– 仅输出 JSON 格式内容，禁止任何无关说明。
– JSON 输出模板：

```
```json
```

```
{
```

```
 "综合评分": "加权平均得分，取整",
```

```
 "综合评分原因": "（可选综合评分原因）"
```



评测状态	说明
编辑中	表示评测任务正在编辑过程中，您可以点击任务名称继续编辑。
排队中	表示评测任务正在排队等待执行。在请求高峰期，排队时间可能会延长，期间您无需进行任何操作。
推理中	表示评测任务正在执行中。在高负载时段，任务执行时间可能会延长，期间您无需进行任何操作。
停止中	表示评测任务正在停止。
已停止	表示评测任务已被停止。
完成	表示评测任务执行成功。点击任务名称可查看评测结果。
失败	表示评测任务执行失败。建议您提交工单咨询具体原因。

### 查看评测详情结果

在模型评测页面，当任务的评测状态为完成时，单击操作列的结果查看当前评测的任务信息及评测结果（区分为AI裁判员打分和基线评测两种评测方式）。

在评测详情页（如下图所示），您可以：

- 查看当前自动评测任务的评测模型、评测方式、AI裁判员模型器、评测指令（如果是进行AI裁判员自动打分）、评测数据集情况（包含题目总量、已完成量和失败量）、消耗tokens、优惠情况、实际费用。
  - 查看所有参评模型的模型名称、以及各自的评测结果报告。
  - 将当前评测任务的详细结果列表下载到本地（xlsx格式）。
1. 评测结果：AI裁判员打分 查看评测指令 您可以查看当前评测的评测指令Prompt。点击评测指令右侧的查看，可以展开完整的评测指令。

## 任务信息

### 基础信息

任务名称: 翻译GLM

评测模型: tran\_glm1.0

评测方式: AI裁判员打分

任务状态: 评测完成

AI裁判员模型: GLM-4-Flash

评测指令: [查看](#)

创建时间: 2023-03-08 16:49:08

### 评测数据

 翻译评测集.json (约20,000 tokens, 共5000题, 其中4880题评测成功, 20题评测失败)

### 费用信息

消耗tokens: 150,000 tokens 

优惠: [资源包抵扣](#) 

实际费用: ¥ 3.263  

批量处理: [未开启](#) 

## 评测结果

[下载评测结果](#)

### 多维度评分报告

 

模型名称	可理解度	准确度	贴合度	语境适应性
翻译GLM	2	2	4	4

### 综合评分报告

 

模型名称	1分	2分	3分	4分	5分	6分	平均分	标准差	中位数
翻译GLM	2	2	2	2	2	4	4	3	3

### 评测题目详情 (仅随机显示200条)

在评测结果栏 (如下图所示), 您可以:

- 直接下载评测结果报告。
- 查看多维度评分报告和综合评分报告。
- 点击表格右侧的图标切换表格/图。
- 点击评测题目右侧的红色感叹号查看该题目评测失败原因。

模型名称	可理解度	准确度	贴合度	语境适应性
翻译GLM	2	2	4	4

## 综合评分报告

模型名称	1分	2分	3分	4分	5分	6分	平均分	标准差	中位数
翻译GLM	2	2	2	2	2	4	4	3	3

## 评测题目详情 (仅随机显示200条)

评测题目	详情
1 A critical problem with the examination of learning in education is that there is an underlying assumption that the dynamic	查看
2 the N46 Jupyter Notebook you linked is cool but after all it just uses the original openai whisper python project so this is not directly useful .....	查看

- 在评测题目详情列表，可以随机显示不超过200条的评测题目，点击详情列中的查看，可以查看该题目的模型回复结果、评测得分以及评分原因（如下图所示）。点击对应模型得分右侧的原因，可查看完整的评分理由。

1/200

X

在时代飞速发展的现在,对孩子来说什么样的教育方法或两容才是对的? 用文言文回答

## 评测集结果

子在川上曰：“逝者如斯夫，不舍昼夜。”诚哉斯言！今日之世，风驰电掣，变迁迅速。育儿之道，亦当因时制宜，与时俱进。然则何谓适宜之教育方法乎？

一曰：德行教育为根本。子曰：“君子务本，本立而道生。”德育为先，品行端正，方能立足于世。父母师长者，当以身作则，以德育人。

二曰：因材施教。孟子曰：“教育者，因材施教也。”观察儿童之兴趣、特长，因势利导，激发潜能，使各尽其才。

三曰：注重实践。荀子曰：“不闻不若闻之，闻之不若见之，见之不若知之，知之不若行之。”实践出真知，教育当注重体验，使儿童在实践中增长见识，锻炼能力。

## GLM-4-Plus

4分 ①

子在川上曰：“逝者如斯夫，不舍昼夜。”诚哉斯言！今日之世，风驰电掣，变迁迅速。育儿之道，亦当因时制宜，与时俱进。然则何谓适宜之教育方法乎？

一曰：德行教育为根本。子曰：“君子务本，本立而道生。”德育为先，品行端正，方能立足于世。父母师长者，当以身作则，以德育人。

二曰：因材施教。孟子曰：“教育者，因材施教也。”观察儿童之兴趣、特长，因势利导，激发潜能，使各尽其才。

三曰：注重实践。荀子曰：“不闻不若闻之，闻之不若见之，见之不若知之，知之不若行之。”实践出真知，教育当注重体验，使儿童在实践中增长见识，锻炼能力。

四曰：培养创新能力。庄子曰：“夫子西游，见lgs牛，曰：‘蓍哉！吾友跬步以至。’”创新思维，勇于探索，方能引领时代。教育者当鼓励儿童发散思维，勇于尝试，培养创新能力。

总之，教育方法繁多，关键在于因时制宜，因地制宜，因人而异。教育者当秉持“立德树人”之理念，关注儿童全面发展，激发潜能，培养创新精神，以适应时代发展之需。

## GLM-4-Flash

4分 ①

子在川上曰：“逝者如斯夫，不舍昼夜。”诚哉斯言！今日之世，风驰电掣，变迁迅速。育儿之道，亦当因时制宜，与时俱进。然则何谓适宜之教育方法乎？

一曰：德行教育为根本。子曰：“君子务本，本立而道生。”德育为先，品行端正，方能立足于世。父母师长者，当以身作则，以德育人。

二曰：因材施教。孟子曰：“教育者，因材施教也。”观察儿童之兴趣、特长，因势利导，激发潜能，使各尽其才。

三曰：注重实践。荀子曰：“不闻不若闻之，闻之不若见之，见之不若知之，知之不若行之。”实践出真知，教育当注重体验，使儿童在实践中增长见识，锻炼能力。

四曰：培养创新能力。庄子曰：“夫子西游，见lgs牛，曰：‘蓍哉！吾友跬步以至。’”创新思维，勇于探索，方能引领时代。教育者当鼓励儿童发散思维，勇于尝试，培养创新能力。

总之，教育方法繁多，关键在于因时制宜，因地制宜，因人而异。教育者当秉持“立德树人”之理念，关注儿童全面发展，激发潜能，培养创新精神，以适应时代发展之需。

上一题

下一题

## 2， 评测结果：基线评测 在基线评测的评测结果栏，您可以：

- 查看基线评测整体指标，查看基线评测基于当前基线评测集榜单的评分结果。

>

评测结果			下载评测结果
基线评测整体指标			 
模型名称	MMLU	C-Eval	
GLM-4-Plus	66.8	63.2	
医疗GLM	66.8	63.2	
基线评测明细			
MMLU		C-Eval	
评测能力	GLM-4-Plus	医疗GLM	
人问学科	66.8	63.2	
社会学科	66.8	63.2	
文学	66.8	63.2	
数学	66.8	63.2	
逻辑学	66.8	63.2	
			去 10 页 < 1/20 >

## 下一步建议

- 如果您对被评测模型的评测结果，即可开始在您的任务中调用模型。
- 如果对评测结果不满意，可以选择其他模型重新评测，或者根据评测的结果明确优化方式。
- Prompt提示词工程优化的成本明显低于模型微调。您可以在Bigmodel的[prompt工程最佳实践](#)中学习相关知识。
- 如果模型频繁出现输出结果严重偏离参考答案的问题，建议你考虑引入知识库。

