

上下文增强技术报告

[Copy page](#)

① “上下文增强”检索旨在通过重建每个知识碎片的完整上下文，让AI能够像人类专家一样，不仅“读懂”文字，更能“理解”其背后的深层含义与结构，从而显著提升您知识问答系统的准确率和用户满意度。

上下文增强技术报告

随着大语言模型（LLM）的浪潮席卷各行各业，我们看到越来越多的企业正在使用我们的知识库产品，结合RAG技术构建智能问答、客服、和文档查询系统。然而，我们也敏锐地洞察到，当您的知识库变得庞大、文档变得冗长复杂时，传统的RAG技术开始显现出它的局限性。您可能也曾遇到过这些令人困扰的场景：

- 问了一个很具体的问题，系统却返回了风马牛不相及的段落。
- 明明知道答案就在某份报告的第三章，但系统就是找不到。
- 模型回答经常“张冠李戴”，错误地理解了专有名词或代词的指代。

这些问题的根源在于，传统RAG在处理文档时，会将文档“切割”成独立的知识碎片。这些碎片一旦脱离了原始的文档结构，就丢失了至关重要的上下文信息，变成了“无根之木，无源之水”。

为了解决这些痛点，我们推出“上下文增强”检索功能。这项技术旨在通过重建每个知识碎片的完整上下文，让AI能够像人类专家一样，不仅“读懂”文字，更能“理解”其背后的深层含义与结构，从而显著提升您知识问答系统的准确率和用户满意度

1. 挑战：传统RAG检索在复杂知识库中面临的三大难题

在深入了解我们的解决方案之前，让我们先清晰地定义传统RAG技术遇到的具体挑战：

挑战一：上下文缺失导致“语义漂移”



- 问题描述：当一篇长文档（如研究报告、法律合同）被切分成小段落，每个段落都失去了它的“位置感”。例如，“该系统性能提升了30%”这个段落，如果脱离了“第二季度财报-核心产品线表现”这一章节标题，AI将无法知道“该系统”具体指代什么，也无法理解这个性能提升是在哪个时间背景下发生的。
- 用户体感：模型回答模糊不清，甚至出现事实性错误。

挑战二：关键元信息丢失导致“检索失败”

- 问题描述：用户的提问方式是多样的。他们可能会问“2023年用户增长报告里关于新用户的部分怎么说？”，问题中包含了“文档名称”和“章节”等关键信息。但如果这些信息恰好没有出现在被切分的段落文本内，传统的检索方法就无法命中正确答案。
- 用户体感：系统频繁反馈“找不到相关信息”，尽管知识库中明明存在答案。

挑战三：单一检索模式的“能力缺口”

- 问题描述：目前主流的检索方式有两种，但都存在短板：
- 向量检索（Semantic Search）：擅长理解语义和概念，但对于精确的关键词、产品型号、专有名词（如 Model-X7）的匹配能力较弱。
- 关键词检索（Keyword Search，如 BM25）：能精准匹配关键词，但无法理解同义词、上下位概念或整体主题。例如，它无法理解“车辆安全性能”和“碰撞测试表现”之间的强关联。
- 用户体感：检索结果要么“抓不住重点”，要么“过于死板”。

2. 我们的解决方案：上下文增强

上下文增强功能通过自动化流程，为您的每一个知识切片生成一份信息丰富的“上下文摘要卡片”，并将其与原始文本“绑定”，共同参与检索。核心理念：为知识切片“恢复记忆” 想象一下，我们不再给AI提供孤立的段落，而是为每个段落都附上一张卡片，上面清晰地写着：“这段内容摘自《2024年第一季度市场分析报告》的‘竞品动态’章节，主要讨论了‘A公司’发布的新产品。其中提到的‘它’指的是A公司的新品。” 这张“卡片”就是我们自动生成的上下文描述（Contextual Text）。它通常包含：

- 来源信息：所属的文档名称、章节标题、列表序号等。



主题概括：对该切片核心内容的精炼总结。

关键实体：提取出的核心人物、产品、指标、时间等。

歧义消除：明确代词（如“它”、“该公司”）的具体指向。

风格保持：生成的描述语言与原文风格保持一致，确保语义连贯。



一个直观的例子：

原始切片文本	+自动生成的“上下文摘要卡片”
“在更新后，系统的响应时间缩短了50%。这极大地改善了用户体验。”	本文档为《Project Phoenix Q2 2024性能

通过这种方式，即使原始切片前言不搭后语，其增强后的整体也包含了丰富的语义上下文，无论是语义理解还是关键匹配都能精准命中。

3. 技术实现：三重保障，确保检索质量

为了将“上下文增强”的效果发挥到极致，我们在后端采用了稳健且高效的三重技术架构：

第一重：双索引架构（Dual-Index Structure）

我们同时为您的知识库构建两种类型的索引，各司其职：

- 向量索引（Vector DB）：负责语义理解。我们将“原始文本 + 上下文描述”整体进行向量化，使其能够在高维空间中捕捉复杂的语义关系。当用户提出一个概念性的问题时，它能迅速找到含义最相近的内容。
- 文本倒排索引（Elasticsearch BM25）：负责精确匹配。它对所有文本进行分词，能快速定位包含特定关键词、年份、产品型号的段落，弥补向量检索在细节上的不足。

第二重：加权融合排序（Weighted RRF Fusion）与重排模型

当用户发起一次查询时，我们会同时向两个索引“提问”，并各自获得一份候选结果列表。随后，通过加权RRF融合算法或重排模型，我们将两份列表进行合并与重排。



优势：这种混合检索策略确保了结果既有语义上的相关性，又不失关键词的精确性，达到“1+1 > 2”的效果。



- 灵活性：您还可以根据自身业务需求，调整向量检索和关键词检索的权重，实现最优的排序策略。

第三重：高效缓存与处理

我们深知在企业级应用中，效率和成本至关重要。

- 生成效率：上下文的生成过程经过高度优化，确保在知识库索引阶段的耗时可控。
- 缓存机制：对于已处理的文档，系统会智能利用缓存，避免重复计算，进一步提升大规模知识库的处理效率，并大幅降低 token 消耗成本。

4. 您是否应该启用“上下文增强”？

我们建议在以下场景中，优先启用此功能，您将获得立竿见影的效果：

场景一：拥有大量长篇、结构化文档

如果您的知识库包含大量研究报告、技术手册、财务报表、保险合同等，这些文档结构复杂、章节分明、内容存在前后引用关系。

场景二：需要进行深度、细粒度的问答

如果您的用户经常提出需要结合上下文才能回答的“情景类”问题，例如：“对照去年，我们今年的研发投入主要用在了哪些新项目上？”

场景三：对问答的准确性有极高要求

在智能客服、技术支持、企业内训等场景，错误的回答可能导致用户流失或内部决策失误。上下文增强能最大程度减少AI“幻觉”和事实错误。


不一定需要的情况：

如果您的知识库主要是由大量简短、独立的问答对（FAQ）、或独立的条文条款组成，每个问答或条款本身已经包含了完整的上下文，那么传统RAG方法可能已经足够，启用此功能的收益相对有限。

5. 性能评测


5.1 缓存命中率

经过测试，我们的缓存命中率普遍在80%以上，平均命中率在85%以上。这将使您可以使用极少的token消耗来处理大文档。





5.2 生成耗时

在我们的测试中，平均每个文档大约需要100秒左右的处理时间，超长文档（切片数量超过200个）平均耗时在300秒左右。



5.3 效果评测



Our evaluation takes a fine-grained, token-wise approach to evaluating retrieval accuracy and efficiency, which allows it to take components such as chunking into account. The presence or absence of relevant tokens is more important than their relative ranking in AI applications.


我们的评估采用细粒度、逐词的方法来评估检索的准确性和效率，这使得它能够考虑诸如分块等组件。在人工智能应用中，相关词元的出现与否比它们的相对排名更为重要。

由于正确切片和实际切片之间的差异，我们无法直接判断切片是否召回，因此我们定义了一个 token 级别的召回率，用于判断切片是否正确召回。当 token 召回率大于一定阈值（通常是 0.8）时，我们将该切片视为正确召回。

- 检索召回率 (Recall)：相关片段被成功召回的比例，衡量系统覆盖相关内容的能力。
- 检索精准率 (Precision)：检索片段中命中相关片段的比例，衡量系统返回结果的纯度。
- F1 Score：Precision 与 Recall 的调和平均，用于在两者存在权衡时提供一个综合评价指标，尤其适用于正负样本分布不均衡的检索与分类任务。
- 端到端语义一致性准确率 (End-to-End Semantic Accuracy)：模型基于检索结果生成的最终答案，与参考答案在语义层面的等价性或一致性比例。通常通过语义相似度模型、判别式评估器或人工标注判断，用于衡量完整 RAG 流程（检索 + 生成）的真实回答质量。

我们分别在三个场景下做了评测，学术论文场景、车书问答场景、保险条款场景，每一个场景都有不同程度的提升。

文档类型	基准召回率	上下文增强召回率	提升幅度	失败率下降
学术论文	33%	56.25%	+23.25%	-34.75%
车书问答	68%	80%	+12%	-37.5%
保险条款	53.60%	71.43%	+17.83%	-38.4%



说明：上下文增强技术对所有文档类型的召回率都有显著提升，其中学术论文提升最大(+23.25%)，车书问答召回率最高(80%)

后续我们将会在更多评测集上进行评测，相关评测数据会更新到文档中来，并形成一個上下文增强的最佳实践。

5.4 生成样例

• 样例一：学术论文

1.2.3.5 基于机器学习的轨迹规划方法

模型预测生成方法根据采样轨迹生成的模型预测生成轨迹。图4-12(b)为采样轨迹和模型预测生成轨迹的曲率变化值为 $0.004 \ 0 \ m^{-2}$ ，最小为 $-0.004 \ 2 \ m^{-2}$ ，标准差为 $2.04 \times 10^{-3} \ m^{-2}$ 。模型预测生成方法轨迹的曲率变化基于模型优化的方法的曲率变化率标准差相对于采样轨迹降低了34.3%，显著降低了轨迹的曲率波动，提升舒适性。

基于采样方法的轨迹曲率变化率反复震荡，主要原因是采样依据S-L 坐标系中心参考线进行。采样轨迹的横向偏移虽然是多项式，但是依赖于中心参考线的平滑程度。受限于真实高精地图的中心参考线曲率，采样轨迹的曲率可能发生突变和振荡。相比之下，模型生成轨迹的曲率平滑，主要原因是模型轨迹基于笛卡尔坐标系和客车车辆运动模型生成该案例测试说明，本文提出的轨迹规划框架可以提供一条安全、舒适的轨迹，可提供给下层的轨迹跟踪模块以供控制。

(a) 多阶段规划轨迹结果

图4-12 采样和优化轨迹对比

![id-96.png](https://space-static.coze.site/coze_space/7571752030017667091/upload,

BigModel

该片段出自《周扬-硕士论文-自动驾驶客车结构化道路高实时性轨迹规划算法研究》第四章高实时性动作与实验研究，对比了采样轨迹与模型预测生成轨迹的曲率变化率，指出模型优化方法使曲率变化率标准差降低，显著提升了轨迹舒适性，原因是模型轨迹基于笛卡尔坐标系和车辆运动模型生成，而非依赖S-L坐标系中心参考

- 样例二：金融报告

Note: The common stock of the registrant is also traded on the SWX Swiss Exchange.

Securities registered pursuant to section 12(g) of the Act: None

Indicate by check mark if the registrant is a well-known seasoned issuer, as defined in Rule 405 of the Securities Act: ☐ Yes ☒ No

Indicate by check mark if the registrant is not required to file reports pursuant to Section 13 or 15(d) of the Act: ☐ Yes ☒ No

Indicate by check mark whether the registrant (1) has filed all reports required by Section 13 and 15(d) of the Securities Act of 1933 and the Securities Exchange Act of 1934 during the preceding 12 months (or for such shorter period as the registrant was required to file such reports) and (2) has maintained all filing requirements that may apply: ☐ Yes ☒ No

Indicate by check mark whether the registrant has submitted electronically every report pursuant to Section 13 and 15(d) of the Securities Act of 1933 and the Securities Exchange Act of 1934 during the preceding 12 months (or for such shorter period as the registrant was required to file such reports): ☐ Yes ☒ No

Indicate by check mark whether the registrant is a large accelerated filer, an accelerated filer, a non-accelerated filer, a smaller reporting company, or an emerging growth company: ☒ Large accelerated filer ☐ Accelerated filer ☐ Non-accelerated filer ☐ Smaller reporting company ☐ Emerging growth company

If an emerging growth company, indicate by check mark if the registrant has elected not to use the extended transition period for complying with any new or revised financial accounting standards: ☐ Yes ☒ No

Indicate by check mark whether the registrant is a shell company (as defined in Rule 12b-2 of the Securities Exchange Act of 1934): ☐ Yes ☒ No

The aggregate market value of voting stock held by nonaffiliates of the registrant as of December 31, 2019 was approximately \$91.3 billion as of January 31, 2020 (approximately \$99.7 billion as of January 31, 2020).

Shares of common stock outstanding at January 31, 2020: 575.6 million

DOCUMENTS INCORPORATED BY REFERENCE

Parts of the Company's definitive proxy statement (to be filed pursuant to Regulation S-K of the Securities Act of 1933) for its annual meeting to be held on May 12, 2020, are incorporated by reference.

3M COMPANY

FORM 10-K

For the Year Ended December 31, 2019

Pursuant to Part IV, Item 16, a summary of Form 10-K content follows, including highlights of the Company's performance.

Beginning

Page

PART I

ITEM 1 Business 4

ITEM 1A Risk Factors 10

ITEM 1B Unresolved Staff Comments 13

ITEM 2 Properties 13

ITEM 3 Legal Proceedings 13

ITEM 4 Mine Safety Disclosures 13

PART II

ITEM 5 Market for Registrant's Common Equity, Related Stockholder Matters and Issuer Purchases of Equity Securities 15

ITEM 6 Selected Financial Data 15

ITEM 7 Management's Discussion and Analysis of Financial Condition and Results of Operations 21

ITEM 8 Financial Statements and Supplementary Data 21

ITEM 9 Changes in and Disagreements with Accountants on Accounting and Financial Disclosure 21

ITEM 10 Directors, Executive Officers and Corporate Governance 21

ITEM 11 Executive Compensation 21

ITEM 12 Security Ownership of Certain Beneficial Owners and Management; and Related Stockholder Matters 21

ITEM 13 Certain Relationships and Related Transactions, and Director Independence 21

ITEM 14 Principal Accounting Fees and Services 21

ITEM 15 Other Information 21

ITEM 16 Other Information 21

ITEM 17 Other Information 21

ITEM 18 Other Information 21

ITEM 19 Other Information 21



BigModel

This chunk is from "3M 2019 Form 10-K Annual Report, Section: Securities Registration and Company Information." It lists 3M's 1.500% Notes due 2031 trading as MMM31 on NYSE, indicates the common stock is also traded on the SWX Swiss Exchange, and provides regulatory compliance status including that 3M is a well-known seasoned issuer and accelerated filer. The chunk also includes market value data of voting stock held by nonaffiliates (\\$91.3 billion as of January 31, 2020) and shares outstanding information (575.6 million shares).