

模型工具

模型部署

 Copy page

概述

- ① 私有实例部署（Private Instance Deployment）是指将大模型在专属的计算资源上进行独立部署，以满足企业对数据安全、性能隔离、个性化定制和资源可控性的需求。

什么是私有模型部署？

与共享公共模型服务不同，私有实例部署为客户提供了专属的运行环境和服务能力，确保模型调用不会受到其他用户的干扰，同时支持更灵活的配置与扩展。



独享算力

专属 GPU/CPU 资源，避免多租户带来的性能抖动



可控访问

结合 VPC、内网、白名单等安全策略，保障数据传输安全



可定制化

支持模型参数、微调版本、推理配置等定制化需求



高可用与扩展性

支持水平扩展、负载均衡及容灾部署，保障高并发与稳定性

何时使用私有实例部署？

模型私有实例部署通常适用于以下场景：



- **高安全性要求的业务场景：** 例如金融、医疗、政企等对数据合规与隐私保护要求严格的行业
- **大规模并发调用：** 当业务需要大规模、高频次调用时，私有实例能提供更稳定的吞吐能力
- **性能隔离需求：** 确保关键业务调用不受其他用户的影响，保障 SLA
- **个性化模型定制：** 如需要长期运行经过专属数据微调的模型，并保证其仅对特定应用服务
- **成本可控与长期使用：** 适合有长期稳定需求的客户，相比公有实例调用可优化成本结构

哪些模型可以私有实例部署？

当前支持部署的模型包括：

- **智谱官方模型：** GLM-4.5-Air、GLM-4-Plus、GLM-4-0520、GLM-4-Air、GLM-4-Flash 等
- **微调后的模型：** 基于客户数据完成微调后的专属模型

如何进行部署

1. 模型部署入口

在[私有实例](#)页面点击“创建部署任务”按钮，选择要部署的基础模型/微调模型。





💡 你可以根据实际使用场景的并发需求选择部署实例的数量。实例部署需要一定时间（通常为10-30分钟，具体取决于模型大小）。我们会在部署完成后通过短信通知你。

新部署的模型的模型编码、状态及实例信息可在[私有实例](#)页面部署信息查看，并支持前往体验中心体验。



2. 模型实例变更与取消部署

操作实例变更与模型部署取消



您可以在[模型广场](#)的模型详情页或在[私有实例](#)页面选择已经部署的模型进行实例数量变更或者取消部署。

⚠ 取消部署动作将在操作后立即生效，取消后该部署模型无法再进行调用。

实例管理							
Q 请输入模型名称/模型编码							
部署模型	模型编码	部署方式	部署版本	量化版本	运行实例数	占用算力单元	部署状态
GLM-4-Air		私有实例	8k (函数调用版)	int4	1	1	部署成功

变更实例


实例管理							
Q 请输入模型名称/模型编码							
部署模型	模型编码	部署方式	部署版本	量化版本	运行实例数	占用算力单元	部署状态
GLM-4-Air		私有实例	8k (函数调用版)	int4	1	1	部署成功

模型修改
查看详情
取消部署
去体验

3. 模型推理

模型编码获取

您可以在[私有实例](#)页面直接复制模型编码。



模型调用

你可以通过体验中心或 API 使用模型。在进行 API 请求时，你可以将你命名的新的模型代码作为 `model` 参数的值传递。

调用示例

安装 SDK

```
# 安装最新版本
pip install zai-sdk

# 或指定版本
pip install zai-sdk==0.2.2
```

验证安装

```
import zai
print(zai.__version__)
```

```
from zai import ZhipuAiClient
>

# 初始化客户端
client = ZhipuAiClient(api_key="YOUR_API_KEY")

# 创建聊天完成请求
response = client.chat.completions.create(
    model="chatglm3-6b-1001", # 填写你需要调用的模型名称
    messages=[
        {
            "role": "system",
            "content": "你是一个名为chatGLM的AI助手。"
        },
        {
            "role": "user",
            "content": "你好，请介绍一下自己。"
        }
    ],
    temperature=0.7
)

# 获取回复
print(response.choices[0].message.content)
```

部署计费说明



计费规则

- **首次部署：** 实时扣减算力单元额度，后续每日凌晨扣减当日所需消耗算力单元
- **示例：** A模型部署1个实例，单实例算力单元2。今日下午16:30部署一个实例成功，则部署成功后扣减2个算力单元。次日起，每日凌晨扣减2个算力单元
- **取消部署：** 选择取消/减少实例时，次日起不再扣减对应实例的算力单元

Q：我应该在哪里查看资源包余额？

A：> **【[资源包管理](#)】** - **【我的资源包】** 中查看我的资源包余额。

Q：我应该去哪查询账单？

A：在 **【[财务总览](#)】** 中查看全部账单记录。

Q：部署已完成，在哪里添加 API Key？

A：您可前往 **【[API KEY](#)】** 页面可创建并管理您的 API Key。

Q：我是云私用户，已经购买了套餐，订单应该在哪里查看？

A：**【[订单明细](#)】** - **【云私订单明细】** 中查看已购套餐订单。