

新品发布

[📄 Copy page](#)

最新模型和产品发布公告

公告通知

2026-04-07

GLM-5.1 新一代旗舰模型上线

💬 [GLM-5.1](#)

- Coding 能力大大增强，长程任务（Long Horizon Task）显著提升，支持一次任务中独立、持续工作长达 8 小时，实现从规划、执行到交付的完整闭环
- 在自主规划、持续执行、问题修复与策略迭代上展现更强的工程智能，能够完成更长链路的复杂任务闭环
- 综合能力全面对齐 Claude Opus 4.6，成为首个在综合能力上实现全面对齐的中国模型，并跻身全球开源模型前列
- 通过 multi-turn SFT、RL 与过程质量评估体系，进一步强化长任务中的稳定性、一致性与 tool use 能力

2026-04-02

GLM-5V-Turbo 多模态 Coding 基座模型上线

👁️ [GLM-5V-Turbo](#)

- 兼顾视觉理解与 Coding 能力，在更小参数量下实现更优的性能表现，多模态任务处理更高效
- 细粒度理解、几何感知与空间理解能力进一步增强，复杂视觉推理更准确
- 强化 GUI Agent、Coding Agent 等复杂任务表现，更适合“看懂环境—规划动作—执行任务”的长流程场景
- 多模态工具链进一步扩展，在文本工具基础上新增支持画框、截图、读网页（含图片识别）等多模态 Tools

GLM-5-Turbo 龙虾增强 基座模型上线

GLM-5-Turbo

- 面向 OpenClaw 龙虾场景深度优化的基座模型
- 强化了对外部工具与各类Skills的调用能力，在多步任务中更稳定、更可靠
- 复杂指令拆解更强，能够精准识别目标、规划步骤，并支持多智能体之间的协同分工
- 能够更好理解时间维度上的要求，在复杂长任务中保持执行连续性
- 针对数据吞吐量大、逻辑链条长的龙虾任务，进一步提升了执行效率与响应稳定性

2026-02-12

GLM-5 新一代旗舰模型 上线

GLM-5

- 专为复杂系统工程与长程 Agent 任务设计，实现从代码到工程的范式跃迁
- 后端架构设计、复杂算法实现及顽固 Bug 修复上展现出卓越的深度推理能力
- 在代码逻辑密度和系统工程能力上直接对标 Claude Opus 4.5
- 首次集成 DeepSeek Sparse Attention，在维持长文本效果无损的同时，提升 Token Efficiency

2026-02-03

GLM-OCR 图文解析模 型上线

GLM-OCR

- 采用自研 CogViT 与 GLM-0.5B 的编码器-解码器设计，连接层实现高效跨模态对齐
- 基于数十亿图文对的 CLIP 预训练，具备强大的视觉语义与关键 Token 提取能力
- 模型小、速度快，在手写体、表格、印章、竖排等复杂场景中表现稳定

2026-01-19

GLM-4.7-Flash

- 轻量参数规模下实现了高效的 Coding 能力，任务理解与代码生成能力处于同类模型的较高水平
- 通用能力同级别最优，在写作、翻译、推理、角色扮演、长文本与审美等核心场景下兼顾质量与响应速度
- 为 GLM-4.7 的免费版本，针对高频调用场景进行优化，显著降低使用门槛与成本

2026-01-14

GLM-Image 图像生成
模型上线

GLM-Image

- 首个在国产芯片上完成全流程训练的 SOTA 多模态模型
- 采用「自回归理解 + 扩散解码」混合架构，模型能读懂指令、补全细节
- 知识密集型场景全面增强，文字渲染更稳更准（汉字尤其出色）

2025-12-22

GLM-4.7 基座模型上线

GLM-4.7

- Coding 能力全面提升，代码生成更稳、更完整，长代码与工程级场景下的一次性交付能力显著增强
- Agentic Coding 能力升级，支持以任务为中心的端到端开发
- 前端与视觉代码理解增强，生成页面在布局、交互与审美上更接近可展示、可直接使用的水平
- 通用对话与内容生成更可靠，复杂问题拆解更清晰，简单问题回应更直接，整体表达更自然、高效

2025-12-11

AutoGLM-Phone AI 手
机智能助理框架上线

AutoGLM-Phone

- 支持用自然语言自动完成 App 操作任务
- 具备界面识别、意图规划与设备执行的端到端处理能力，无需人工点击或复杂配置



• 已适配 50+ 主流中文应用场景，覆盖购物、出行、外卖、影音、资讯等高频任务

支持完整操作指令集，包括启动 App、输入文字、滑动、点击、回退、长按等，实现细粒度交互控制



2025-12-11

GLM-TTS-Clone 音色

克隆模型上线

GLM-TTS-Clone

- 只需录制约 3 秒清晰语音，即可生成专属音色
- 支持普通话及轻口音，更好复刻节奏、停顿、语气词等个性化表达
- 无论旁白、客服、剧情配音、教育讲解，均可保持音色统一与情感一致性
- 可与 GLM-TTS 联动，通过音色 ID 进行批量生产

2025-12-11

GLM-TTS 语音合成模型

上线

GLM-TTS

- 在架构上采用两阶段生成，在自然度、情绪表达与语调连贯性上实现全面升级
- 支持流式与非流式接口，首帧响应低于 400ms，实现低延迟的交互式体验
- 强化学习（GRPO）优化显著降低字错误率，并在开源评测中取得 SOTA 情感表达表现
- 支持灵活控制语速、音量与风格，满足客服、阅读、文旅、智能硬件等多场景需求

2025-12-10

GLM-ASR-2512 语音识

别模型上线

GLM-ASR-2512

- 行业出色语音识别性能，最新评测字符错误率（CER）仅 0.0717
- 支持多语言与方言识别，覆盖普通话、粤语、四川话、美式/英式英语及数十种全球常用语言
- 原生支持自定义词典，可快速导入专业术语、人名地名与项目代号，显著提升垂直行业识别精度

GLM-4.6V 视觉推理模型上线

👁️ GLM-4.6V

- 20+ 主流多模态评测基准全面验证，均取得 SOTA 成绩
- 原生支持工具调用，具备强大的图文混排创作能力，并能处理识图购物等复杂的视觉任务
- 视觉上下文窗口扩展至 128k，可单次处理约150页的复杂文档、200页PPT或一小时视频
- 针对前端开发场景深度调优，支持“截图即代码”，大幅提升 GLM Coding Plan 的开发与调试效率

2025-09-30

GLM-4.6 基座模型上线

💬 GLM-4.6

- 在公开基准与真实编程任务中展现出更强的代码能力
- 上下文窗口扩展至200K，提升处理长代码与复杂智能体任务的能力
- 推理过程进一步优化，支持在推理过程中调用工具，提升智能体任务执行的灵活性与效率
- 加强了模型在工具调用和智能体框架下的表现，使其在多场景应用中更加高效

2025-08-11

GLM-4.5V 视觉推理模型上线

👁️ GLM-4.5V

- 100B 级别开源视觉推理模型 SOTA，比 GLM-4.1V-Thinking “更大更强”
- 覆盖从视频理解、前端复刻、视觉定位、图像识别与推理，到复杂文档解析与 GUI Agent 等多场景的视觉任务
- 新增“思考模式”开关，可灵活选择快速响应或深度推理

2025-07-28

💬 **GLM-4.5**

- SOTA 级原生智能体大模型
- 参数效率翻倍，API 价格仅为 Claude 的1/10，极速版速度超 100tokens/秒
- 实测 Agentic Coding 表现优异，支持一键兼容 Claude Code 框架

2025-07-15

CogVideoX-3 视频生成
模型上线

 CogVideoX-3

- 新升级视频生成大模型，支持文生、图生视频
- 新增首尾帧生成功能
- 画面清晰度主观感受显著提升
- 主体大幅度运动自然流畅
- 提升了高清现实及 3D 风格场景表现

2025-07-02

GLM-4.1V-Thinking 系
列视觉推理模型上线

👁️ **GLM-4.1V-Thinking**

- 定位优势：通用视觉模型
- 核心能力：具备强大的多模态理解和推理能力
- 任务表现：在视频理解、图像问答、图表解读、图形界面操作等多任务项均达到新SOTA
- 能力特点：不止看得懂（基础视觉理解），更能想得透（深度推理能力）

2025-06-18

接入两个 Vidu 热门视频
生成模型



Vidu Q1

BigModel



- 聚焦高质量视频创作
- 固定输出 5 秒、24 帧、1080P 规格内容
- 凭借对清晰度的深度优化，画质质感大幅跃升
- 写实风格逼近真实场景，2D 动画画风精准保持
- 首尾帧转场更加丝滑
- 适用于影视、广告、动漫短剧等高要求创作场景



Vidu 2

- 平衡速度、质量与成本
- 主攻图生视频、首尾帧功能
- 支持 4 秒时长下 720P分辨率输出
- 画面稳定可控适配电商等场景
- 首尾帧语义理解与多参考图一致性增强
- 是泛娱乐、互联网、动漫短剧、广告量产的高效工具

2025-04-23

新增高识别精度、强抗噪能力的语音模型



语音模型 GLM-ASR

- 能够基于上下文理解将音频转录为符合语言习惯的文本
- 显著提升输出结果的流畅性和可读性
- 在噪音环境中较当前模型有明显较好的表现
- 不会被非语言类噪声干扰
- 支持中文、英语以及各地方方言（东北官话、胶辽官话、北京官话、冀鲁官话、中原官话、江淮官话、兰银官话和西南官话）
- 上新限时免费中～

2025-04-14

一次新增2个基座模型、
3个推理模型

- 在工程代码、Artifacts 生成、函数调用、搜索问答及报告撰写等任务上均表现出色
- 性能比肩 GPT-4o、DeepSeek-V3-0324 等大尺寸模型水平

GLM-4-Flash-250414 (免费版)

- 免费使用
- 在通用任务上依然表现出色
- 适合轻量化任务

推理模型

GLM-Z1-AirX (极速版)

- 性能优异的推理模型
- 速度最快可达 200 tokens/秒 (比常规快 8 倍)

GLM-Z1-Air (高性价比版)

- 价格仅为 DeepSeek-R1 的 1/30
- 适合高频调用场景

GLM-Z1-Flash (免费版)

- 免费使用
- 进一步降低模型使用门槛

2025-04-14

一站式 AI 搜索工具全家
桶更新升级

全系列 **AI 搜索工具** 升级上线，覆盖 基础检索 (Web Search API)、问答增强 (Web Search in Chat)、搜索智能体 (Search Agent) 三大服务。新增支持 bing、搜狗、夸克、Jina.ai 等主流搜索引擎，灵活切换。优化了意图识别和结果搜索的准确度。**上新限时特惠**

- **Web Search API:** 支持直接获取结构化搜索结果 (标题/摘要/链接等)，提供多搜索引擎支持 (智谱自研/bing/搜狗/夸克/Jina AI)。
- **Chat Search:** 将 Web Search API 的搜索结果融入大模型，生成智能回答，并标注网页结果来源。



Search Agent: 根据用户的 query，分析搜索意图，进行多个 query 拆解，将搜索结果融入大模型，提供
BigModel 更精准的回答。



功能更新 >