

对话补全

POST https://api.deepseek.com/chat/completions

根据输入的上下文，来让模型补全对话内容。

Request

APPLICATION/JSON

▼ BODY **REQUIRED**

> messages	object[]	REQUIRED
model	string	REQUIRED
Possible values: [deepseek-v4-flash, deepseek-v4-pro]		
使用的模型的 ID。		
> thinking	object	NULLABLE
reasoning_effort	string	
Possible values: [high, max]		
控制模型的推理强度。对普通请求，默认为 high。对一些复杂 Agent 类请求（如 Claude Code、OpenCode），自动设置为 max。出于兼容考虑 low、medium 会映射为 high，xhigh 会映射为 max。		
max_tokens	integer	NULLABLE
限制一次请求中模型生成 completion 的最大 token 数。输入 token 和输出 token 的总长度受模型的上下文长度的限制。取值范围与默认值详见文档。		
> response_format	object	NULLABLE
> stop	object	
	nullable	
stream	boolean	NULLABLE
如果设置为 True，将会以 SSE（server-sent events）的形式以流式发送消息增量。消息流以 data: [DONE] 结尾。		
> stream_options	object	NULLABLE
temperature	number	NULLABLE

Possible values: `<= 2`

Default value: `1`

采样温度，介于 0 和 2 之间。更高的值，如 0.8，会使输出更随机，而更低的值，如 0.2，会使其更加集中和确定。我们通常建议可以更改这个值或者更改 `top_p`，但不建议同时对两者进行修改。

top_p number

NULLABLE

Possible values: `<= 1`

Default value: `1`

作为调节采样温度的替代方案，模型会考虑前 `top_p` 概率的 token 的结果。所以 0.1 就意味着只有包括在最高 10% 概率中的 token 会被考虑。我们通常建议修改这个值或者更改 `temperature`，但不建议同时对两者进行修改。

> tools object[]

NULLABLE

> tool_choice

object

nullable

logprobs boolean

NULLABLE

是否返回所输出 token 的对数概率。如果为 true，则在 `message` 的 `content` 中返回每个输出 token 的对数概率。

top_logprobs integer

NULLABLE

Possible values: `<= 20`

一个介于 0 到 20 之间的整数 N，指定每个输出位置返回输出概率 top N 的 token，且返回这些 token 的对数概率。指定此参数时，logprobs 必须为 true。

user_id

NULLABLE

您自定义的 user_id，可选字符集为 [a-zA-Z0-9_-]，最大长度为 512。请不要在 user_id 中包含用户隐私信息。

user_id 可用于区分您业务侧的用户身份，以帮助我们进行内容安全处理。

user_id 可用于 KVCache 缓存隔离，以进行隐私管理。

user_id 可用于我们对您业务侧用户进行调度隔离。

关于 user_id 参数更详细的描述，请参考[限速与隔离](#)

frequency_penalty

DEPRECATED

该参数已不再支持。传入该参数将不会产生任何效果。

presence_penalty

DEPRECATED

该参数已不再支持。传入该参数将不会产生任何效果。

OK, 返回一个 `chat completion` 对象。

APPLICATION/JSON

Schema

Example (from schema)

Example

SCHEMA

id string	REQUIRED
该对话的唯一标识符。	
> choices object[]	REQUIRED
created integer	REQUIRED
创建聊天完成时的 Unix 时间戳（以秒为单位）。	
model string	REQUIRED
生成该 completion 的模型名。	
system_fingerprint string	REQUIRED
This fingerprint represents the backend configuration that the model runs with.	
object string	REQUIRED
Possible values: [<code>chat.completion</code>]	
对象的类型, 其值为 <code>chat.completion</code> 。	
> usage object	


CURL


PYTHON


GO


NODEJS


RUBY


CSHARP


PHP


JAVA

CURL

```
1 curl -L -X POST 'https://api.deepseek.com/chat/completions' \  
2 -H 'Content-Type: application/json' \  
3 -H 'Accept: application/json' \  
4 -H 'Authorization: Bearer <TOKEN>' \  
5 --data-raw '{  
6   "messages": [  
7     {  
8       "content": "You are a helpful assistant",  
9       "role": "system"  
10    },  
11    {
```

REQUEST

COLLAPSE ALL

✓ Base URL

https://api.deepseek.com

✓ Auth

Bearer Token

Bearer Token

✓ Body **REQUIRED**

```
{  
  "messages": [  
    {  
      "content": "You are a helpful assistant",  
      "role": "system"  
    },  
    {  
      "content": "Hi",  
      "role": "user"  
    }  
  ],  
  "model": "deepseek-v4-pro",  
  "thinking": {  
    "type": "enabled"  
  },  
  "reasoning_effort": "high",  
  "max_tokens": 4096,  
  "response_format": {  
    "type": "text"  
  },  
  "stop": null,  
  "stream": false,  
  "stream_options": null,  
  "temperature": 1,  
  "top_p": 1,  
  "tools": null,  
  "tool_choice": "none",  
}
```

```
"logprobs": false,  
"top_logprobs": null  
}
```

SEND API REQUEST

RESPONSE

CLEAR

Click the `Send API Request` button above and see the response here!