

DeepSeek API 升级，支持续写、FIM、Function Calling、JSON Output

今天，DeepSeek API 迎来更新，装备了新的接口功能，来释放模型的更多潜力：

- 更新接口 `/chat/completions`
 - JSON Output
 - Function Calling
 - 对话前缀续写 (Beta)
 - 8K 最长输出 (Beta)
- 新增接口 `/completions`
 - FIM 补全 (Beta)

所有新功能，均可使用 `deepseek-chat` 和 `deepseek-coder` 模型调用。

一、更新接口 `/chat/completions`

1. JSON Output，增强内容格式化

DeepSeek API 新增 JSON Output 功能，兼容 OpenAI API，能够强制模型输出 JSON 格式的字符串。

在进行数据处理等任务时，该功能可以让模型按预定格式返回 JSON，方便后续对模型输出内容进行解析，提高程序流程的自动化能力。

要使用 JSON Output 功能，需要：

1. 设置 `response_format` 参数为 `{'type': 'json_object'}`
2. 用户需要在提示词中，指导模型输出 JSON 的格式，来确保输出格式符合预期
3. 合理设置 `max_tokens`，防止 JSON 字符串被中途截断

以下为一个 JSON Output 功能的使用样例。在这个样例中，用户给出一段文本，模型对文本中的问题&答案进行格式化输出。

SYSTEM:

用户的输入包含一个问题和相应的答案，请解析出问题和答案，并将解析结果按 JSON 格式输出。

输入样例：

世界上最长的河是哪条？尼罗河

输出样例：

```
{"question": "世界上最长的河是哪条?",  
"answer": "尼罗河"}
```

USER:

游戏《黑神话悟空》什么时候发售？2024年8月20日

ASSISTANT:

```
{"question": "游戏《黑神话悟空》什么时候发售?",  
"answer": "2024年8月20日"}
```

详细使用方法，请参考 [JSON Output 指南](#)。

2. Function，连接物理世界


DeepSeek API 新增 Function Calling 功能，兼容 OpenAI API，通过调用外部工具，来增强模型与物理世界交互的能力。

Function Calling 功能支持传入多个 Function（最多 128 个），支持并行 Function 调用。

下图展示了将 `deepseek-coder` 整合到开源大模型前端 [LobeChat](#) 的效果。在这个例子中，我们开启了“网站爬虫”插件，来实现对网站的爬取和总结。



下图展示了使用 Function Calling 功能的交互过程：



详细使用方法，请参考 [Function Calling 指南](#)。

3. 对话前缀续写 (Beta)，更灵活的输出控制

对话前缀续写沿用了[对话补全](#)的 API 格式，允许用户指定最后一条 `assistant` 消息的前缀，来让模型按照该前缀进行补全。该功能也可用于输出长度达到 `max_tokens` 被截断后，将被截断的消息进行拼接，重新发送请求对被截断内容进行续写。

要使用对话前缀续写功能，需要：

1. 设置 `base_url` 为 `https://api.deepseek.com/beta` 来开启 Beta 功能
2. 确保 `messages` 列表里最后一条消息的 `role` 为 `assistant`，并设置最后一条消息的 `prefix` 参数为 `True`，如：

```
{"role": "assistant": "content": "在很久很久以前，", "prefix": True}
```

以下为对话前缀续写功能的使用样例。在这个例子里，设置了 `assistant` 消息开头为 ````python\n`，以强制其以代码块开始，并设置 `stop` 参数为 `````，让模型不输出多余的内容。

USER:

请帮我用 python 写一段快速排序的代码

ASSISTANT (prefix=True, stop='```'):

```
```python\n
```

**ASSISTANT:**

```
def quick_sort(arr):\n if len(arr) <= 1:\n return arr\n pivot = arr[len(arr) // 2]\n (省略)
```

详细使用方法，请参考 [对话前缀续写指南](#)。

#### 4. 8K 最长输出 (Beta)，释放更长可能

为了满足更长文本输出的场景，我们在 Beta 版 API 中，将 `max_tokens` 参数的上限调整为 8K。

要提高到 8K 最长输出，需要：

1. 设置 `base_url` 为 `https://api.deepseek.com/beta` 来开启 Beta 功能
2. `max_tokens` 默认为 4096。开启 Beta 功能后，`max_tokens` 最大可设置为 8192

---

## 二、新增接口 `/completions`

### 1. FIM 补全 (Beta)，使能续写场景

DeepSeek API 新增 FIM (Fill-In-the-Middle) 补全接口，兼容 OpenAI 的 FIM 补全 API，允许用户提供自定义的前缀/后缀（可选），让模型进行内容补全。该功能常用于故事续写、代码补全等场景。FIM 补全接口收费与对话补全相同。

要使用 FIM 补全接口，需要设置 `base_url` 为 `https://api.deepseek.com/beta` 来开启 Beta 功能。

以下为 FIM 补全接口的使用样例。在这个例子中，用户提供斐波那契数列函数的开头和结尾，模型对中间内容进行补全。

**PROMPT:**

```
def fib(a):
```

**SUFFIX:**

```
 return fib(a-1) + fib(a-2)
```

**MODEL:**

```
 if a == 0: return 0
 elif a == 1: return 1
```

详细使用方法，请参考 [FIM 补全指南](#)。

---

## 更新说明

Beta 接口已开放给所有用户使用，用户需要设置 `base_url` 为 `https://api.deepseek.com/beta` 来开启 Beta 功能。

Beta 接口属于不稳定接口，后续测试、发布计划会灵活变动，敬请谅解。

相关模型版本，在功能稳定后会发布到开源社区，敬请期待。