

DeepSeek-V4 预览版：迈入百万上下文普惠时代


今天，我们全新系列模型 DeepSeek-V4 的预览版本正式上线并同步开源。

DeepSeek-V4 拥有百万字超长上下文，在 Agent 能力、世界知识和推理性能上均实现国内与开源领域的领先。模型按大小分为两个版本：

模型	参数	激活	预训练数据	上下文长度	开源	API 服务	网页端/APP 访问方式
deepseek - v4 - pro	1.6T	49B	33T	1M	✓	✓	专家模式
deepseek - v4 - flash	284B	13B	32T	1M	✓	✓	快速模式

即日起登录官网 chat.deepseek.com 或官方App，即可与最新的 DeepSeek-V4 对话，探索 1M 超长上下文记忆的全新体验。API 服务已同步更新，通过修改 model_name 为 deepseek-v4-pro 或 deepseek-v4-flash 即可调用。

DeepSeek-V4-Pro：性能比肩顶级闭源模型



- **Agent 能力大幅提高：**相比前代模型，DeepSeek-V4-Pro 的 Agent 能力显著增强。在 Agentic Coding 评测中，V4-Pro 已达到当前开源模型最佳水平，并在其他 Agent 相关评测中同样表现优异。目前 DeepSeek-V4 已成为公司内部员工使用的 Agentic Coding 模型，据评测反馈使用体验优于 Sonnet 4.5，交付质量接近 Opus 4.6 非思考模式，但仍与 Opus 4.6 思考模式存在一定差距。
- **丰富的世界知识：**DeepSeek-V4-Pro 在世界知识测评中，大幅领先其他开源模型，仅稍逊于顶尖闭源模型 Gemini-Pro-3.1。
- **世界顶级推理性能：**在数学、STEM、竞赛型代码的测评中，DeepSeek-V4-Pro 超越当前所有已公开评测的开源模型，取得了比肩世界顶级闭源模型的优异成绩。



Benchmark (metric)		DS-V4-Pro	DS-V4-Flash	K2.6	GLM-5.1	Opus-4.6	GPT-5.4	Gemini-3.1-Pro
Reasoning Effort		Max	Max	Thinking	Thinking	Max	xHigh	High
Knowledge & Reasoning	MMLU-Pro (EM)	87.5	86.2	87.1	86.0	89.1	87.5	91.0
	SimpleQA-Verified (Pass@1)	57.9	34.1	36.9	38.1	46.2	45.3	75.6
	Chinese-SimpleQA (Pass@1)	84.4	78.9	75.9	75.0	76.2	76.8	85.9
	GPQA Diamond (Pass@1)	90.1	88.1	90.5	86.2	91.3	93.0	94.3
	HLE (Pass@1)	37.7	34.8	36.4	34.7	40.0	39.8	44.4
	LiveCodeBench (Pass@1)	93.5	91.6	89.6	-	88.8	-	91.7
	Codeforces (Rating)	3206	3052	-	-	-	3168	3052
	HMMT 2026 Feb (Pass@1)	95.2	94.8	92.7	89.4	96.2	97.7	94.7
	IMOAnswerBench (Pass@1)	89.8	88.4	86.0	83.8	75.3	91.4	81.0
	Apex (Pass@1)	38.3	33.0	24.0	11.5	34.5	54.1	60.9
	Apex Shortlist (Pass@1)	90.2	85.7	75.5	72.4	85.9	78.1	89.1
Long	MRCR 1M (MMR)	83.5	78.7	-	-	92.9	-	76.3
Context	CorpusQA 1M (ACC)	62.0	60.5	-	-	71.7	-	53.8
Agentic	Terminal Bench 2.0 (Acc)	67.9	56.9	66.7	63.5	65.4	75.1	68.5
	SWE Verified (Resolved)	80.6	79.0	80.2	-	80.8	-	80.6
	SWE Pro (Resolved)	55.4	52.6	58.6	58.4	57.3	57.7	54.2
	SWE Multilingual (Resolved)	76.2	73.3	76.7	73.3	77.5	-	-
	BrowseComp (Pass@1)	83.4	73.2	83.2	79.3	83.7	82.7	85.9
	HLE w/tools (Pass@1)	48.2	45.1	54.0	50.4	53.1	52.0	51.6
	GDPval-AA(Elo)	1554	1395	1482	1535	1619	1674	1314
	MCPAtlas Public(Pass@1)	73.6	69.0	66.6	71.8	73.8	67.2	69.2
	Toolathlon (Pass@1)	51.8	47.8	50.0	40.7	47.2	54.6	48.8

DeepSeek-V4-Flash：更快捷高效的经济之选

- 相比 DeepSeek-V4-Pro，DeepSeek-V4-Flash 在世界知识储备方面稍逊一筹，但展现出了接近的推理能力。而由于模型参数和激活更小，相较之下 V4-Flash 能够提供更加快捷、经济的 API 服务。
- 在 Agent 测评中，DeepSeek-V4-Flash 在简单任务上与 DeepSeek-V4-Pro 旗鼓相当，但在高难度任务上仍有差距。

结构创新和超高上下文效率

DeepSeek-V4 开创了一种全新的注意力机制，在 token 维度进行压缩，结合 DSA 稀疏注意力 (DeepSeek Sparse Attention)，实现了全球领先的长上下文能力，并且相比于传统方法大幅降低了对计算和显存的需求。从现在开始，1M（一百万）上下文将是 DeepSeek 所有官方服务的标配。



Agent 能力专项优化

DeepSeek-V4 针对 Claude Code 、OpenClaw、OpenCode、CodeBuddy 等主流的 Agent 产品进行了适配和优化，在代码任务、文档生成任务等方面表现均有提升。下图为 V4-Pro 在某 Agent 框架下生成的 PPT 内页示例：

UGC传播与社交裂变设计

SOCIAL AMPLIFICATION & UGC STRATEGY

构建「触点-参与-分享-激励-再参与」的完整社交传播闭环，让每个地铁站成为内容生产引擎

社交传播飞轮

- ① 触点触发

地铁站内的品牌视觉+互动装置+灯箱构成第一触点，以高颜值、强差异的东方美学设计激发拍照冲动
- ② 轻量参与

集章、扭蛋、拍照打卡等<3分钟即可完成的轻量级参与门槛，确保通勤场景下的高转化率
- ③ 即时激励

完成互动即获茶券/周边/限定杯套等即时奖励，正向反馈强化参与满足感与品牌好感
- ④ 社交分享

内嵌话题标签+拍照辅助(补光灯/支架/样片引导)→用户自发发布小红书/抖音/朋友圈
- ⑤ 二次裂变

UGC内容触达好友圈→「FOMO效应」驱动新用户前往站点打卡→循环往复，声量指数级放大

传播效果预估（保守测算）

单站日均互动参与	80-150人次
基于地铁站内快闪行业均值(进站客流1-3%互动转化率)	
单站月均UGC产出	200-500条
小红书+抖音+朋友圈合计，含自然内容与活动引导内容	
单波次全网曝光量	300-800万次
含UGC自然传播+品牌官方内容+达人合作三层叠加	
全年累计UGC触达	1,500-3,000万次
四季四波叠加效应，Q3-Q4段品牌资产积累效果倍增	
核心话题阅读量	500-1,000万
#戳主茶席北京茶叙 #CHAGEE京城茶事 双话题年度累计	
互动转化率	8-15%
从互动参与到小程序领券门店消费的转化链路追踪	

Page 18 / 25

全年营销排期总览

ANNUAL MARKETING CALENDAR OVERVIEW

四季四波段 · 12个月全覆盖 · 30站轮转激活 · 全年品牌声量无空窗

1月	2月	3月	4月	5月	6月	7月	8月	9月	10月	11月	12月
波段1：春茶初会 (1-3月)			波段2：夏茶有约 (4-6月)			波段3：秋茶叙友 (7-9月)			波段4：冬茶归暖 (10-12月)		
春节、元宵、早春焕新 品牌亮相，视觉占领			毕业季、端午、春夏活跃 社交裂变，游戏化互动			暑期、七夕、中秋、国庆 文化深耕，感官沉浸			感恩节、立冬、圣诞、跨年 情感升温，会员转化		

月度活动强度

1月 新春开篇 · 品牌登场 3站 高强度	2月 元宵团圆 · 茶礼迎新 3站 高强度	3月 早春焕新 · 她力量 3站 中强度	4月 清明踏青 · 城市漫游 3站 中强度
5月 毕业季 · 青春茶会 3站 高强度	6月 端午茶香 · 盛夏启幕 3站 高强度	7月 暑期档 · 文化寻踪 3站 高强度	8月 七夕茶叙 · 中秋预热 3站 高强度
9月 中秋茶席 · 金秋品鉴 3站 高强度	10月 国庆献礼 · 感恩回馈 3站 中强度	11月 暖冬茶肆 · 社区深耕 3站 中强度	12月 岁末收官 · 跨年茶叙 3站 高强度

Page 21 / 25

全年营销排期总览（二）：站点使用频次与全域覆盖分析

ANNUAL MARKETING CALENDAR OVERVIEW

30站全年轮转逻辑 | 旗舰店复用策略 | 空白区域补充机制

南锣鼓巷站		2次	传媒大学站		1次	车公庄站		1次
奥林匹克公园站		2次	工人体育场站		1次	西直门站		1次
星火/朝阳站		1次	团结湖站		1次	丰台站		1次
四惠站		1次	双井站		1次	金台路站		1次
王府井站		2次	巴沟站		1次	湾子站(南)		1次
潘家园站		2次	宋家庄站(10号线)		1次	湾子站(北)		0次
前门站		1次	高家园站		1次	宋家庄站(亦庄线)		0次
鼓楼大街站		1次	呼家楼站		1次	七里庄站		0次
三元桥站		1次	珠市口站		1次	安华桥站		0次
四惠东站		1次	东四站		1次	花庄站		0次

站点使用策略说明：

• 旗舰店复用站（2次/年）：南锣鼓巷、奥林匹克公园、王府井、潘家园——均为高流量或大面积站点，在2个波段中出现但空间主题、视觉体系、互动内容完全错位焕新，确保「同一个站、完全不同的体验」

• 年度旗舰单次启用：星火/朝阳站（208m²）——全年最大空间仅在最能体现其价值的秋文化波段应用一次，保持稀缺性与期待感

• 单次精准使用站（15个）：根据波段主题与客群匹配度精准投放，避免资源浪费与消费者审美疲劳

• 非运营时段站：十里堡、安化桥、双井、望京站(亦庄线)、德胜门站(未来科学城线)等运营时段外或运营时段内非重点覆盖站，作为机动站储备或在非运营时段激活

分波段投资拆解与资源配置

QUARTERLY INVESTMENT BREAKDOWN & RESOURCE ALLOCATION

基于「标准配置档」500万基准方案的四季度资金与资源分配模型

季度预算拆解（基准方案·年度500万）

项目	Q1 春茶初会	Q2 夏茶有约	Q3 秋茶叙友	Q4 冬茶归暖	全年 合计	占比
站点租赁	30	35	38	42	145	29%
展陈搭建	48	52	55	60	215	43%
互动装置	12	15	15	13	55	11%
人员运营	8	10	10	12	40	8%
主题车厢	28	0	30	28	86	—
灯箱广告	10	12	12	15	49	—
创意设计	15	10	10	10	45	9%
合计(万元)	151	134	170	180	635	—

- 以上为「标准配置档」基准方案(含项目管理费及10%应急储备后的总额约500万, 不含增值税)
- Q4预算略高于其他季度, 因含跨年庆典事件(星火/朝阳站+奥林匹克公园站双主场, 增量约25-35万)
- 互动装置采用模块化设计+跨季复用策略, 实际硬件采购成本在Q1集中投入后, Q2-Q4仅覆盖迭代内容与部分新增件
- 展陈搭建Q2起复用基础结构件(框架/灯光/展台), 达标的本季度降低约15-20%, 表中已体现此优化效应
- 主题车厢Q2空缺(预算预留展陈搭建与灯箱, 因Q2重点为多站点互动体验升级)

API 访问

目前，DeepSeek API 已同步上线 V4-Pro 与 V4-Flash，支持 OpenAI ChatCompletions 接口与 Anthropic 接口。访问新模型时，base_url 不变, model 参数需要改为 deepseek-v4-pro 或 deepseek-v4-flash。

API 访问模型名	输入（缓存命中）	输入（缓存未命中）	输出	上下文长度
deepseek - v4 - pro	1 元	12 元	24 元	1M
deepseek - v4 - flash	0.2 元	1 元	2 元	

*受限于高端算力，目前 Pro 的服务吞吐十分有限，预计下半年昇腾 950 超节点批量上市后，Pro 的价格会大幅下调。

V4-Pro 与 V4-Flash 最大上下文长度为 1M，均同时支持非思考模式与思考模式，其中思考模式支持 reasoning_effort 参数设置思考强度（high/max）。对于复杂的 Agent 场景建议使用思考模式，并设置强度为 max。模型调用与参数调整方法请参考 [API 文档](#)。

请大家注意：旧有的 API 接口的两个模型名 deepseek-chat 与 deepseek-reasoner 将于三个月后（2026-07-24）停止使用。当前阶段内，这两个模型名分别指向 deepseek-v4-flash 的非思考模式与思考模式。

开源权重和本地部署

- DeepSeek-V4 模型开源链接：

<https://huggingface.co/collections/deepseek-ai/deepseek-v4>

<https://modelscope.cn/collections/deepseek-ai/DeepSeek-V4>

- DeepSeek-V4 技术报告：

https://huggingface.co/deepseek-ai/DeepSeek-V4-Pro/blob/main/DeepSeek_V4.pdf

「不诱于誉，不恐于诽，率道而行，端然正己。」

感谢每一位用户的信任与支持，大家的肯定、建议和期许，是我们不竭探索、持续进步的动力，也让我们始终坚守初心，专注于不懈的创新。

我们将始终秉持长期主义的原则理念，在尝试与思考中踏实前行，努力向实现 AGI 的目标不断靠近。

