

更新日志

时间: 2026-04-24

DeepSeek-V4

DeepSeek API 已支持 V4-Pro 与 V4-Flash，支持 OpenAI ChatCompletions 接口与 Anthropic 接口。访问新模型时，base_url 不变, model 参数需要改为 `deepseek-v4-pro` 或 `deepseek-v4-flash`。

旧有的 API 接口的两个模型名 `deepseek-chat` 与 `deepseek-reasoner` 将于三个月后（2026-07-24）停止使用。当前阶段内，这两个模型名分别指向 `deepseek-v4-flash` 的非思考模式与思考模式。

详细更新内容请[参阅文档](#)

时间: 2025-12-01

DeepSeek-V3.2

`deepseek-chat` 和 `deepseek-reasoner` 都已升级为 DeepSeek-V3.2。

- `deepseek-chat` 对应 DeepSeek-V3.2 的**非思考模式**
- `deepseek-reasoner` 对应 DeepSeek-V3.2 的**思考模式**

DeepSeek-V3.2-Speciale

我们非正式部署了 DeepSeek-V3.2-Speciale 的 API 服务，API 用户可以通过设置 `base_url="https://api.deepseek.com/v3.2_speciale_expires_on_20251215"` 访问该模型。该模型 API 价格不变，只支持思考模式下的对话功能，不支持工具调用等功能，最大输出长度默认为 128K，支持时间截止至北京时间 2025-12-15 23:59。

详细更新内容请[参阅文档](#)

时间: 2025-09-29

DeepSeek-V3.2-Exp

`deepseek-chat` 和 `deepseek-reasoner` 都已经升级为 DeepSeek-V3.2-Exp。

- `deepseek-chat` 对应 DeepSeek-V3.2-Exp 的非思考模式
- `deepseek-reasoner` 对应 DeepSeek-V3.2-Exp 的思考模式

详细更新内容请[参阅文档](#)

时间: 2025-09-22

DeepSeek-V3.1-Terminus

`deepseek-chat` 和 `deepseek-reasoner` 都已经升级为 DeepSeek-V3.1-Terminus。`deepseek-chat` 对应 DeepSeek-V3.1-Terminus 的非思考模式，`deepseek-reasoner` 对应 DeepSeek-V3.1-Terminus 的思考模式。

此次更新在保持模型原有能力的基础上，针对用户反馈的问题进行了改进，包括：

- 语言一致性：缓解了中英文混杂、偶发异常字符等情况；
 - Agent能力：进一步优化了 Code Agent 与 Search Agent 的表现。
-

时间: 2025-08-21

DeepSeek-V3.1

`deepseek-chat` 和 `deepseek-reasoner` 都已经升级为 DeepSeek-V3.1。`deepseek-chat` 对应 DeepSeek-V3.1 的非思考模式，`deepseek-reasoner` 对应 DeepSeek-V3.1 的思考模式。

- DeepSeek-V3.1 包含以下主要变化：
 - 混合推理架构：一个模型同时支持思考模式与非思考模式
 - 更高的思考效率：相比 DeepSeek-R1-0528，DeepSeek-V3.1-Think 能在更短时间内给出答案
 - 更强的 Agent 能力：通过 Post-Training 优化，新模型在工具使用与智能体任务中的表现有较大提升
 - SWE-bench Verified: 66.0

- SWE-bench Multilingual: 54.5
 - Terminal-bench: 31.3
-

时间: 2025-05-28

deepseek-reasoner

deepseek-reasoner 模型升级为 **DeepSeek-R1-0528**:

- **推理能力增强**
 - 基准测试提升显著 (Pass@1)
 - AIME 2025: 70.0 → 87.5 (+17.5)
 - GPQA: 71.5 → 81.0 (+9.5)
 - LCB_v6: 63.5 → 73.3 (+9.8)
 - Aider: 57.0 → 71.6 (+14.6)
 - 注: 复杂推理问题相比老版本R1会使用更多tokens
 - **Web前端开发能力优化**
 - 生成的网页与游戏更加美观
 - **幻觉降低**
 - 极大程度抑制了老版本R1所存在的幻觉问题
 - **Json Output与Function Calling 支持**
 - Function call性能
 - Tau-bench score: 53.5 (Airline)/63.9 (Retail)
-

时间: 2025-03-24

deepseek-chat

deepseek-chat 模型升级为 **DeepSeek-V3-0324**:

- **推理能力增强**
 - 基准测试提升显著
 - MMLU-Pro: 75.9 → 81.2 (+5.3)
 - GPQA: 59.1 → 68.4 (+9.3)
 - AIME: 39.6 → 59.4 (+19.8)

- LiveCodeBench: 39.2 → 49.2 (+10.0)

- **Web前端开发能力优化**
 - 代码生成准确率提升
 - 生成的网页与游戏前端更加美观
 - **中文写作能力升级**
 - 风格与内容优化
 - 实现与R1写作风格对齐
 - 中长篇写作内容质量提升
 - **功能增强**
 - 多轮交互式改写能力提升
 - 翻译质量与书信写作优化
 - **中文搜索能力优化**
 - 报告分析类请求优化，输出内容详实
 - **Function Calling 能力改进**
 - Function Calling 准确率提升，修复 V3 之前的问题
-

时间: 2025-01-20

deepseek-reasoner

- `deepseek-reasoner` 是我们的新模型 DeepSeek-R1. 可以通过指定 `model=deepseek-reasoner` 调用。
 - 详细更新，请参考: [DeepSeek-R1 正式发布](#)
 - 调用指南，请参考: [推理模型](#)
-

时间: 2024-12-26

deepseek-chat

- `deepseek-chat` 模型升级为 DeepSeek-V3，接口不变，可以通过指定 `model=deepseek-chat` 调用。
 - 详细更新，请参考: [DeepSeek-V3 正式发布](#)
-

时间: 2024-12-10

deepseek-chat

deepseek-chat 模型升级为 DeepSeek-V2.5-1210，模型各项能力提升，相关基准测试：

- 数学能力：在 MATH-500 基准测试中的表现从 74.8% 提升至 82.8%
- 代码能力：在 LiveCodebench (08.01 - 12.01) 基准测试中的准确率从 29.2% 提升至 34.38%
- 中文写作与推理能力：在内部测试集中表现也有相应提升

与此同时，全新版本的模型对文件上传和网页总结功能的用户体验进行了优化。

时间：2024-09-05

deepseek-coder & deepseek-chat 升级为 DeepSeek V2.5 模型

DeepSeek V2 Chat 和 DeepSeek Coder V2 两个模型已经合并升级，升级后的新模型为 DeepSeek V2.5。

为向前兼容，API 用户通过 `deepseek-coder` 或 `deepseek-chat` 均可以访问新的模型。

新模型在通用能力、代码能力上，都显著超过了旧版本的两个模型。

新模型更好的对齐了人类的偏好，在写作任务、指令跟随等多方面进行了优化：

- ArenaHard winrate从 68.3% 提升至 76.3%
- AlpacaEval 2.0 LC winrate从 46.61% 提升至 50.52%
- MT-Bench 分数从 8.84 提升至 9.02
- AlignBench 分数从 7.88 提升至 8.04

新模型在原Coder模型的基础上进一步提升了代码生成能力，对常见编程应用场景进行了优化，并在标准测试集上取得了以下成绩：

- HumanEval: 89%
 - LiveCodeBench (1-9月): 41%
-

时间：2024-08-02

API 上线硬盘缓存技术

DeepSeek API 创新采用硬盘缓存，价格再降一个数量级

更新详情请跳转文档 [API 上线硬盘缓存 2024/08/02](#)

时间：2024-07-25

API 接口更新

- 更新接口 `/chat/completions`
 - JSON 输出
 - Function 调用
 - 对话前缀续写 (Beta)
 - 8K 最长输出 (Beta)
- 新增接口 `/completions`
 - FIM 补全 (Beta)

更新详情请跳转文档 [API 升级新功能 2024/07/25](#)

时间：2024-07-24

deepseek-coder

deepseek-coder 模型升级为 DeepSeek-Coder-V2-0724。

时间：2024-06-28

deepseek-chat

`deepseek-chat` 模型升级为 DeepSeek-V2-0628，模型推理能力提升，相关基准测试：

- 代码，HumanEval Pass@1 79.88% -> 84.76%
- 数学，MATH ACC@1 55.02% -> 71.02%
- 推理，BBH 78.56% -> 83.40%

在 Arena-Hard 测评中，与 GPT-4-0314 的对战胜率从 41.6% 提升到了 68.3%。

模型角色扮演能力显著增强，可以在对话中按要求扮演不同角色。

时间：2024-06-14

deepseek-coder

`deepseek-coder` 模型升级为 DeepSeek-Coder-V2-0614，代码能力显著提升，在代码生成、代码理解、代码修复和代码补全上达到了 GPT-4-Turbo-0409 的水平，并拥有卓越的数学和推理能力，其通用能力与 DeepSeek-V2-0517 持平。

时间：2024-05-17

deepseek-chat

`deepseek-chat` 模型升级为 DeepSeek-V2-0517，模型在指令跟随方面的性能得到了显著提升，IFEval Benchmark Prompt-Level 准确率从 63.9% 跃升至 77.6%。此外，我们对API端的“system”区域指令跟随能力进行了优化，显著增强了沉浸式翻译、RAG 等任务的用户体验。

模型对于 JSON 格式输出的准确性得到了提升。在内部测试集中，JSON 解析率从 78% 提高到了 85%。通过引入恰当的正则表达式，JSON 解析率进一步提高至 97%。