

创建对话补全

📄 复制页面



为聊天消息创建补全结果。支持标准聊天、Partial Mode 和 Tool Use（函数调用）。

POST /v1/chat/completions

创建聊天补全

🔧 cURL ↕



```
curl --request POST \
  --url https://api.moonshot.cn/v1/chat/completions \
  --header 'Authorization: Bearer <token>' \
  --header 'Content-Type: application/json' \
  --data '
{
  "messages": [
    {
      "content": "<string>",
      "name": null,
      "partial": false
    }
  ],
  "model": "kimi-k2.6"
}
```

KIMI 开放平台



```
{
  "id": "<string>",
  "object": "chat.completion",
  "created": 123,
  "model": "<string>",
  "choices": [
    {
      "index": 123,
      "message": {
        "content": "<string>",
        "tool_calls": [
          {
            "id": "<string>",
            "function": {
              "name": "<string>",
              "arguments": "<string>"
            }
          }
        ]
      }
    }
  ]
},
{
  "usage": {
    "prompt_tokens": 123,
    "completion_tokens": 123,
    "total_tokens": 123
  }
}
```

创建一个对话补全请求，模型将根据输入的消息列表生成回复。

▸ content 字段说明

▸ 响应格式

授权

KIMI 开放平台

API 请求头需要一个 Bearer 令牌。使用 MOONSHOT_API_KEY 作为令牌。这是一个服务端密钥，请在 [API 密钥页面](#) 生成。

>

请求体

application/json

[kimi-k2.6](#) [kimi-k2.5](#) [kimi-k2](#) [kimi-k2-thinking](#) [moonshot-v1](#)

messages `object[]` 必填

包含迄今为止对话的消息列表。每个元素格式为 {"role": "user", "content": "你好"}。role 支持 system、user、assistant 其一，content 不得为空。content 字段可以是 string，也可以是 array[object]（用于多模态输入）

> Show child attributes

model `enum<string>` `默认值:kimi-k2.6` 必填

模型 ID

可用选项: `kimi-k2.6`

max_tokens `integer` 已弃用

已弃用，请使用 max_completion_tokens

max_completion_tokens `integer`

聊天补全生成的最大 Token 数量。如果不给的话，默认给一个不错的整数比如 1024。如果结果达到最大 Token 数而未结束，finish reason 将为 "length"；否则为 "stop"。此值为期望返回的 Token 长度，而非输入加输出的总长度。如果输入加 max_completion_tokens 超出模型上下文窗口，将返回 invalid_request_error。

response_format `object`

"icon_schema") 可启用 Structured Output，按指定的 JSON Schema 约束输出结构（推荐，需配合 json_schema 字段使用）。如果您在使用 JSON Schema 时遇到校验问题，欢迎到 walle GitHub Issues (<https://github.com/MoonshotAI/walle/issues>) 提交反馈。



> Show child attributes

stop string ▾

停用词，完全匹配时将停止输出。匹配到的词本身不会被输出。最多允许 5 个字符串，每个不超过 32 字节

stream boolean 默认值: false

是否以流式方式返回响应，默认 false

stream_options object

流式响应选项

> Show child attributes

tools object[]

模型可调用的工具列表

Maximum array length: 128

> Show child attributes

KIMI 开放平台

相似请求的响应以优化缓存命中率。对于 Coding Agent，通常是代表单个会话的 session id 或 task id；退出并恢复会话时应保持不变。对于 Kimi Code Plan，此字段为必填以提高缓存命中率。对于其他多轮对话 Agent，也建议使用此字段

safety_identifier string

用于检测可能违反使用政策的用户的稳定标识符。应为唯一标识每个用户的字符串。建议对用户名或邮箱进行哈希处理以避免发送可识别信息

thinking object

控制 kimi-k2.6 模型是否启用思考能力，以及是否完整保留多轮对话中的 reasoning_content。可选参数，默认值为 {"type": "enabled"}。

> Show child attributes

响应

200 ▾

application/json

聊天补全响应

id string

补全结果的唯一标识符

object string

对象类型

示例: "chat.completion"

model string

用于补全的模型

choices object[]

补全选项列表

➤ Show child attributes

usage object

➤ Show child attributes

此页面对您有帮助吗？

👍 是

👎 否

⏪ Partial Mode

模型列表 ➤

