

其他

批量推理定价

📄 复制页面



产品定价

Batch API 即批量推理 API，批量推理 API 费用为标准模型价格的 **60%**，适合大规模、低实时性要求的任务场景。

模型	计费单位	输入价格（缓存命中）	输入价格（缓存未命中）	输出价格	上下文窗口
kimi-k2.6（Batch）	1M tokens	¥0.66	¥3.90	¥16.20	262,144 tokens
kimi-k2.5（Batch）	1M tokens	¥0.42	¥2.40	¥12.60	262,144 tokens

此处 1M = 1,000,000，表格中的价格代表每消耗 1M tokens 的价格。

说明

- Batch API 支持 `kimi-k2.6` 和 `kimi-k2.5` 模型
- Batch API 不受实时并发限制，适合大批量任务
- 任务需在指定的 `completion_window` 内完成，超时将变为 `expired` 状态
- 详细使用方法请参阅 [Batch API 指南](#)

 Kimi K2.6 模型已正式发布，长程代码编写能力更强更稳。

KIMI 开放平台



< Moonshot V1

联网搜索定价 >

>

