

模型推理定价

模型推理价格说明

📄 复制页面



计费基本概念

计费单元

Token：代表常见的字符序列，每个汉字使用的 Token 数目可能是不同的。例如，单个汉字“夔”可能会被分解为若干 Token 的组合，而像“中国”这样短且常见的短语则可能会使用单个 Token。大致来说，对于一段通常的中文文本，1 个 Token 大约相当于 1.5-2 个汉字。具体每次调用实际产生的 Tokens 数量可以通过调用[计算 Token API](#) 来获得。

计费逻辑

Chat Completion 接口收费：我们对 Input 和 Output 均实行按量计费。如果您上传并抽取文档内容，并将抽取的文档内容作为 Input 传输给模型，那么文档内容也将按量计费。文件相关接口（文件内容抽取/文件存储）接口**限时免费**，即您只上传并抽取文档，这个API本身不会产生费用。

模型定价

请查看各模型的详细定价：



Kimi K2.6

多模态模型，支持视觉与文本输入



Moonshot V1

经典生成模型系列

 Kimi K2.6 模型已正式发布，长程代码编写能力更强更稳。

KIMI

开放平台



Kimi K2.6 >

