

G1 中文精读导读：用强化学习教大模型“在图上推理”

原文：Xiaojun Guo, Ang Li, Yifei Wang, Stefanie Jegelka, Yisen Wang (NeurIPS 2025)

本导读为面向初学者的中文学习笔记：含要点翻译、公式精讲与图表解读。

论文卡片

标题	G1: Teaching LLMs to Reason on Graphs with Reinforcement Learning (教大语言模型用强化学习在图上做推理)
作者	Xiaojun Guo, Ang Li, Yifei Wang, Stefanie Jegelka, Yisen Wang
机构	北京大学、MIT、慕尼黑工业大学 (TUM)
会议	NeurIPS 2025 (神经信息处理系统大会)
arXiv	2505.18499
代码	https://github.com/PKU-ML/G1
模型/数据	Hugging Face 合集 PKU-ML/G1 (含 Erdős 数据集与 G1 模型权重)
方向	图 (Graph) × 大模型 × 后训练 (强化学习 RL 路线)
一句话	第一个用强化学习 (可程序验证的规则奖励) 教大模型做图论推理的工作; RL 微调后 3B 小模型反超 24 倍大的模型。

1 一、这篇论文在解决什么问题

大语言模型 (Large Language Model, LLM, 如 GPT、Qwen、Llama) 已经很会写文章、解数学题、写代码了。但作者指出：它们在“**图 (graph) 推理**”上还很弱。所谓图，就是由**节点** (点) 和**边** (连线) 组成的结构，比如社交网络、地图、知识图谱、分子结构。很多现实问题本质上都是图问题，例如“两个城市之间最短怎么走”“这张网络里有没有环”“哪些点彼此相连”。

问题有多严重？文中提到：连 OpenAI 的 o1 这种顶尖模型，在最基础的“**判断图里两点是否连通**”任务上，准确率也低到只有 58.49% (差不多和瞎猜一半对一半)。这说明 LLM 并不能可靠地“看懂图”。

已有人尝试过几条路，但作者认为都有明显短板：

1. **换“图的写法”**：研究怎么把一张图“翻译”成文字 (邻接矩阵、边列表等) 喂给 LLM，但提升很有限，没有哪种写法在所有任务上都最好。

2. **指令微调 / 偏好微调**：用人工整理的图题数据集去“教”模型（如 GraphWiz）。但高质量图题数据又贵又难造；而且这种“照着标准答案背”的训练容易让模型**只会死记套路**、换个题型或换种问法就崩（作者在实验里证明了这一点）。
3. **从头预训练“图基础模型”**：受限于“缺乏大规模、通用的图表示数据”，难以推广。

本文的核心主张：在互联网海量数据上预训练过的 LLM，其实**本身就潜藏着图推理能力**，我们不需要喂它人类标注的答案，只要让它自己反复试错、**答对了就奖励它**，就能把这份能力激发出来。这条路就是**强化学习（Reinforcement Learning, RL）**。这正是 DeepSeek-R1 在数学和代码上大获成功的配方，本文第一次把它搬到**图推理**上。

【小白补丁】为什么偏偏选“图论问题”当试验场

RL 训练有个硬性前提：得能**自动判断模型答得对不对**，才能给出奖励。图论问题天生满足这一点——比如“最短路径”“有没有哈密顿路径”，都可以用程序（如 NetworkX 库）**一键算出标准答案或验证一个解是否合法**。这就像下围棋（AlphaGo）输赢有明确规则一样，不需要请人来打分，避免了人工标注的昂贵与偏差。所以图论是检验“RL 能不能教会图推理”的**完美沙盒**。

2 二、摘要中译

尽管大语言模型（LLM）已取得显著进展，它们在图相关任务上的能力仍明显有限，阻碍了真正通用模型的发展。已有尝试——包括预训练图基础模型或采用监督微调——常面临诸多挑战，例如缺乏大规模、可统一表示的图数据。我们提出 **G1**，一种简单而有效的方法，证明在**合成的图论任务**上施加强化学习（RL）能显著扩展 LLM 的图推理能力。为支持 RL 训练，我们构建了 **Erdős**——迄今规模最大的图推理数据集，包含 50 个难度各异的图论任务、10 万条训练数据与 5 千条测试数据，全部源自真实世界的图。借助在 Erdős 上的 RL，G1 在图推理上取得大幅提升：我们微调后的 **3B 模型甚至超过了体量为其 24 倍的 Qwen2.5-72B-Instruct**。经 RL 训练的模型还表现出强大的**零样本泛化能力**，可迁移到未见过的任务、领域和图编码方式，包括其他图论基准以及真实世界的节点分类、链接预测任务，**且不损害其通用推理能力**。我们的发现为构建强大的图推理器提供了一条高效、可扩展的路径：在图论任务上用 RL 微调 LLM，将预训练 LLM 的能力与海量、可自动生成的合成数据相结合，表明 LLM 本就具备图理解能力、而 RL 能成功地将其激发出来。代码已开源于 <https://github.com/PKU-ML/G1>，模型与数据集托管在 Hugging Face 合集 PKU-ML/G1。

3 三、四大核心贡献

1. **首次把 RL 用于图推理**：提出 G1，证明“适当微调过的 LLM 能变成更强的图推理器”，在大量合成图论任务上显著提升能力。
2. **提出 Erdős 数据集**：迄今规模最大、覆盖最全的图论数据集（50 个难度各异的任务，且独特地从真实世界的图采样构造），为图推理的训练与评测提供可靠平台。
3. **实证大幅领先**：在 Erdős 上相比基线最高提升约 46%；G1-7B 媲美 o3-mini 等顶尖推理模型，G1-3B 明显反超 Qwen2.5-72B-Instruct。
4. **强零样本泛化、不损通用能力**：在未见过的图任务/领域 (GraphWiz、GraphArena、Cora、PubMed) 上提升，同时**不削弱**数学与综合推理能力 (GSM8K、MATH、MMLU-Pro)，体现协同增益。

4 四、预备知识（小白先看这里）

这一节把全文最关键的几个概念讲清楚。看不懂公式没关系，先建立直觉。

【小白补丁】什么是强化学习 (RL)？它和“普通训练”有何不同

普通的**监督学习**是“给题 + 给标准答案，让模型照着学”——本质是**模仿**。**强化学习 (RL)**不一样：它只给题和一个**打分器 (奖励)**，让模型**自己生成答案**，答得好就加分、答得差就扣分，模型据此**调整自己以后更可能给出高分答案**。打个比方：监督学习像“抄范文背下来”，RL 像“自己反复做题，老师只告诉你对错，你自己摸索出解法”。本文发现：RL 这种“自己摸索”的方式，比“背范文”更能学到**真正会迁移**的解题能力。

【小白补丁】什么是“可验证奖励” (RLVR)

RLVR = Reinforcement Learning from Verifiable Rewards (基于可验证奖励的强化学习)。意思是：奖励不是靠人打分、也不是靠另一个 LLM 当裁判（那样既贵又可能被“钻空子”），而是用**确定性的程序规则**来判对错。本文用 NetworkX 库当“裁判”：模型答“最短路径是 [6,1,3,7,4]”，程序就能立刻验证这条路径是否真的存在且最短。对就给 +1，错就给 0。这种奖励**客观、便宜、无法作弊**，是本文方法能成立的基石。

【小白补丁】GRPO 与 PPO：RL 怎么“调整模型”

PPO (Proximal Policy Optimization, 近端策略优化) 是经典的 RL 算法，但它需要额外训练一个“价

值网络”来估计每步的好坏，开销大。**GRPO** (Group Relative Policy Optimization, **组相对策略优化**) 是 DeepSeek 提出的简化版：对同一道题，让模型一次采样一组（比如 5 个）答案，直接拿这组答案的平均分当基准——比平均分高的答案就“鼓励”，比平均分低的就是“抑制”。这样不需要价值网络，省一半开销。本文就用 GRPO。直觉：同一道题做 5 遍，对的那几遍以后多写、错的那几遍以后少写。

【小白补丁】RL 与 SFT（监督微调）的区别——本文反复对比的两条路

SFT (Supervised Fine-Tuning, 监督微调) = 拿“题 + 答案”直接让模型拟合，是**模仿/记忆**。**RL** = 让模型自己探索、用奖励引导，是**激发/泛化**。本文有一个很重要的发现（呼应 Chu et al. 的名言“SFT 记忆，RL 泛化”）：SFT 在图任务上分数也能不低，但它会**损害模型原本的数学/通用能力**（因为死记了图题套路）；而 RL 既能提升图推理、又能保住甚至略微提升通用能力。这是 RL 路线最大的卖点。

其他速记：**零样本 (zero-shot)** 指模型没在这种任务上训练过就直接去做；**CoT (Chain-of-Thought, 思维链)** 指让模型把推理过程一步步写出来再给答案；**rollout (轨迹/采样)** 指模型针对一道题生成的一条完整回答。

5 五、Erdős 数据集：先有“题库”才能训练与比拼

要做 RL，先得有海量、可自动判分的题。作者构建了 **Erdős** 数据集（取名纪念图论大师 Paul Erdős），是迄今**规模最大、覆盖最全**的图论推理数据集。它既是**训练集**，也是**评测基准**。关键设计有三点：

- **50 个任务、四档难度**：从最简单的“数节点个数”，到 NP 难的“最大独立集 / 旅行商问题”。训练集共 10 万条（每任务 2000 条），另留 5 千条测试。
- **答案可程序生成与验证**：用 NetworkX 的标准求解器生成标准答案；若一题有多个正确解，就写程序验证模型给的解是否合法（避免人工标注，也避免 LLM 裁判的偏差）。
- **图来自真实世界、统一用边列表描述**：不像以往多用随机图，作者从 Network Repository（含 30 多个领域的真实网络）采样，再用“带重启的随机游走”抽出 5~35 个节点的子图。图统一写成**边列表**形式，例如 (1, 2), (2, 3), ...。

下表（数据源自原文 Table 1）展示了四档难度的任务分布，以及基座模型 Qwen2.5-7B-Instruct 与 RL 训练后 G1-7B 的准确率对比——**这一栏对比最直观地说明了 RL 的威力**：

表 1: Erdős 的四档难度任务及 RL 前后准确率（数据源自原文 Table 1, 10 万训练/5 千测试）。

难度	任务占比	基座 Qwen2.5-7B	G1-7B (RL 后)
Easy（简单，如数节点、BFS、有无环）	29.16%	57.16%	95.07%
Medium（中等，如聚类系数、二部匹配）	22.91%	42.55%	88.91%
Hard（困难，如最短路、直径、旅行商）	33.33%	18.87%	50.44%
Challenging（挑战，如图同构、最大流、哈密顿路径）	14.58%	3.29%	23.57%

【小白补丁】为什么从“真实图”采样很重要

以往数据集多用 Erdős-Rényi 等随机图模型造图，但这些图和现实里遇到的图差别很大（现实网络往往有社区结构、长尾度分布等特性）。在真实图上训练，模型学到的能力更贴近实用，也更能泛化。这是 Erdős 区别于以往基准的一大特色。

6 六、训练方法：怎么用 RL 教会图推理

G1 的训练流程刻意保持简单（和 DeepSeek-R1 一致），就两部分：一个必做的 RL 阶段（用 GRPO 算法奖励正确回答）+ 一个可选的 SFT 热身阶段（只在开头给模型“补补基础”）。如果跳过 SFT 热身，得到的模型叫 G1-Zero。

6.1 第一步：为图任务设计“规则奖励”

不同任务答案类型不同（有的是一个数、有的是一个集合、有的是一条路径），作者设计了三种判分规则：

- **严格数值匹配**：答案是唯一确定值时（如“节点数”），只有和标准答案完全相等才给 +1，否则 0（且会做归一化，例如 0.5 与 1/2 视为相等）。
- **Jaccard 集合匹配**：答案是无序集合时（如“两点的共同邻居”），按 $|s \cap \hat{s}| / |s \cup \hat{s}|$ 给部分分（交集越大分越高）。这让“答对一半”也能拿到中间奖励，训练信号更平滑。
- **算法验证**：答案有多个合法解且无法穷举时（如“最短路径”“哈密顿路径”），写程序验证合法性——比如检查路径上每条边都存在、每个点恰好走一次。

6.2 第二步：用 GRPO 做强化学习（核心公式）

对训练集里的每个问题 q ，GRPO 先让当前模型 π_θ 采样出一组 G 个回答 $\{o_i\}_{i=1}^G$ ，它们各自拿到奖励 $\{r_i\}_{i=1}^G$ 。然后算出每个回答的“组内相对优势” A_i ——也就是它比这组的平均水平好多少（再除以标准差做归一化）：

$$A_i = \frac{r_i - \text{mean}(\{r_1, r_2, \dots, r_G\})}{\text{std}(\{r_1, r_2, \dots, r_G\})}. \quad (1)$$

直觉： $A_i > 0$ 表示这个回答“优于平均”，应该鼓励（提高它被生成的概率）； $A_i < 0$ 则抑制。关键是用同组的平均分当基准，所以不需要额外的价值网络。

接着，更新模型参数 θ ，使下面这个目标 $J_{\text{GRPO}}(\theta)$ 最大化：

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{q, \{o_i\}} \frac{1}{G} \sum_{i=1}^G \left[\min \left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\text{old}}}(o_i|q)} A_i, \text{clip} \left(\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\text{old}}}(o_i|q)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}}) \right]. \quad (2)$$

【小白补丁】把公式 (2) 拆开来读（不必硬背，理解三件事即可）

(1) 概率比 $\frac{\pi_\theta(o_i|q)}{\pi_{\theta_{\text{old}}}(o_i|q)}$ ：新模型相比旧模型，更/更不倾向于生成回答 o_i 。乘上优势 A_i ，就实现了“好答案多写、坏答案少写”。

(2) $\text{clip}(\dots, 1 - \epsilon, 1 + \epsilon)$ 与 $\min$ ：给这个概率比加一个“安全带”，不让模型一步迈太大（ ϵ 控制幅度，文中取 0.2）。这是 PPO/GRPO 训练稳定的关键技巧。

(3) $-\beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}})$ ：一个“别跑太偏”的拉绳。 D_{KL} 衡量新模型与原始基座模型 π_{ref} 的差距， β 是力度（文中取 0.001）。它防止模型为了刷图题分而遗忘原本的语言/通用能力——这也是 G1 “不损通用能力”的机制保障。

训练规模（源自附录）：从 Qwen2.5-Instruct (3B/7B) 出发，用 8 张 A800 GPU、批大小 512、仅训练 300 步就取得大幅提升，可见这条路数据高效。

6.3 第三步：可选的 SFT 热身（应对最难的任务）

对极难任务（如“图同构映射”），基座模型初始正确率几乎为 0——全是错答案，RL 就没有正向信号可学（因为组内没有一个“高于平均”的好样本可鼓励）。解法是先做一小段 SFT 热身，教会模型基本套路。两种方式：

- **Direct-SFT**：直接拿“问题 q + 最终答案 a ”微调，不含推理过程。简单，但教不会“怎么想”。
- **CoT-SFT**：用更强的模型（Qwen2.5-32B-Instruct）生成带思维链的解题轨迹 (q, c, a) ，只保留通过验证的正确轨迹（这叫“拒绝采样微调 RFT”），约 4500 条，再用它微调。本文默认的 G1 用的就是“CoT-SFT 热身 + RL”。

7 七、实验与结果：3B 反超 72B 是怎么回事

实验设置：基座用 Qwen2.5-Instruct (3B、7B)。对比对象包括闭源模型 (GPT-4o-mini、o3-mini)、开源指令模型 (Qwen2.5 系列 3B/7B/72B、Llama-3 系列)、蒸馏推理模型 (DeepSeek-R1-Distill-Qwen-7B)、以及专门训过图题的 GraphWiz (RFT/DPO 两版)。指标是在 Erdős 各难度上的平均准确率。

7.1 主结果：小模型大逆袭

表 2：不同 LLM 在 Erdős 上的测试准确率 (%) 对比 (数据源自原文 Table 2；越高越好，加粗为本文模型)。括号内为相对基座模型的提升。

模型	Easy	Medium	Hard	Challenging	平均
闭源 (参数未知)					
GPT-4o-mini	76.20	72.07	28.81	3.34	47.60
OpenAI o3-mini (带工具)	74.83	83.49	59.28	43.22	64.90
3B 量级					
Qwen2.5-3B-Instruct (基座)	45.71	30.18	9.44	1.29	22.72
Direct-SFT-3B (本文)	74.43	75.27	43.69	14.43	53.78
G1-3B (本文)	94.86	84.64	41.25	7.57	59.76 (+37.04)
7B 量级					
Qwen2.5-7B-Instruct (基座)	57.36	42.55	18.87	3.29	32.06
DeepSeek-R1-Distill-Qwen-7B	71.79	73.73	39.12	16.57	51.64
GraphWiz-7B-DPO	20.36	19.09	1.44	0.78	10.59
G1-7B (本文)	95.07	88.91	50.44	23.57	66.16 (+34.10)
70B 量级					
Llama-3.1-70B-Instruct	68.07	55.45	31.87	4.44	42.28
Qwen2.5-72B-Instruct	71.71	67.81	33.37	8.22	47.16

怎么读这张表 (几个关键数字)：

- **3B 反超 72B：**G1-3B 平均 **59.76%**，明显高于 Qwen2.5-72B-Instruct 的 47.16% 和 Llama-3.1-70B-Instruct 的 42.28%——一个 **3B 小模型**，打赢了体量约 **20~24 倍的大模型**。
- **7B 媲美 o3-mini：**G1-7B 平均 **66.16%**，已经追平顶尖推理模型 o3-mini (64.90%)、并超过 GPT-4o-mini (47.60%) 约 18.56 个百分点——而 o3-mini 的训练成本远高于 G1。
- **RL 提升巨大：**G1-3B 相对其基座 (22.72%) 提升 **+37.04**，G1-7B 相对基座 (32.06%) 提升

+34.10。在 Easy 任务上 G1-7B 高达 95.07%。

- 专门训图的 GraphWiz 反而很差：GraphWiz-7B-DPO 平均仅 10.59%。作者解释：它靠死记套路，换个题型/格式就崩——反衬出 RL 路线的泛化优势。

7.2 一张图看懂“RL 的作用”与“SFT 热身的加成”

图 1 是全文最直观的一张结果图：在 3B 量级上，对比三者——**基座**（Qwen2.5-3B-Instruct）、**G1-Zero-3B**（只做 RL，不热身）、**G1-3B**（CoT-SFT 热身 + RL）。




图 1: G1-3B 与 G1-Zero-3B 在 Erdős 各难度上的准确率对比（原文 Figure 1，图内英文为原文保留）。三组柱子从左到右：粉色 = Qwen2.5-3B-Instruct（基座，未训练）、橙色 = G1-Zero-3B（仅 RL）、蓝色 = G1-3B（CoT-SFT 热身后再 RL）。横轴为难度（Easy/Medium/Hard/Challenging/平均），纵轴为准确率（%）。

这张图说明两件事：

1. **光靠 RL 就已经脱胎换骨**：橙色（G1-Zero-3B）远高于粉色基座——平均从 22.7% 飙到 50.1%，完全不用任何人工标注答案，只靠“自己试错 + 规则奖励”。这印证了作者的核心假设：图推理能力本就潜藏在 LLM 里，RL 能把它激发出来（与 DeepSeek-R1-Zero 的发现一致）。
2. **SFT 热身锦上添花**：蓝色（G1-3B）在各难度上又稳稳高于橙色，平均 59.8% vs 50.1%，且越难的任务提升越明显。说明“先用 CoT-SFT 教点基础、再 RL”能学得更好、推理更规整。

7.3 泛化能力：换任务、换领域、换格式都能打

这是本文最有分量的部分——证明 G1 学到的不是“死套路”，而是**可迁移的图推理能力**（全部零样本，即没在这些新任务上训练过）：

- **其他图论基准**：在 GraphWiz 上 G1-7B 取得最高 57.11%，甚至超过专门在 GraphWiz 上训过的 GraphWiz-7B-RFT (49.61%)；在 GraphArena 上（该基准用人名而非整数表示节点，换了图的写法）G1-7B 也大幅领先（41.10% vs 基座 28.84%）。说明 G1 能适应没见过的图编码格式与题型。
- **真实世界图任务**：在 Cora/PubMed 引文网络上做**节点分类**与**链接预测**（这类任务要同时用图结构和文本属性，和训练时的纯图论题很不一样），G1-7B 平均 87.29% 拿下最高分，G1-3B 也比基座大幅提升（Cora 链接预测 +16.82%）。
- **不损通用能力（关键!）**：见下表。CoT-SFT 会**拉低**数学/通用分数（死记套路的副作用），但**后续**的 RL 阶段把它救了回来，G1-7B 在三项基准上**全面超过**原始基座。

表 3：图外的通用推理基准上的准确率（%）（数据源自原文 Table 8）。重点看 CoT-SFT 掉分、而 G1（RL 后）回升甚至超过基座。

模型	GSM8K（数学）	MATH（数学）	MMLU-pro（综合）
Qwen2.5-7B-Instruct（基座）	86.27	69.80	45.75
CoT-SFT-7B（仅热身，掉分）	83.85	65.80	44.79
G1-7B（RL 后，回升）	87.49	71.80	48.56

【小白补丁】为什么“不损通用能力”这么值得强调

很多“专精微调”都会付出代价：把模型练成某领域的专家，却让它在别处变笨（叫“灾难性遗忘”）。本文展示了一个反直觉而美好的结果：**只在图任务上做 RL，却连数学、经济学等不相关科目都一起变强了**（如 MMLU-Pro 的经济学从 46.87 涨到 68.76）。作者推测 RL 提升的是底层的“数值计算与信息利用”等通用推理素质，而非死记某类题。公式 (2) 里那个 KL 拉绳也帮了忙——它拦住了模型“跑偏遗忘”。

7.4 两个有意思的分析

- (1) **数据配比**：G1-3B 在最难的两档上略逊于 Direct-SFT-3B。作者发现这是因为**奖励信号不均衡**——简单题更容易答对、拿奖励，RL 就把“注意力”更多分给了简单题。证据：单独只用难题训练的 G1-Hard-3B，在 Hard/Challenging 上反超（48.50% / 17.43%），且**学难题还能顺带提升简单题**（“学会解难题，简单题自然会”）。
- (2) **RL 改变了“解题策略”**：以“最短路径”为例（见原文 Figure 2 的案例对比），基座模型爱用复杂的 **Dijkstra 算法**，但因要维护优先队列、容易算错（图中它甚至误判“节点 4 没有边”而答

错)。而 RL 训练后的模型放弃了笨重的 Dijkstra，转而采用更轻便的 BFS（广度优先搜索）+ 直觉式探索，反而又快又准。作者的洞见：RL 引导模型选择“与自身能力相适配”的策略，而不是硬套教科书算法。

8 八、附录里值得一看的补充

- **扩展到 32B** (Table 15): G1-Zero-32B 平均从 47.10% 提升到 **75.06%** (+27.96)，且数学能力不降反升 (MATH +4.00)，证明方法可**规模化**。
- **扩展到更大的图** (Table 12): 在 36~100 节点的更大图上（训练时只见过 5~35 节点），G1 仍**零样本**大幅领先基座，说明能力可外推到训练分布之外（更大的图受限于 LLM 上下文窗口）。
- **稳健性**: 32 个随机种子重跑、以及 GPT-4o 改写的 3 种等价提示，标准差都**小于 1.5%**，说明结果稳定、对“换种问法”不敏感。
- **关键超参** (附录 A.3): GRPO 取 $\epsilon = 0.2$ 、 $\beta = 0.001$ 、组大小 $G = 5$ 、上下文 4096，额外加权重 0.001 的熵损失鼓励探索；训练 300 步。

9 九、小白知识点卡片（速查）

- **图论任务 (graph-theoretic task)**: 只关心结构的题，如连通性、最短路、环、哈密顿路径。
- **强化学习 (RL)**: 让模型自己试错、用奖励引导，是“激发”而非“模仿”。
- **RLVR (可验证奖励的 RL)**: 奖励由确定性程序判定（对/错），客观且无法作弊。
- **GRPO**: 用“同一题一组答案的平均分”当基准的简化 RL 算法，无需价值网络。
- **PPO**: 经典 RL 算法，需额外价值网络；GRPO 是其轻量替代。
- **SFT (监督微调)**: 拿“题 + 答案”直接拟合，倾向记忆；本文证明易损通用能力。
- **CoT (思维链)**: 让模型把推理过程一步步写出来。
- **零样本泛化 (zero-shot generalization)**: 没在新任务上训练就能做对。
- **KL 散度 (D_{KL})**: 衡量新旧模型差距的“拉绳”，防止跑偏遗忘。
- **NetworkX**: Python 图处理库，本文用它生成标准答案与验证解。
- **NP 难 / NP 完全**: 一类计算上很难的问题（如旅行商、最大独立集），没有已知的快速精确算法。

10 十、一句话总结与定位

一句话：G1 第一次证明——不喂人工答案，只让 LLM 在“可程序验证”的图论题上反复试错、答对就奖励（用 GRPO 做强化学习），就能把模型潜藏的图推理能力激发出来；结果一个 3B 小模型反超 24 倍大的对手、7B 媲美 o3-mini，还零样本泛化到没见过的图任务、且无损通用能力。

在“图 × 后训练”谱系里的位置：G1 是这一谱系中“强化学习 (RL)”路线的代表作。对照本系列其他工作“把图的信息塞进 LLM”的不同方式：

- **G-Retriever** 走“检索 + 轻量后训练（软提示）”——检索相关子图当外部知识；
- **LLaGA** 走“投影器对齐”——把图编码成向量对齐进 LLM；
- **InstructGraph / GraphWiz** 走“指令微调 + 偏好优化 (DPO)”——用标注数据教；
- **G1 (本文)** 走“强化学习”——不教标准答案，让模型自己摸索。

本文特别地反衬出 **SFT/指令微调路线的局限**（GraphWiz 在跨任务时崩盘、SFT 损害通用能力），而 RL 路线**泛化更好、不伤本领**——这也呼应了“SFT 记忆、RL 泛化”的观点，预示着图推理乃至更广义的结构化推理，可能正从“堆数据做监督微调”转向“用合成可验证任务做 RL”。

动手复现：官方代码 <https://github.com/PKU-ML/G1>，数据集与模型权重在 Hugging Face 合集 PKU-ML/G1（含 Erdős 全部任务提示、思维链样例与解答验证程序），是入门“图推理 + RL 后训练”的优质练手项目。